

« Des données propres sont la fondation de toute analyse juste. Une heure investie dans le nettoyage en économise dix en débogage et en erreurs d'interprétation. »

CHAPITRE I – PRINCIPES FONDAMENTAUX

— LES RÈGLES QUI NE SE NÉGOCIENT PAS —

Ne touche jamais aux données brutes. Travaille toujours sur une copie. La donnée originale est un trésor – si ta transformation est incorrecte, tu dois pouvoir revenir en arrière sans recollecte. Cette règle semble évidente jusqu'au jour où tu l'as violée.

Documente chaque décision de nettoyage. Pourquoi ce champ est remplacé par cette valeur. Sur quelle base cette règle a été définie. Par qui elle a été validée. Dans six mois, personne ne saura plus – y compris toi.

Ne décide jamais seul des ambiguïtés fonctionnelles. Une valeur manquante signifie-t-elle zéro ou inconnu ? Un montant négatif est-il une erreur ou un avoir ? Un client avec deux adresses est-il un doublon ou deux entités distinctes ? Ces décisions appartiennent au métier, pas à l'analyste.

Logue les transformations. Combien de lignes sont entrées, combien sont sorties, combien ont été modifiées, combien ont été rejetées. Ces chiffres sont ta traçabilité et ton outil de diagnostic.

Valide le résultat contre une vérité connue. Si le chiffre d'affaires calculé après nettoyage diffère du chiffre comptable, la vérité est dans la comptabilité.

— L'ORDRE DU NETTOYAGE —

Le nettoyage suit toujours le même ordre logique.

D'abord le structurel – vérifier que le fichier peut être lu, que les colonnes attendues existent, que les types de base sont corrects. Sans cette étape, toutes les suivantes produisent des résultats incohérents.

Ensuite le qualitatif – identifier et traiter les valeurs manquantes, les doublons, les outliers, les incohérences. C'est l'étape la plus longue et la plus importante.

Enfin le sémantique – normaliser les valeurs selon le référentiel métier, enrichir, calculer les dérivées. Cette étape ne peut se faire qu'une fois les données propres et cohérentes.

Changer cet ordre crée des problèmes. Dédupliquer avant d'avoir normalisé les identifiants rate les doublons orthographiques. Traiter les outliers avant d'avoir converti les types produit des résultats aberrants. L'ordre est une règle, pas une suggestion.

CHAPITRE II – AUDIT INITIAL

— COMPRENDRE AVANT D'AGIR —

Avant de modifier une seule valeur, passe du temps à comprendre ce que tu as. Un audit initial mal fait mène à des décisions de nettoyage inadaptées qui créent de nouveaux problèmes.

Commence par les dimensions. Combien de lignes, combien de colonnes. La taille du dataset dit déjà beaucoup – un dataset trop petit pour la question posée est un problème que le nettoyage ne résoudra pas.

Examine les types réels de chaque colonne, pas les types déclarés. Une colonne nommée "montant" stockée en texte est un signe que des problèmes de format se cachent dedans. Une colonne nommée "date" en format numérique entier est un signe qu'un export a mal été configuré.

Identifie la granularité. Une ligne représente quoi exactement ? Une commande, une ligne de commande, un client, une transaction ? Toute l'analyse qui suit dépend de cette réponse. Une granularité mal comprise produit des agrégats faux.

— CE QU'IL FAUT MESURER —

Le taux de valeurs manquantes par colonne. Une colonne à plus de 50% de valeurs manquantes est généralement inutilisable sans décision explicite sur son traitement. Une colonne à 100% de valeurs manquantes est à supprimer.

Le nombre de doublons exacts et fonctionnels. Les doublons exacts sont faciles à détecter. Les doublons fonctionnels – même entité, données légèrement différentes – nécessitent une compréhension métier.

La cardinalité de chaque colonne. Une colonne avec une seule valeur unique dans tout le dataset ne porte aucune information – supprime-la. Une colonne avec autant de valeurs uniques que de lignes est une clé candidate.

La distribution des valeurs numériques. Minimum, maximum, moyenne, médiane, écart-type, percentiles extrêmes. Ces chiffres révèlent immédiatement les ordres de grandeur aberrants et les asymétries qui signalent des problèmes de qualité.

Les valeurs les plus fréquentes dans chaque colonne catégorielle. Souvent révélateur de variantes orthographiques, de valeurs par défaut parasites, ou de catégories mal définies.

CHAPITRE III – NETTOYAGE STRUCTUREL

— COLONNES ET LIGNES —

Supprime les colonnes entièrement vides avant tout travail. Elles consomment de la mémoire, confondent l'analyse, et n'apportent rien.

Supprime les lignes entièrement vides. Elles arrivent souvent dans les exports Excel quand des lignes de formatage vides ont été incluses.

Pour les colonnes partiellement vides, la décision dépend du seuil de vide et de l'importance de la colonne. Une colonne à 90% vide qui porte une information critique

mérite un traitement différent d'une colonne à 30% vide qui est accessoire.

Attention aux colonnes qui semblent vides mais contiennent des espaces, des tirets, des "N/A" textuels. Ces pseudo-nulls sont souvent plus traîtres que les vrais nulls parce qu'ils passent inaperçus dans un premier passage.

— NOMS DE COLONNES —

Des noms de colonnes cohérents réduisent les erreurs de code et améliorent la lisibilité de toute l'analyse. Standardise-les dès le départ selon une convention et tiens-t'y.

Supprime les espaces dans les noms de colonnes. Remplace-les par des underscores. Un espace dans un nom de colonne crée des problèmes dans SQL, dans Python, et dans toutes les jointures.

Uniformise la casse. Tout en minuscules est la convention la plus sûre. Elle évite les erreurs dues aux majuscules inconsistantes dans les jointures et les filtres.

Supprime les accents des noms de colonnes. Ils créent des problèmes d'encodage selon les environnements.

Renomme les colonnes ambiguës. Une colonne nommée "valeur" ou "données" ne dit rien. Une colonne nommée "ca_ht_eur" ou "date_commande" dit tout.

— ENCODAGE ET FORMAT D'IMPORT —

L'encodage est le premier problème rencontré avec les fichiers plats. UTF-8 est le standard moderne. Latin-1 et Windows-1252 persistent dans les vieux systèmes français. Un mauvais encodage produit des caractères corrompus qui contaminent toutes les analyses textuelles.

Détecte l'encodage avant d'importer, pas après. Les caractères corrompus dans les données sont presque impossibles à corriger proprement après le fait.

Le séparateur des CSV n'est pas toujours une virgule. En France, l'export Excel par défaut utilise le point-virgule parce que la virgule est le séparateur décimal. Vérifie toujours le séparateur réel sur les premières lignes avant de charger.

Les fichiers Excel ont souvent des lignes parasites en début de fichier – titre, date de génération, ligne vide de séparation. Ces lignes décalent tout l'import si elles ne sont pas gérées explicitement.

CHAPITRE IV – LES VALEURS MANQUANTES

— CE QUE SIGNIFIE "MANQUANT" —

Une valeur manquante peut signifier trois choses très différentes. L'information est inconnue – on ne l'a pas collectée. L'information n'est pas applicable – la question ne se pose pas pour cette ligne. L'information est zéro – l'absence est une valeur en soi.

Ces trois cas ne se traitent jamais de la même façon. Remplacer "inconnu" par zéro est une erreur analytique grave. Elle transforme une absence d'information en information fausse. Valide toujours la sémantique du manquant avec le métier avant de décider.

Les pseudo-nulls sont plus dangereux que les vrais nulls. Des valeurs comme "N/A", "null", "INCONNU", "-", "0" utilisées pour représenter une absence doivent être identifiées et standardisées en vraies valeurs manquantes avant tout traitement.

— LES STRATÉGIES DE TRAITEMENT

Supprimer les lignes est la stratégie la plus simple. Elle est adaptée quand la colonne est critique (sans elle, la ligne est inutilisable), quand le taux de manquants est faible, et quand les lignes manquantes ne sont pas systématiquement différentes des autres. Si elles le sont, la suppression introduit un biais.

Remplacer par une valeur fixe fonctionne quand la sémantique est claire. Zéro pour un montant non renseigné quand l'absence signifie réellement zéro. "INCONNU" pour une catégorie non renseignée quand on veut suivre ce sous-groupe.

Remplacer par la médiane est plus robuste que la moyenne pour les distributions asymétriques. C'est le choix par défaut pour les colonnes numériques quand l'absence est réellement aléatoire.

Remplacer par le mode (valeur la plus fréquente) est adapté pour les catégorielles quand l'absence est supposée aléatoire et qu'une valeur domine clairement.

L'imputation par groupe est plus précise. Remplacer les valeurs manquantes par la médiane du groupe auquel appartient la ligne – par région, par segment, par catégorie – produit des imputations plus cohérentes que des imputations globales.

La propagation avant ou arrière est adaptée aux séries temporelles. Une valeur manquante entre deux valeurs connues est souvent mieux imputée par la dernière valeur connue que par la médiane globale.

Créer un indicateur binaire avant l'imputation. Une colonne "montant_imputed" qui vaut vrai pour les lignes où le montant a été imputé permet aux analyses suivantes de distinguer les vraies valeurs des valeurs calculées. Cet indicateur est souvent aussi informatif que la valeur elle-même.

— CE QU'ON NE FAIT JAMAIS

On ne remplace jamais une valeur manquante sans comprendre pourquoi elle manque. Le mécanisme du manque – aléatoire, systématique, ou structurel – détermine la bonne stratégie.

On ne supprime pas des lignes avec des valeurs manquantes sur une colonne non critique. Les données partielles contiennent de l'information. Les supprimer entièrement pour éviter de traiter la colonne manquante est une perte.

On ne présente jamais des résultats calculés sur des données imputées sans mentionner que des imputations ont été faites et sur quelle proportion des données.

CHAPITRE V – LES TYPES ET CONVERSIONS

— LES DATES

Les dates sont le cas le plus complexe du nettoyage. Elles arrivent dans des dizaines de formats différents, parfois

mélangés dans la même colonne. Elles sont sensibles aux paramètres régionaux – le 01/02/2024 est le 1er février en France et le 2 janvier aux États-Unis.

Identifie tous les formats présents dans la colonne avant de parser. Tenter un parsing aveugle sur une colonne avec des formats mixtes produit silencieusement des dates incorrectes – ce qui est pire que des erreurs visibles.

Le fuseau horaire est une source d'erreur invisible. Des données collectées en UTC dans un système et affichées en heure locale dans un export peuvent créer des décalages de quelques heures qui faussent toutes les analyses temporelles. Détermine le fuseau horaire de chaque source et normalise vers un fuseau de référence unique dès l'import.

Les dates invalides – 30 février, 31 novembre – arrivent dans les exports de systèmes anciens qui ne valident pas la saisie. Elles doivent être converties en valeurs manquantes et documentées, jamais ignorées.

Extrait toujours les composantes utiles après conversion : année, mois, trimestre, semaine, jour de la semaine, heure. Ces dérivées sont la base de toute analyse temporelle et valent le temps qu'elles prennent à générer.

— LES NUMÉRIQUES

Les chiffres stockés en texte arrivent avec des symboles monétaires, des espaces de séparation des milliers, des virgules utilisées comme séparateur décimal. Chacun de ces cas doit être traité explicitement avant conversion.

Le séparateur décimal est particulièrement piégeux dans les fichiers français où la virgule est le séparateur décimal et le point ou l'espace est le séparateur de milliers. Une valeur "1.234,56" représente mille deux cent trente-quatre virgule cinquante-six – pas un point quelque chose.

Les pourcentages stockés comme texte avec le symbole "%" doivent être divisés par 100 après conversion pour être utilisables dans des calculs.

Après toute conversion numérique, vérifie les plages de valeurs. Un âge de 200 ans ou un montant de -999999 sont des artefacts de conversion qui doivent être traités comme des valeurs manquantes, pas comme des valeurs réelles.

— LES BOOLÉENS

Les valeurs booléennes arrivent sous des dizaines de formes. Oui/Non, True/False, 1/0, Vrai/Faux, O/N, Y/N, Actif/Inactif. Tous ces formats doivent être mappés vers un type cohérent unique avant l'analyse. Une analyse qui mélange des vrais booléens avec des entiers 0/1 produit des résultats incorrects.

Les valeurs qui ne correspondent à aucune forme connue de booléen doivent être traitées comme manquantes, pas comme fausses. L'absence d'un oui n'est pas un non.

— LES IDENTIFIANTS ET CODES

Les codes clients, codes produits, codes postaux, numéros de commande sont souvent normalisés par un système et malmenés par un autre. Un code client "001234" peut devenir "1234" dans un export Excel qui supprime les zéros de tête, rendant toutes les jointures impossibles.

Stocke toujours les identifiants en texte, pas en entier. Convertir un code en entier pour "économiser de la mémoire" est la cause numéro un des pertes de zéros de tête.

Normalise les espaces et la casse dans les identifiants.
"CLIENT 01" et "client01" et "Client 01" peuvent représenter le même client selon les systèmes. Cette normalisation doit se faire avant toute jointure ou déduplication.

CHAPITRE VI – LES DOUBLONS

— TYPES DE DOUBLONS —

Les doublons exacts ont toutes leurs colonnes identiques. Ils arrivent généralement par des exports répétés depuis la même source, des concatenations de fichiers sans contrôle, ou des chargements multiples du même lot. Ils sont simples à détecter et faciles à traiter.

Les doublons fonctionnels représentent la même entité réelle avec des données légèrement différentes. Deux lignes pour le même client avec des adresses différentes. Une commande qui apparaît deux fois avec des statuts différents. Ces doublons sont difficiles à détecter automatiquement et nécessitent une compréhension du métier.

Les doublons temporels sont des enregistrements du même fait à des moments différents. Une mise à jour d'état qui crée une nouvelle ligne plutôt que de modifier l'existante. Le traitement dépend du besoin – conserver l'historique complet ou ne garder que l'état le plus récent.

Les doublons orthographiques existent dans les données textuelles – "Paris", "paris", "PARIS", "paris " sont potentiellement le même. La déduplication orthographique nécessite un fuzzy matching et est la plus coûteuse en temps.

— RÈGLES DE DÉDUPLICATION —

Avant de supprimer un doublon, définis la règle : lequel garder ? Garder le premier enregistrement est simple mais favorise arbitrairement l'ordre d'import. Garder le plus récent est souvent plus pertinent pour les données qui évoluent. Garder le plus complet – celui avec le moins de valeurs manquantes – est la stratégie la plus prudente.

La déduplication sur une clé fonctionnelle partielle est risquée. Si tu dedupliques sur l'identifiant client alors que des clients ont des identifiants dupliqués par erreur, tu supprimes des données légitimes. Vérifie toujours la signification métier de la clé sur laquelle tu dedupliques.

Documente toujours les doublons supprimés dans une table de rejets. Ne les supprime pas en silence. Ils peuvent révéler un problème en amont dans le processus de collecte qui nécessite une correction à la source.

— FUSIONNER LES DOUBLONS —

Dans certains cas, plutôt que de supprimer un doublon, il faut fusionner les informations des deux lignes. Prendre la première valeur non manquante de chaque colonne. Prendre la valeur la plus récente selon une date de modification. Sommer les valeurs numériques si elles représentent des quantités complémentaires.

Cette fusion doit être documentée comme une règle explicite et validée par le métier. Une fusion incorrecte crée des données composites qui ne correspondent à aucune réalité et qui fausseront toutes les analyses suivantes.

— CE QU'EST UN OUTLIER —

Un outlier est une valeur qui s'écarte fortement du reste de la distribution. Il peut être une erreur de saisie, une erreur de codage, une valeur réelle exceptionnelle, ou une fraude. La réponse correcte n'est jamais de supprimer automatiquement. C'est toujours de comprendre.

La méthode IQR identifie les outliers comme les valeurs qui s'écartent de plus de 1.5 fois l'écart interquartile des bornes Q1 et Q3. Elle est robuste parce qu'elle ne dépend pas de la moyenne ni de l'écart-type, qui sont eux-mêmes influencés par les outliers.

La méthode du z-score identifie les valeurs qui s'écartent de plus de 3 écarts-types de la moyenne. Elle est sensible aux distributions asymétriques et peut signaler comme outlier des valeurs qui sont simplement dans la queue longue d'une distribution normale.

La méthode MAD (Median Absolute Deviation) est plus robuste que le z-score sur les distributions asymétriques. Elle utilise la médiane au lieu de la moyenne, ce qui la rend moins sensible aux valeurs extrêmes.

L'isolation forest est une méthode de machine learning qui détecte les anomalies dans des espaces multi-dimensionnels. Elle est utile quand l'outlier ne ressort pas sur une seule dimension mais dans une combinaison de dimensions.

— LES ACTIONS POSSIBLES —

Flaguer est la première action à envisager. Ajouter une colonne indicatrice qui identifie les outliers sans les modifier. Le décideur ou l'expert métier décide ensuite de l'action. Cette approche est la plus sûre.

Plafonner (winsoriser) remplace les valeurs extrêmes par les bornes de la plage acceptable. Une valeur de 1 000 000 dans un dataset de montants où la borne haute est 50 000 devient 50 000. Cette transformation préserve les données et élimine l'influence des extrêmes sur les statistiques.

Remplacer par une valeur manquante est adapté quand l'outlier est clairement une erreur sans valeur réelle à laquelle se substituer. Mieux vaut une valeur manquante qu'une valeur fausse.

Supprimer la ligne n'est justifié que si l'outlier rend la ligne entière inutilisable et si la perte de cette ligne n'introduit pas de biais dans l'analyse.

Transformer la variable – par exemple en logarithme – peut réduire l'influence des outliers dans les analyses statistiques sans supprimer aucune donnée. Cette transformation est utile pour les variables qui ont une distribution log-normale naturelle comme les revenus.

— LES ANOMALIES NE SONT PAS TOUJOURS DES ERREURS —

Les outliers les plus intéressants sont parfois les plus vrais. Le client qui achète dix fois plus que la moyenne n'est pas une erreur – c'est ton meilleur client. La transaction à 0,01€ n'est peut-être pas une erreur de codage – c'est peut-être un test de paiement.

Analyse toujours les outliers avant de les traiter.

Qu'ont-ils en commun ? Viennent-ils d'une même source ? D'une même période ? D'une même catégorie ? Les réponses révèlent souvent des problèmes systémiques ou des opportunités analytiques.

CHAPITRE VIII – COHÉRENCE ET VALIDATION MÉTIER

— LES CONTRAINTES DE COHÉRENCE —

La cohérence concerne les relations entre colonnes plutôt que les valeurs individuelles. Une date de fin antérieure à une date de début. Un montant de remboursement supérieur au montant facturé. Une quantité non entière dans un dataset de produits qui se vendent à l'unité. Un âge calculé qui contredit la date de naissance.

Ces incohérences ne ressortent pas dans l'audit d'une colonne isolée. Elles ne se révèlent qu'en croisant les colonnes entre elles. C'est pourquoi elles sont souvent les plus difficiles à détecter et les plus coûteuses si elles passent inaperçues.

Définis les règles de cohérence avec les experts métier avant de commencer l'analyse. "Date de fin doit être supérieure ou égale à date de début." "Marge doit être inférieure au CA." "Âge doit être positif et inférieur à 120." Ces règles deviennent des tests automatiques à chaque chargement.

— LA NORMALISATION DU RÉFÉRENTIEL —

Un référentiel est un ensemble de valeurs canoniques vers lequel toutes les variantes d'une catégorie doivent converger. "Île-de-France", "IDF", "ile de france", "Paris" peuvent tous représenter la même région. Le référentiel décide que la valeur canonique est "IDF" et que toutes les variantes y sont mappées.

Construis le référentiel avec les experts métier, pas à partir des données. Le référentiel précède les données – il dit ce qui devrait être, pas ce qui est. Ce qu'on trouve dans les données qui ne correspond à aucune valeur canonique est soit une erreur, soit un cas manquant dans le référentiel.

La normalisation de référentiel révèle souvent des problèmes de collecte. Si 30% des valeurs d'une colonne région ne correspondent à aucune région connue, le formulaire de saisie ou l'export a un problème structurel.

Maintiens une table des correspondances pour tracer quelles variantes ont été mappées vers quelle valeur canonique. Cette table est documentaire et diagnostic – elle permet de comprendre la diversité des saisies et de détecter les nouveaux cas à chaque mise à jour.

— INTÉGRITÉ RÉFÉRENTIELLE —

L'intégrité référentielle vérifie que les relations entre tables sont cohérentes. Toutes les lignes de commandes doivent avoir un `client_id` qui existe dans la table clients. Tous les produits des lignes de commande doivent exister dans le catalogue produits.

Les orphelins – enregistrements dont la clé étrangère ne trouve pas de correspondance – signalent soit des suppressions non propagées, soit des chargements dans le mauvais ordre, soit des identifiants inconsistants.

Logue toujours le taux de matching de chaque jointure.
Si 95% des commandes trouvent leur client mais 5% ne le trouvent pas, ces 5% méritent une investigation avant d'être silencieusement ignorés dans une jointure interne.

CHAPITRE IX – PIPELINE ET GOUVERNANCE

— STRUCTURE D'UN PIPELINE DE NETTOYAGE —

Un pipeline de nettoyage est une séquence d'étapes reproductibles qui transforme les données brutes en données propres de façon déterministe. La même entrée doit toujours produire la même sortie. Cette propriété est essentielle pour le débogage et la confiance.

L'étape d'audit produit un rapport de qualité sans modifier les données. Elle sert de baseline pour mesurer l'effet du nettoyage.

L'étape de nettoyage structurel traite le format et la structure. L'étape de conversion traite les types. L'étape de nettoyage qualitatif traite les valeurs. L'étape de validation vérifie le résultat final. Chaque étape est indépendante et testable séparément.

La table de rejets capture toutes les lignes qui ont été supprimées ou qui ont des problèmes non résolus. Elle ne se jette jamais. Elle est la source de réconciliation et d'investigation pour les problèmes en amont.

— DOCUMENTER LE NETTOYAGE —

Chaque règle de nettoyage appliquée doit être documentée avec quatre informations. Le quoi – quelle transformation est appliquée. Le pourquoi – quelle logique métier justifie cette décision. Le qui – quelle personne du métier a validé la règle. Le quand – depuis quelle version du pipeline cette règle s'applique.

La documentation du nettoyage est le dictionnaire de données de l'organisation. Elle dit non seulement ce que les données contiennent, mais comment elles ont été construites et quelles décisions ont été prises sur leur qualité.

Un jeu de données livré sans documentation de nettoyage est un jeu de données dont la confiance ne peut pas être vérifiée. Elle devra être reconstituée – et elle le sera toujours au pire moment, quand une décision importante est remise en question.

— TESTER LE NETTOYAGE —

Construis un jeu de données de test minimal – quelques dizaines de lignes – avec des cas représentatifs de chaque problème de qualité connu. Inclus des cas normaux, des valeurs manquantes, des doublons, des outliers, des incohérences.

Après chaque modification du pipeline, vérifie que les résultats sur ce jeu de test correspondent aux résultats attendus. Une régression dans le nettoyage sur un jeu de test de 50 lignes est détectable en secondes. La même régression sur 10 millions de lignes de production peut passer inaperçue pendant des semaines.

Vérifie le résultat final contre au moins une valeur connue et vérifiable – un total comptable, un décompte de clients issu d'un système de référence. Ce contrôle

de cohérence final est la dernière ligne de défense avant que les données nettoyées alimentent des décisions.

VÉRITÉS DU TERRAIN

Les données propres n'existent pas. Il n'existe que des niveaux d'imparfection différents. L'objectif n'est pas la perfection – c'est la qualité suffisante pour que les décisions prises sur ces données soient fiables.

80% du temps de nettoyage est dans les 20% de cas les plus tordus. Les valeurs manquantes banales se traitent rapidement. Les doublons fonctionnels ambigus, les formats mixtes non documentés, et les incohérences temporelles prennent des heures.

Une décision de nettoyage non documentée est une décision qui devra être prise à nouveau dans six mois – probablement différemment par une autre personne, créant une incohérence dans les résultats qui sera impossible à expliquer.

Le rejet est souvent la bonne décision. Une ligne qui viole une contrainte métier importante ne doit pas être "nettoyée" au risque d'introduire une fausse donnée. Elle doit être rejetée, documentée, et retournée à la source pour correction.

Le meilleur nettoyage est celui qui corrige le problème à la source plutôt que dans le pipeline. Si une colonne arrive systématiquement mal formée, le vrai correctif est de fixer le système de collecte, pas d'ajouter une règle de nettoyage de plus.

Un analyste qui présente des résultats sans mentionner la qualité des données sur lesquelles ils sont basés prend un risque pour lui-même et pour le décideur. La transparence sur les limites des données est une marque de professionnalisme, pas de faiblesse.
