

« La donnée ne se donne pas. Elle se récolte.  
Et comme toute récolte, elle demande de savoir  
ce qu'on cherche, de préparer le terrain,  
d'arriver au bon moment, et de ne jamais  
gâcher ce qu'on a trouvé. »

---

## CHAPITRE I – L'ÉTAT D'ESPRIT DU RÉCOLTEUR

---

### — RÉCOLTER N'EST PAS STOCKER —

La confusion la plus commune entre les débutants est de confondre la récolte de données avec l'accumulation de données. On collecte tout ce qui existe, on remplit des disques durs, on crée des lacs de données – et à la fin, on nage dans des gigaoctets qui ne répondent à aucune question précise.

Une récolte bien menée commence par une question. Quelle décision cette donnée doit-elle éclairer ? Quelle hypothèse veut-on tester ? Quel comportement cherche-t-on à comprendre ? La question précède toujours la collecte. Les données récoltées sans question sont du bruit habillé en information.

Le principe de minimisation est ton premier allié. Collecte le minimum nécessaire pour répondre à la question. Pas plus. Les données superflues ne coûtent pas rien – elles coûtent du temps de traitement, de la complexité d'interprétation, et parfois des obligations réglementaires supplémentaires.

Le principe de la source primaire est ton second allié. Toujours préférer la donnée à sa source d'origine plutôt qu'une agrégation ou un rapport qui en est dérivé. La source primaire contient la granularité et le contexte que les dérivés perdent toujours.

### — CARTOGRAPHIER AVANT DE COLLECTER —

Avant de toucher à un fichier ou une API, cartographie les sources disponibles. Quelles données existent dans l'organisation ? Qui les produit ? Qui les possède ? Sous quel format ? À quelle fréquence sont-elles mises à jour ? Quelle est leur qualité déclarée ou estimée ?

Cette cartographie est rarement faite et toujours révélatrice. Elle révèle les doublons – la même donnée stockée à trois endroits différents avec trois définitions légèrement différentes. Elle révèle les orphelins – des fichiers riches que personne ne consulte depuis deux ans. Elle révèle les lacunes – les données qui n'existent pas et qu'il faudra créer ou acheter.

Note aussi ce qui n'existe pas dans les données mais qui devrait. Une organisation qui mesure ses ventes mais pas ses retours. Une boulangerie qui enregistre chaque vente mais jamais les invendus. Un hôpital qui collecte les diagnostics mais pas les durées d'attente. Ces absences sont des besoins futurs et parfois des opportunités de valeur immédiate.

### — RESPECTER LA DONNÉE QU'ON RÉCOLTE —

Chaque donnée a une provenance – elle a été créée par quelqu'un, dans un contexte, pour une finalité. La comprendre avant de l'utiliser est une obligation intellectuelle autant qu'éthique.

Une note de satisfaction client dans un questionnaire rempli juste après un incident difficile ne dit pas la même chose que la même note remplie lors d'une interaction positive. Les deux se ressemblent dans la base de données mais leur signification est différente.

Un chiffre de ventes incluant les retours n'est pas le même qu'un chiffre net. Une donnée de stock calculée en quantités n'est pas la même que celle calculée en valeur. Ces distinctions sont invisibles dans les données brutes mais fondamentales pour les décisions.

Respecter la donnée, c'est refuser de l'utiliser hors de son contexte de production. C'est documenter ce contexte dans chaque livrable. C'est nommer les limites plutôt que de les ignorer.

---

## CHAPITRE II – LES SOURCES ET COMMENT Y ACCÉDER

---

### — LES DONNÉES INTERNES —

---

Les données internes sont les données produites et possédées par l'organisation. Elles sont généralement les plus pertinentes, les plus accessibles légalement, et les mieux connues dans leur contexte. Ce sont aussi celles qu'on exploite le moins parce qu'on les connaît trop bien pour les regarder avec un regard neuf.

Les systèmes de gestion – ERP, CRM, logiciels métier – sont les premières sources. Leur accès passe généralement par une requête SQL, un export CSV, ou une API interne. Leur richesse est souvent sous-estimée par les utilisateurs quotidiens qui n'en voient qu'une fraction.

Les fichiers Excel et les bases de données artisanales sont les sources les plus révélatrices. Le fichier Excel que quelqu'un tient manuellement depuis trois ans pour compenser une lacune du logiciel officiel contient souvent plus d'information sur les vraies pratiques de l'organisation que les données officielles.

Les emails, les comptes-rendus de réunion, et les notes internes sont des sources de données qualitatives souvent ignorées. Elles contiennent les raisonnements qui ont conduit aux décisions visibles dans les données quantitatives.

Les capteurs et objets connectés – machines de production, véhicules GPS, terminaux de paiement, compteurs d'entrée – génèrent des données continues qui sont parfois collectées mais rarement analysées systématiquement.

L'accès aux données internes nécessite une autorisation explicite du décideur compétent. Ne jamais accéder à des données sans mandat clair, même si l'accès technique est possible. Le droit d'accéder n'implique pas le droit d'analyser.

### — LES DONNÉES EXTERNES —

---

Les données externes enrichissent les données internes avec un contexte que l'organisation ne peut pas produire elle-même. Elles sont variées, souvent gratuites dans leurs versions agrégées, et parfois très puissantes

pour expliquer des phénomènes que les données internes décrivent sans expliquer.

Les données publiques et open data sont une mine souvent sous-exploitée. L'INSEE produit des données démographiques, économiques, et sociales à des granularités très fines. Data.gouv.fr centralise les données ouvertes de l'administration française. Eurostat couvre l'Europe. Les collectivités territoriales publient leurs données de plus en plus systématiquement.

Les données météorologiques de Météo-France sont disponibles en open data à des granularités spatiales et temporelles très fines. Pour la boulangerie, l'hôtel, le bar, ou l'agriculture – la météo est une variable prédictive de premier ordre que peu d'organisations intègrent dans leurs analyses.

Les données économiques sectorielles – indices de prix à la production, cours des matières premières, données d'importations et exportations – sont publiées par Banque de France, INSEE, et les fédérations sectorielles. Elles constituent le contexte économique dans lequel les décisions d'une organisation s'inscrivent.

Les données de marché – parts de marché, panels consommateurs, études sectorielles – sont souvent coûteuses dans leurs versions complètes mais leurs résumés publics et leurs méthodologies sont accessibles.

Les données géographiques – OpenStreetMap, IGN, données cadastrales – permettent d'enrichir tout problème qui a une dimension spatiale avec une précision remarquable et souvent gratuitement.

Les données de réseaux sociaux et d'avis en ligne – Google Business, TripAdvisor, LinkedIn, Twitter/X – sont des données comportementales et d'opinion en temps réel sur des sujets précis. Leur accès via les APIs officielles est réglementé et souvent payant au-delà d'un certain volume.

---

#### — LES DONNÉES ACHETÉES —

Les données achetées complètent ce que les sources gratuites ne couvrent pas. Bases de données d'entreprises (Kompass, Infogreffe, Bodacc), panels consommateurs (Nielsen, Kantar), données de trafic (TomTom, HERE), données financières (Bloomberg, Refinitiv).

Avant d'acheter des données, valide trois points. Elles répondent précisément à la question posée – pas approximativement. Leur coût est inférieur à la valeur de la décision qu'elles vont éclairer. Leur utilisation est légalement autorisée pour l'usage prévu.

Négocie toujours les conditions d'utilisation avant l'achat. La plupart des contrats de données externes contiennent des restrictions sur la revente, la redistribution, et l'utilisation dans des produits dérivés. Les violer expose à des risques juridiques sérieux.

---

### CHAPITRE III – LES MÉTHODES DE COLLECTE

---

---

#### — LA COLLECTE PAR EXTRACTION DIRECTE —

L'extraction directe depuis les systèmes sources est la méthode la plus fiable parce qu'elle va chercher

la donnée là où elle vit, sans intermédiaire. Elle nécessite un accès technique – connexion SQL, export paramétré, accès administrateur – et une connaissance du modèle de données source.

La règle d'or de l'extraction directe est la non-destructivité. Utilise uniquement des accès en lecture. Ne modifie jamais les données sources pendant l'extraction. Ne teste jamais tes requêtes sur la base de production avec des volumes importants sans avoir évalué l'impact sur les performances du système.

L'extraction par requête SQL est la méthode la plus précise. Elle permet de spécifier exactement ce dont on a besoin – les tables, les colonnes, les filtres, les jointures – et de ne transférer que ces données. Paramétrise toujours les requêtes pour éviter les injections et pour pouvoir les rejouer avec des dates différentes.

L'extraction par export natif du logiciel est moins précise mais plus accessible. La plupart des logiciels permettent un export CSV ou Excel de leurs données. L'inconvénient est que le format et le contenu de l'export sont définis par le logiciel, pas par tes besoins. Travaille avec ce que le logiciel produit en documentant précisément son format.

L'extraction par copie de fichiers – fichiers de logs, fichiers de sauvegarde, dumps de bases de données – est la méthode de dernier recours quand aucun autre accès n'est disponible. Elle nécessite souvent des traitements de parsing importants.

---

## — LA COLLECTE PAR API —

Les APIs (Application Programming Interfaces) sont les interfaces standardisées que les systèmes exposent pour permettre l'échange de données entre applications. Elles sont devenues la méthode de référence pour accéder aux données de plateformes numériques.

Avant d'utiliser une API, lis attentivement la documentation. Les endpoints disponibles, les formats de réponse, les paramètres acceptés, les limites de débit (rate limits), et les règles d'utilisation sont tous dans la documentation. Une API mal comprise produit des données incorrectes ou une facturation inattendue.

Les rate limits sont les limites du nombre de requêtes autorisées par unité de temps. Ne jamais les ignorer. Une stratégie d'appel qui dépasse les rate limits se fait bloquer – parfois définitivement. Implémente toujours une pause entre les requêtes et un mécanisme de retry avec backoff exponentiel.

La pagination est la gestion des résultats en plusieurs pages quand le volume dépasse la taille maximale d'une réponse. C'est le piège le plus fréquent des développeurs débutants avec les APIs – ils croient avoir tout collecté alors qu'ils n'ont récupéré que la première page. Vérifie toujours si la réponse contient un indicateur de suite (next\_page, has\_more, cursor) et continue jusqu'à ce qu'il n'y en ait plus.

L'authentification est obligatoire sur presque toutes les APIs modernes. Tokens Bearer, OAuth 2.0, clés API – chaque plateforme a son mécanisme. Ces credentials ne doivent jamais être dans le code – toujours dans des variables d'environnement.

La gestion des changements d'API est une réalité opérationnelle. Les plateformes modifient leurs APIs, déprécient des endpoints, changent des formats. Un

pipeline de collecte qui fonctionne aujourd'hui peut casser demain. Implémente des validations sur le format de réponse reçu pour détecter immédiatement un changement.

---

## — LE WEB SCRAPING

Le web scraping est l'extraction automatisée de données depuis des pages web conçues pour être lues par des humains. C'est une technique puissante mais qui s'accompagne de considérations légales, éthiques, et techniques importantes.

Avant de scraper, cherche toujours si une API officielle ou un export de données existe. La plupart des sites qui ont des données structurées ont une API – parfois non documentée publiquement mais accessible. Utiliser l'API officielle est toujours préférable au scraping parce que c'est plus stable, plus rapide, et légalement plus sûr.

Le fichier robots.txt d'un site web indique les pages que le propriétaire autorise ou interdit aux robots. Le respecter est une obligation légale dans certaines juridictions et une pratique éthique dans toutes. Un scraping qui ignore robots.txt sur des données clairement sensibles expose à des risques judiciaires.

La fréquence des requêtes dans un scraping doit être raisonnable. Bombarder un site de requêtes à la vitesse maximale possible constitue une attaque par déni de service involontaire. Ajoute toujours un délai aléatoire entre les requêtes – entre 1 et 5 secondes selon le volume – pour ne pas saturer le serveur cible.

Les sites modernes chargent souvent leur contenu via JavaScript après le chargement initial de la page. Le HTML brut ne contient pas les données. Il faut utiliser un navigateur headless (Playwright, Selenium, Playwright) qui exécute le JavaScript avant d'extraire les données. Cette étape est plus lente et plus fragile que le scraping HTML classique.

La fragilité est la caractéristique principale du scraping. Le moindre changement dans la structure de la page cible casse le script. Plan pour la maintenance – un scraper doit être surveillé et mis à jour régulièrement.

---

## — L'ENQUÊTE ET LA COLLECTE PRIMAIRE

Parfois les données n'existent nulle part et doivent être créées. La collecte primaire – questionnaires, entretiens, observations directes, expériences contrôlées – est la méthode pour créer des données sur des phénomènes non encore mesurés.

La conception d'un questionnaire est un art à part entière. Chaque question doit être univoque – une seule interprétation possible. Les questions orientées produisent des réponses orientées. L'ordre des questions influence les réponses sur les sujets sensibles. La longueur du questionnaire influence le taux de réponse et la qualité des réponses en fin de formulaire.

Le biais de désirabilité sociale est la tendance des répondants à donner la réponse qu'ils croient attendue plutôt que la réponse vraie. Il est particulièrement fort sur les questions de comportements (consommation, pratiques, opinions). Les méthodes de détection passent par des questions de contrôle et la comparaison avec des données comportementales observées.

Le taux de réponse à une enquête dépend de la crédibilité de l'émetteur, de la pertinence perçue pour le répondant,

de la longueur du questionnaire, et des conditions de relance. Un taux de réponse inférieur à 30% introduit un biais de sélection significatif – les répondants ne sont plus représentatifs de la population cible.

L'observation directe produit des données comportementales plus fiables que les données déclaratives. Analyser comment les clients utilisent réellement un espace de vente, comment les équipes appliquent réellement un processus, comment les patients naviguent réellement dans un parcours de soins – cette méthode révèle des comportements que personne n'aurait décrits dans un questionnaire.

---

## CHAPITRE IV – LA QUALITÉ À LA SOURCE

---

### — ÉVALUER LA QUALITÉ AVANT DE COLLECTER —

La qualité d'une source de données ne se découvre pas après la collecte – elle s'évalue avant. Investir du temps dans cette évaluation préalable économise des heures de débogage et évite des décisions basées sur des données inadaptées.

Les cinq dimensions de la qualité à évaluer sur toute source. La complétude – quelle proportion des données attendues est réellement présente ? La précision – les valeurs enregistrées correspondent-elles à la réalité qu'elles prétendent mesurer ? La cohérence – les données de cette source sont-elles cohérentes avec d'autres sources qui mesurent le même phénomène ? L'actualité – les données sont-elles suffisamment récentes pour la décision qu'elles doivent éclairer ? La granularité – le niveau de détail disponible est-il suffisant pour l'analyse prévue ?

La meilleure façon d'évaluer une source est de la tester sur un petit échantillon avant de lancer la collecte complète. Extraire 100 lignes, les analyser manuellement, les comparer à des valeurs de référence connues – cette étape révèle presque toujours des surprises sur la qualité réelle.

Les métadonnées – informations sur les données – sont aussi importantes que les données elles-mêmes. Quand ont-elles été collectées ? Par quel système ? Avec quel degré d'automatisation versus saisie humaine ? Ont-elles été modifiées depuis leur création ? Ces informations conditionnent l'interprétation de tout ce qui suivra.

### — LES BIAIS DE COLLECTE À CONNAÎTRE —

Le biais de survivance est l'un des plus fréquents et des moins détectés. Les données disponibles ne représentent que les cas qui ont survécu jusqu'au moment de la collecte. Les clients qui ont churné ne figurent plus dans la base active. Les projets abandonnés ne figurent plus dans les reportings. Les produits retirés du marché n'apparaissent plus dans les catalogues. Chaque absence peut biaiser une analyse qui ne la prend pas en compte.

Le biais de mesure apparaît quand l'instrument de mesure influence ce qu'il mesure. Un questionnaire de satisfaction envoyé immédiatement après un moment positif capte autre chose qu'un questionnaire envoyé à froid. Un sondage en ligne capte d'autres profils que le même sondage par courrier postal.

Le biais de confirmation dans la collecte pousse à chercher les données qui confirment une hypothèse préexistante et à négliger celles qui l'infirmement. C'est souvent inconscient. La façon de le combattre est de se forcer à chercher activement les données qui contredisent son hypothèse.

Le biais temporel apparaît quand la période de collecte est atypique. Des données collectées pendant la pandémie de 2020-2021, pendant une grève, ou pendant une période promotionnelle exceptionnelle ne représentent pas le comportement normal. Toujours qualifier la période de collecte et ses éventuelles particularités.

Le biais de sélection apparaît quand les données collectées ne représentent pas la population cible. Un sondage de satisfaction envoyé uniquement aux clients qui ont interagi récemment avec le service client ne représente pas l'ensemble des clients – il surreprésente ceux qui ont eu un problème.

---

## — PRÉSERVER LA PROVENANCE —

La provenance d'une donnée – d'où elle vient, comment elle a été collectée, par qui, quand, et dans quel contexte – est une métadonnée aussi précieuse que la donnée elle-même. La perdre crée des données dont on ne peut plus évaluer la fiabilité.

Documente systématiquement la provenance de chaque jeu de données collecté. Nom et version de la source. Date et heure de la collecte. Paramètres de la requête ou de l'export. Personne qui a autorisé l'accès. Restrictions d'utilisation connues. Cette documentation est la clé de la reproductibilité et de l'auditabilité.

Stocke les données brutes séparément des données transformées – dans un dossier data/raw immuable. Une fois stockées, les données brutes ne se modifient jamais. Toute transformation crée une nouvelle version dans un autre dossier. Cette discipline permet de revenir à la source à n'importe quelle étape.

L'horodatage de toute collecte est obligatoire. Une donnée sans date de collecte est une donnée sans contexte temporel. Sur des sujets qui évoluent – prix de marché, indicateurs de santé, comportements clients – l'absence de date de collecte rend la donnée inutilisable en comparaison avec des données plus récentes.

---

## CHAPITRE V – RÉCOLTE CONTINUE ET AUTOMATISATION

---

---

### — CONCEVOIR POUR LA RÉPÉTABILITÉ —

Une collecte ponctuelle répond à une question d'hier. Une collecte continue répond aux questions de demain. La différence entre les deux est une architecture pensée pour la répétabilité.

Chaque collecte doit être conçue comme si elle allait tourner dix mille fois. Le code doit être robuste aux changements de format, aux sources indisponibles, aux volumes anormaux, et aux erreurs réseau. Ce qui casse silencieusement est plus dangereux que ce qui casse bruyamment.

L'idempotence est la propriété selon laquelle exécuter la collecte deux fois de suite produit le même résultat qu'une seule fois. Elle est essentielle pour les collectes automatisées – si le script redémarre après

une erreur, il ne doit pas dupliquer les données déjà collectées.

La collecte incrémentale – ne collecter que ce qui est nouveau depuis la dernière collecte – est indispensable pour les sources qui évoluent en continu. Elle nécessite un mécanisme de watermark – une marque de la dernière position atteinte – stocké de façon persistante et mis à jour seulement en cas de succès complet.

---

## — MONITORER LA COLLECTE —

Une collecte automatisée sans monitoring est une collecte dont on ne sait pas si elle fonctionne. Le jour où quelqu'un s'aperçoit que les données n'ont pas été mises à jour depuis trois semaines, il est trop tard pour récupérer les données manquantes.

Les métriques à surveiller sur chaque collecte automatisée. Le volume collecté comparé au volume habituel – une baisse de 50% est un signal d'alerte. La durée d'exécution comparée à la normale – une durée deux fois supérieure signale un problème de performance ou de volume. Le taux d'erreurs dans la collecte – des erreurs récurrentes sur les mêmes entités signalent un changement dans la source. La fraîcheur des données – depuis combien de temps les données n'ont-elles pas été mises à jour.

Les alertes doivent aller quelque part. Email, Slack, SMS selon l'urgence. Une alerte qui n'est vue par personne ne sert à rien. Un tableau de bord de la santé des collectes visible par l'équipe est un investissement minimal pour une fiabilité maximale.

---

## — GOUVERNER L'ACCÈS AUX DONNÉES RÉCOLTÉES —

Les données récoltées ont une valeur. Leur accès doit être gouverné. Qui peut y accéder ? Pour quel usage ? Jusqu'à quand ? Ces règles ne sont pas de la bureaucratie – elles protègent la confidentialité des personnes dont les données ont été collectées, et elles protègent l'organisation contre une utilisation non autorisée.

Le registre des données est l'inventaire documenté de toutes les sources collectées avec leurs métadonnées – provenance, fréquence de mise à jour, personnes autorisées à y accéder, restrictions d'utilisation. C'est le premier outil de gouvernance des données d'une organisation.

La durée de conservation doit être définie pour chaque jeu de données. Des données conservées indéfiniment sans justification sont à la fois un risque réglementaire (RGPD) et une charge de maintenance croissante. Définir une politique de purge automatique est une bonne pratique dès le départ.

---

## CHAPITRE VI – ÉTHIQUE DE LA RÉCOLTE

---

---

### — CE QU'ON A LE DROIT DE RÉCOLTER —

Le droit de récolter une donnée ne se déduit pas de sa disponibilité technique. Ce que tu peux extraire techniquement n'est pas nécessairement ce que tu as le droit d'extraire légalement et éthiquement.

Les données personnelles – qui permettent d'identifier une personne physique directement ou indirectement –



sont soumises au RGPD en Europe. Leur collecte nécessite une base légale explicite : consentement, exécution d'un contrat, obligation légale, intérêt légitime. Sans base légale, la collecte est illégale.

Les données de santé, les données biométriques, les données sur les opinions politiques ou religieuses sont des catégories spéciales qui nécessitent un consentement explicite ou une dérogation réglementaire. Elles ne se collectent jamais sans un cadre légal très précis.

Les données produites par une organisation lui appartiennent dans le sens où leur utilisation est soumise à ses conditions. Accéder aux données d'un partenaire commercial, d'un fournisseur, ou d'un client va au-delà d'un accès technique – cela nécessite un accord contractuel sur les usages autorisés.

## — RESPECTER LES PERSONNES DANS LES DONNÉES —

Derrière chaque ligne d'un jeu de données se trouve une personne réelle – un patient, un client, un employé, un élève. Cette réalité ne doit jamais être abstraite. Les décisions prises sur des données affectent des vies réelles.

L'anonymisation est la transformation de données personnelles de façon à rendre impossible l'identification des personnes concernées. Elle ne se limite pas à supprimer le nom – elle nécessite de traiter toutes les variables qui, combinées, permettent une ré-identification. Une donnée dite anonyme qui contient l'âge exact, le code postal, et la date d'un événement rare peut permettre d'identifier une personne.

La transparence sur la collecte est un droit des personnes concernées. Elles ont le droit de savoir que leurs données sont collectées, pourquoi, et comment. Dans un contexte professionnel, cette transparence se traduit par des mentions d'information, des politiques de confidentialité, et des procédures de réponse aux droits des personnes.

---

## VÉRITÉS DU TERRAIN

---

La donnée la plus précieuse n'est pas celle qui est la plus volumineuse ni la plus récente. C'est celle qui répond exactement à la question qu'on se pose, avec la qualité suffisante pour décider. Cette donnée est souvent plus petite et plus simple qu'on ne le croit.

La meilleure récolte est celle qu'on n'a pas à faire parce qu'elle tourne automatiquement depuis six mois et qu'on peut lui faire confiance parce qu'elle est monitorée, documentée, et auditée.

Les meilleures données d'une organisation sont souvent dans les têtes de deux ou trois personnes qui ont passé des années à travailler avec elles. Capturer ce savoir tacite sous forme de règles de collecte, de dictionnaires de données, et de procédures documentées est une mission à part entière.

Un analyste qui sait trouver les données que personne d'autre ne sait trouver, qui en comprend la provenance et les limites, et qui les relie aux questions qui comptent – cet analyste est indispensable. Sa valeur n'est pas dans les outils qu'il utilise pour collecter. Elle est dans son jugement sur ce qui vaut la peine

d'être collecté.

La récolte la plus dangereuse est celle qu'on fait parce qu'on peut, pas parce qu'on en a besoin. Les données accumulées sans question précise sont rarement analysées, souvent mal sécurisées, et parfois source de problèmes réglementaires. Récolte avec intention. Toujours.

---