

Auteur : GCI – Département Formation & Intelligence Analytique
Version : 1.0 – Édition Complète
Format : Bible Professionnelle
Langue : Français

=====

TABLE DES MATIÈRES

PARTIE I – COMPRENDRE LA SCIENCE DES DONNÉES
PARTIE II – ANALYSER : MÉTHODES ET OUTILS
PARTIE III – UTILISER : APPLICATIONS CONCRÈTES
PARTIE IV – DÉCIDER : LA DONNÉE AU SERVICE DE L'ACTION
PARTIE V – DATA SCIENCE DANS LA SCIENCE
PARTIE VI – DATA SCIENCE DANS L'ARMÉE
PARTIE VII – DATA SCIENCE DANS L'INDUSTRIE
PARTIE VIII – DEVENIR UN DATA SCIENTIST INDISPENSABLE
PARTIE IX – GESTION, STOCKAGE ET TRAITEMENT DES DONNÉES
PARTIE X – MACHINE LEARNING : FONDEMENTS ET PRATIQUE
PARTIE XI – DEEP LEARNING : RÉSEAUX DE NEURONES ET IA
PARTIE XII – ANALOGIE PALANTIR : LA DONNÉE COMME ARME
PARTIE XIII – DEVENIR UN SAAS DATA OU CRÉER SON ENTREPRISE

=====

PARTIE I – COMPRENDRE LA SCIENCE DES DONNÉES

=====

1.1 QU'EST-CE QUE LA DATA SCIENCE ?

La science des données est une discipline transversale qui combine :

- Les mathématiques et la statistique
- L'informatique et la programmation
- La connaissance métier (domain expertise)

Son objectif central : extraire de la valeur de la donnée brute pour informer, prédire, automatiser et décider.

La donnée en elle-même n'a aucune valeur. C'est la compréhension que l'on en tire qui crée de la valeur. Un data scientist ne manipule pas des chiffres – il traduit des réalités complexes en langage actionnable.

DÉFINITION OPÉRATIONNELLE :

"La data science est le processus structuré par lequel des données brutes, hétérogènes et volumineuses sont transformées en connaissances fiables servant à prendre des décisions à fort impact."

1.2 LE PROFIL DU DATA SCIENTIST

Le data scientist n'est pas uniquement un programmeur. Il possède trois dimensions indissociables :

- [A] DIMENSION TECHNIQUE
 - Python / R / SQL
 - Statistiques descriptives et inférentielles
 - Machine Learning et modélisation
 - Big Data et infrastructure
- [B] DIMENSION ANALYTIQUE
 - Formulation correcte des problèmes
 - Hypothèses, biais, validation
 - Interprétation rigoureuse des résultats
 - Pensée critique face à la donnée
- [C] DIMENSION MÉTIER
 - Compréhension du secteur d'activité

- Langage commun avec les décideurs
- Capacité à prioriser selon l'impact réel
- Communication des résultats à des non-techniciens

PIÈGE CLASSIQUE DU JUNIOR :

Il se concentre sur [A] et néglige [B] et [C]. Un modèle à 99% de précision qui répond à la mauvaise question est inutile. Le senior construit d'abord la bonne question.

1.3 LE CYCLE DE VIE D'UN PROJET DATA

Tout projet data suit un cycle structuré. L'ignorer est la première cause d'échec des projets analytiques.

ÉTAPE 1 – DÉFINITION DU PROBLÈME

- Qu'est-ce qu'on cherche vraiment à résoudre ?
- Quel est le coût de l'incertitude actuelle ?
- Quelle décision sera prise grâce à cette analyse ?

ÉTAPE 2 – COLLECTE DES DONNÉES

- Quelles sources sont disponibles ?
- Quelle est la qualité, la fraîcheur, la complétude ?
- Existe-t-il des biais dans la collecte ?

ÉTAPE 3 – NETTOYAGE ET PRÉPARATION

- Valeurs manquantes, doublons, anomalies
- Normalisation, encodage, feature engineering
- Construction du dataset final

ÉTAPE 4 – EXPLORATION (EDA)

- Statistiques descriptives
- Visualisations
- Hypothèses initiales

ÉTAPE 5 – MODÉLISATION

- Choix du modèle selon le problème
- Entraînement, validation, test
- Tuning des hyperparamètres

ÉTAPE 6 – ÉVALUATION

- Métriques adaptées au contexte
- Validation croisée
- Tests de robustesse

ÉTAPE 7 – DÉPLOIEMENT

- Intégration dans les systèmes existants
- API, pipeline, monitoring
- Documentation

ÉTAPE 8 – MONITORING ET MAINTENANCE

- Drift des données dans le temps
- Retraînement périodique
- Alertes sur dégradation des performances

1.4 LES TYPES DE DONNÉES

DONNÉES STRUCTURÉES

- Tableaux, bases relationnelles (SQL)
- Exemple : données de vente, fiches clients, logs financiers
- Faciles à traiter, standards bien établis

DONNÉES SEMI-STRUCTURÉES

- JSON, XML, CSV avec hiérarchie
- Exemple : réponses API, fichiers de configuration, logs serveur
- Nécessitent parsing et normalisation

DONNÉES NON STRUCTURÉES

- Textes, images, vidéos, sons
- Représentent 80% des données mondiales
- Requièrent NLP, vision par ordinateur, traitement audio

DONNÉES TEMPORELLES (TIME SERIES)

- Séquences chronologiques avec dépendances temporelles
- Exemple : cours boursiers, capteurs IoT, données météo
- Requièrent des modèles spécifiques (ARIMA, LSTM, Prophet)

DONNÉES GÉOSPATIALES

- Coordonnées GPS, polygones, cartes
- Exemple : trajectoires militaires, flux logistiques, épidémiologie
- Traitement avec GeoPandas, PostGIS, QGIS

1.5 LES GRANDS PARADIGMES ANALYTIQUES

ANALYTIQUE DESCRIPTIVE

- "Que s'est-il passé ?"
- Tableaux de bord, agrégations, KPIs
- Outil : Excel, Power BI, Tableau, SQL

ANALYTIQUE DIAGNOSTIQUE

- "Pourquoi cela s'est-il passé ?"
- Analyse des causes, corrélations, drill-down
- Outil : Python, R, segmentation

ANALYTIQUE PRÉDICTIVE

- "Que va-t-il se passer ?"
- Modèles ML, forecasting, scoring
- Outil : scikit-learn, XGBoost, Prophet

ANALYTIQUE PRESCRIPTIVE

- "Que doit-on faire ?"
- Optimisation, simulation, recommandation
- Outil : OR-Tools, algorithmes génétiques, RL

ANALYTIQUE COGNITIVE (IA avancée)

- "Comprends, apprend, adapte-toi."
- LLMs, systèmes autonomes, raisonnement
- Outil : GPT, Claude, RAG, agents IA

PARTIE II – ANALYSER : MÉTHODES ET OUTILS

2.1 FONDEMENTS STATISTIQUES INDISPENSABLES

Un data scientist sans statistiques solides construit sur du sable.
Voici le socle minimum obligatoire.

STATISTIQUES DESCRIPTIVES

- Moyenne, médiane, mode (tendances centrales)
- Variance, écart-type (dispersion)
- Percentiles, quartiles, IQR
- Asymétrie (skewness), aplatissement (kurtosis)

RÈGLE PRATIQUE :

Toujours regarder la distribution AVANT de calculer une moyenne.
Une moyenne sans distribution est une illusion de précision.

PROBABILITÉS

- Espace probabiliste, événements, loi de probabilité
- Probabilité conditionnelle : $P(A|B) = P(A \cap B) / P(B)$
- Théorème de Bayes : $P(A|B) = P(B|A) \times P(A) / P(B)$
- Distributions importantes :
 - Normale (Gaussienne) – valeurs continues symétriques
 - Binomiale – succès/échecs sur n essais
 - Poisson – événements rares sur intervalle
 - Exponentielle – temps entre événements
 - Bernoulli – expérience binaire unique
 - Beta / Gamma – priors bayésiens

INFÉRENCE STATISTIQUE

- Tests d'hypothèses (H_0 vs H_1)
- p-value : probabilité d'observer les résultats si H_0 est vraie

- Niveau de signification α (généralement 0.05)
- Tests courants :
 - t-test – comparer deux moyennes
 - ANOVA – comparer plusieurs groupes
 - Chi-carré – indépendance entre variables catégorielles
 - Mann-Whitney – alternative non-paramétrique au t-test
 - Kolmogorov-Smirnov – comparer deux distributions

ERREUR CRITIQUE DU JUNIOR :

Confondre corrélation et causalité. Deux variables corrélées n'ont pas nécessairement de lien causal. Un troisième facteur peut expliquer les deux.

INTERVALLES DE CONFIANCE

- Fourchette dans laquelle se trouve le vrai paramètre avec une probabilité donnée
- IC à 95% : le paramètre vrai est dans cet intervalle dans 95% des expériences répétées
- Largeur de l'intervalle = incertitude de l'estimation

CORRÉLATION ET RÉGRESSION

- Corrélation de Pearson : relation linéaire entre deux variables continues
- Corrélation de Spearman : relation monotone, robuste aux outliers
- Régression linéaire simple : $Y = \beta_0 + \beta_1 X + \varepsilon$
- Régression multiple : $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \varepsilon$
- R^2 : proportion de variance expliquée par le modèle

2.2 ANALYSE EXPLORATOIRE DES DONNÉES (EDA)

L'EDA est l'étape la plus sous-estimée et pourtant la plus critique. Elle révèle la structure réelle des données avant toute modélisation.

ÉTAPES D'UNE EDA RIGOUREUSE :

- [1] AUDIT INITIAL
 - `df.shape, df.dtypes, df.info()`
 - Dimensions, types de colonnes, mémoire utilisée
- [2] VALEURS MANQUANTES
 - `df.isnull().sum() / len(df) * 100`
 - Taux de valeurs manquantes par colonne
 - Pattern : MCAR, MAR, MNAR (Missing at Random vs Not at Random)
- [3] STATISTIQUES DESCRIPTIVES
 - `df.describe(include='all')`
 - Min, max, mean, std, quartiles pour toutes les colonnes
- [4] DISTRIBUTION DES VARIABLES
 - Histogrammes pour les variables numériques
 - Diagrammes en barres pour les variables catégorielles
 - Boxplots pour identifier les outliers
- [5] ANALYSE DES OUTLIERS
 - Méthode IQR : outlier si $< Q1 - 1.5 \times IQR$ ou $> Q3 + 1.5 \times IQR$
 - Z-score : outlier si $|z| > 3$
 - Décider : supprimer, imputer, cappers, ou conserver selon contexte
- [6] CORRÉLATIONS
 - Heatmap de corrélation (Pearson ou Spearman)
 - Identifier les variables fortement corrélées entre elles (multicolinéarité = problème pour la régression)
 - Identifier les variables liées à la cible
- [7] ANALYSE BIVARIÉE
 - Variable numérique vs cible numérique : scatter plot + corrélation
 - Variable catégorielle vs cible numérique : boxplot par groupe
 - Variable numérique vs cible binaire : distribution par classe
- [8] ANALYSE TEMPORELLE (si applicable)
 - Tendances, saisonnalités, cycles, points de rupture
 - Autocorrélation (ACF, PACF)

2.3 NETTOYAGE ET PRÉPARATION DES DONNÉES

"Garbage in, garbage out." – Loi fondamentale de la data science.
80% du temps d'un data scientist est consacré au nettoyage des données.
Ce n'est pas une perte de temps – c'est la fondation de tout.

TRAITEMENT DES VALEURS MANQUANTES

STRATÉGIE 1 – SUPPRESSION

- Supprimer les lignes si < 5% de données manquantes
- Supprimer une colonne si > 50-70% de valeurs manquantes
- Risque : perte d'information, biais si données non-MCAR

STRATÉGIE 2 – IMPUTATION SIMPLE

- Numérique : remplacer par la moyenne (symétrique) ou la médiane (skewed)
- Catégoriel : remplacer par le mode ou une catégorie "Inconnu"

STRATÉGIE 3 – IMPUTATION AVANCÉE

- KNN Imputer : utilise les k plus proches voisins
- MICE (Multiple Imputation by Chained Equations)
- Modèle prédictif pour imputer une colonne à partir des autres

ENCODAGE DES VARIABLES CATÉGORIELLES

- Label Encoding : 0, 1, 2, 3... (pour ordinales ou arbres de décision)
- One-Hot Encoding : colonnes binaires (pour régressions, SVM, KNN)
- Target Encoding : remplacer par la moyenne de la cible (attention au leakage)
- Frequency Encoding : remplacer par la fréquence d'apparition

NORMALISATION / STANDARDISATION

- Min-Max Scaling : $X' = (X - X_{min}) / (X_{max} - X_{min}) \rightarrow [0, 1]$
Utilisation : réseaux de neurones, KNN, SVM
- StandardScaler : $X' = (X - \mu) / \sigma \rightarrow$ moyenne 0, écart-type 1
Utilisation : régression, SVM, algorithmes basés sur la distance
- RobustScaler : utilise la médiane et IQR, robuste aux outliers

FEATURE ENGINEERING

L'art de créer de nouvelles variables qui capturent mieux la réalité.

EXEMPLES CONCRETS :

- À partir d'une date : extraire le jour, mois, trimestre, jour de semaine, est_weekend, est_férié, ancienneté_en_jours
- À partir de coordonnées GPS : distance au point central, densité locale
- À partir de texte : longueur, nombre de mots, présence de mots-clés
- Ratios : CA/Coûts, Marge/CA, Incidents/Effectif
- Interactions : Produit de deux variables fortement liées à la cible
- Agrégations : moyenne, max, min sur des groupes (client, région, période)

FEATURE SELECTION

Réduire le nombre de variables pour éviter le surapprentissage.

- Variance Threshold : supprimer les variables quasi-constantes
- Corrélation : supprimer une variable si corrélée à > 0.95 avec une autre
- SelectKBest : sélection statistique (ANOVA F, Chi2, Mutual Information)
- Importance des features : Random Forest ou XGBoost feature importance
- RFECV : Recursive Feature Elimination avec Cross-Validation
- PCA : réduction dimensionnelle non supervisée (perd l'interprétabilité)

2.4 VISUALISATION DES DONNÉES

Une visualisation réussie transmet un message en moins de 5 secondes.
Chaque graphique doit répondre à une question précise.

BIBLIOTHÈQUES PYTHON ESSENTIELLES

- Matplotlib : graphiques de base, contrôle total
- Seaborn : statistiques visuelles élégantes
- Plotly : graphiques interactifs
- Folium : cartes géographiques interactives
- Bokeh : dashboards web interactifs

CHOIX DU BON GRAPHIQUE

COMPARER DES VALEURS

- Barres verticales / horizontales

→ Lollipop chart (plus lisible pour beaucoup de catégories)

MONTRER UNE DISTRIBUTION

- Histogramme (distribution globale)
- Boxplot (médiane, quartiles, outliers)
- Violin plot (boxplot + distribution)

MONTRER UNE TENDANCE TEMPORELLE

- Courbe (line chart)
- Graphique en aires (area chart)

MONTRER UNE RELATION ENTRE DEUX VARIABLES

- Scatter plot (nuagé de points)
- Hexbin (pour beaucoup de points)
- Bubble chart (3 dimensions)

MONTRER UNE COMPOSITION

- Camembert (pie) – max 5 catégories
- Barres empilées (stacked bars)
- Treemap (hiérarchie)

MONTRER DES CORRÉLATIONS

- Heatmap
- Pair plot (matrice de scatter plots)

RÈGLES D'OR DE LA VISUALISATION

1. Titre clair et informatif (pas "Graphique 1" mais "Ventes en hausse de 23%")
2. Axes légendés avec unités
3. Pas plus de 5-6 couleurs distinctes
4. Pas de 3D sauf nécessité absolue
5. Annotation des points importants
6. Adapter le graphique à l'audience (technicien vs décideur)

PARTIE III – UTILISER : APPLICATIONS CONCRÈTES

3.1 PYTHON : L'OUTIL CENTRAL DU DATA SCIENTIST

Python s'est imposé comme la lingua franca de la data science.
Voici pourquoi et comment le maîtriser.

ÉCOSYSTÈME DATA PYTHON

MANIPULATION DES DONNÉES

- NumPy : calculs numériques, tableaux multidimensionnels
- Pandas : DataFrames, manipulation de données tabulaires
- Polars : alternative ultra-rapide à Pandas (multi-thread)

VISUALISATION

- Matplotlib, Seaborn, Plotly (voir section 2.4)

MACHINE LEARNING

- scikit-learn : algorithmes ML classiques, pipelines, métriques
- XGBoost / LightGBM / CatBoost : gradient boosting de haute performance
- Statsmodels : modèles statistiques avec résultats interprétables

DEEP LEARNING

- TensorFlow / Keras : production, déploiement, mobile
- PyTorch : recherche, flexibilité, communauté active

NLP (TRAITEMENT DU LANGAGE)

- NLTK / SpaCy : tokenisation, lemmatisation, POS tagging
- HuggingFace : modèles pré-entraînés (BERT, GPT, T5, etc.)
- Gensim : Word2Vec, LDA (topic modeling)

DONNÉES VOLUMINEUSES

- PySpark : calcul distribué sur cluster
- Dask : Pandas à l'échelle, calcul parallèle
- Vaex : DataFrames hors-mémoire

WORKFLOW TYPE EN PANDAS

```

import pandas as pd
import numpy as np

# Chargement
df = pd.read_csv("donnees.csv", sep=";", encoding="utf-8")

# Audit
print(df.shape)
print(df.dtypes)
print(df.isnull().sum())

# Nettoyage
df.dropna(subset=["colonne_cible"], inplace=True)
df["age"].fillna(df["age"].median(), inplace=True)
df.drop_duplicates(inplace=True)

# Feature Engineering
df["date"] = pd.to_datetime(df["date"])
df["mois"] = df["date"].dt.month
df["est_weekend"] = df["date"].dt.dayofweek >= 5

# Agrégation
resume = df.groupby("region").agg(
    ca_total=("ca", "sum"),
    nb_transactions=("id", "count"),
    panier_moyen=("ca", "mean")
).reset_index()

```

3.2 SQL : LANGUE UNIVERSELLE DES DONNÉES

Tout data scientist doit maîtriser SQL. Les données sont dans des bases. SQL est souvent plus rapide et plus lisible que Pandas pour certaines opérations.

REQUÊTES FONDAMENTALES

```

-- Sélection avec conditions
SELECT client_id, nom, ca_total
FROM clients
WHERE pays = 'Congo' AND ca_total > 500000
ORDER BY ca_total DESC
LIMIT 100;

-- Agrégation
SELECT region,
    COUNT(*) AS nb_clients,
    SUM(ca_total) AS ca_region,
    AVG(ca_total) AS panier_moyen
FROM clients
GROUP BY region
HAVING COUNT(*) > 10;

-- Jointures
SELECT c.nom, c.email, SUM(v.montant) AS total_achats
FROM clients c
INNER JOIN ventes v ON c.id = v.client_id
WHERE v.date >= '2024-01-01'
GROUP BY c.nom, c.email;

-- Fenêtrage (Window Functions) – clé pour analyses avancées
SELECT client_id, date, montant,
    SUM(montant) OVER (PARTITION BY client_id ORDER BY date) AS cumul_achats,
    RANK() OVER (PARTITION BY region ORDER BY ca DESC) AS rang_region,
    LAG(montant, 1) OVER (ORDER BY date) AS montant_precedent
FROM ventes;

-- Sous-requêtes
SELECT * FROM clients
WHERE ca_total > (
    SELECT AVG(ca_total) * 1.5 FROM clients
);

-- CTEs (Common Table Expressions) – lisibilité
WITH top_clients AS (

```

```

SELECT client_id, SUM(montant) AS total
FROM ventes
GROUP BY client_id
ORDER BY total DESC
LIMIT 100
)
SELECT c.nom, tc.total
FROM top_clients tc
JOIN clients c ON tc.client_id = c.id;

```

3.3 PIPELINES ET AUTOMATISATION

Un data scientist senior automatise. Le junior répète les mêmes tâches manuellement.
L'automatisation est la différence entre un artisan et un ingénieur.

PIPELINE SCIKIT-LEARN

```

from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.impute import SimpleImputer
from sklearn.compose import ColumnTransformer
from sklearn.ensemble import RandomForestClassifier

# Définir les transformations
num_pipeline = Pipeline([
    ('imputer', SimpleImputer(strategy='median')),
    ('scaler', StandardScaler())
])

cat_pipeline = Pipeline([
    ('imputer', SimpleImputer(strategy='most_frequent')),
    ('encoder', OneHotEncoder(handle_unknown='ignore'))
])

preprocessor = ColumnTransformer([
    ('num', num_pipeline, colonnes_numeriques),
    ('cat', cat_pipeline, colonnes_categoriques)
])

pipeline_final = Pipeline([
    ('preprocessing', preprocessor),
    ('model', RandomForestClassifier(n_estimators=100, random_state=42))
])

# Entraîner en une ligne
pipeline_final.fit(X_train, y_train)

# Prédire
predictions = pipeline_final.predict(X_test)

```

AVANTAGES DU PIPELINE :

- Pas de data leakage (les transformations apprennent seulement sur le train)
- Reproductible et sérialisable (sauvegardé avec joblib ou pickle)
- Déployable directement en production

PARTIE IV – DÉCIDER : LA DONNÉE AU SERVICE DE L'ACTION

4.1 LA BOUCLE DÉCISIONNELLE BASÉE SUR LA DONNÉE

La donnée sans décision est du bruit. Toute analyse doit se terminer par une recommandation claire, actionnelle, avec un horizon temporel.

STRUCTURE D'UNE RECOMMANDATION DATA-DRIVEN :

- | | |
|-------------------|--|
| 1. CONTEXTE | → Situation actuelle, problème observé |
| 2. ANALYSE | → Ce que les données révèlent |
| 3. INSIGHT | → L'enseignement clé non-évident |
| 4. RECOMMANDATION | → Ce qu'on doit faire (avec priorité et délai) |
| 5. IMPACT ATTENDU | → Résultat mesurable si la recommandation est suivie |

- 6. RISQUES → Ce qui peut mal tourner
- 7. INDICATEURS → Comment on saura si ça fonctionne (KPIs)

EXEMPLE CONCRET (Industrie) :

CONTEXTE : Le taux de pannes machines est de 12% ce trimestre.
ANALYSE : 78% des pannes surviennent sur 3 équipements, les lundis matin.
INSIGHT : Ces machines n'ont pas été entretenues après le pic de production du vendredi soir. La corrélation panne/charge vendredi est à 0.87.
RECOMMANDATION : Ajouter une intervention de maintenance le samedi matin sur ces 3 équipements. Priorité 1. À implémenter sous 2 semaines.
IMPACT ATTENDU : Réduction estimée à 6% du taux de pannes, économie de 2.4M FCFA/mois.
RISQUES : Coût main d'œuvre week-end (+15%). Résistance syndicale possible.
INDICATEURS : Taux de pannes hebdomadaire, durée moyenne entre pannes (MTBF).

4.2 TABLEAUX DE BORD ET KPIs

Un bon tableau de bord ne montre pas tout. Il répond à une question par écran.

RÈGLE DES 3 NIVEAUX DE LECTURE :

- NIVEAU 1 – DIRECTION (vue en 10 secondes)
 - 3 à 5 KPIs critiques avec tendance
 - Alertes rouges / oranges / vertes
 - Comparaison objectif vs réel
- NIVEAU 2 – MANAGEMENT (vue en 2 minutes)
 - Drill-down par département, région, produit
 - Évolution temporelle
 - Top 10 / Bottom 10
- NIVEAU 3 – OPÉRATIONNEL (vue détaillée)
 - Tableaux avec filtres
 - Données granulaires
 - Export possible

OUTILS DE TABLEAU DE BORD

- Power BI (Microsoft, largement utilisé en entreprise)
- Tableau (visualisation avancée)
- Metabase (open source, rapide à déployer)
- Apache Superset (open source, puissant)
- Grafana (monitoring technique, IoT, DevOps)
- Dash / Streamlit (Python, dashboard custom)

CONCEPTION DE BONS KPIs (SMART)

- Spécifique : mesure précisément ce qu'on veut
- Mesurable : calculable à partir de données réelles
- Actionnable : on peut agir dessus
- Relevé : lié aux objectifs stratégiques
- Temporel : défini sur une période précise

4.3 PRISE DE DÉCISION SOUS INCERTITUDE

Les données ne donnent jamais de certitudes absolues. Elles réduisent l'incertitude. Un data scientist senior sait quantifier et communiquer cette incertitude.

OUTILS DE DÉCISION SOUS INCERTITUDE

- ANALYSE DE SCÉNARIOS
 - Scénario pessimiste / base / optimiste
 - Probabilité assignée à chaque scénario
 - Décision robuste = bonne dans la plupart des scénarios
- ARBRES DE DÉCISION (ANALYSE)
 - Représentation graphique des choix et conséquences
 - Valeur espérée = somme des (probabilité × gain)
 - Utile pour décisions à fort impact avec alternatives claires
- ANALYSE COÛT-BÉNÉFICE
 - Coût d'une action vs coût de l'inaction
 - Valeur actualisée nette (VAN) pour décisions d'investissement

- Retour sur investissement (ROI)

SIMULATION MONTE CARLO

- Simuler des milliers de scénarios aléatoires
- Obtenir une distribution des résultats possibles
- Quantifier la probabilité d'atteindre un objectif

THÉORIE DES JEUX

- Décisions où d'autres acteurs réagissent à nos choix
- Utile en contexte concurrentiel, militaire, diplomatique
- Équilibres de Nash, stratégies dominantes

PARTIE V – DATA SCIENCE DANS LA SCIENCE

5.1 LE DATA SCIENTIST AU SERVICE DE LA RECHERCHE SCIENTIFIQUE

La data science a révolutionné la recherche dans presque toutes les disciplines. Le data scientist scientifique n'est pas un biologiste ou un physicien – il est l'ingénieur de la donnée au service des scientifiques.

DOMAINES D'APPLICATION

BIOINFORMATIQUE ET GÉNOMIQUE

- Séquençage ADN, protéomique, phylogénétique
 - Détection de mutations cancéreuses
 - Prédiction de structure protéique (AlphaFold révolution)
 - Clustering de populations génétiques
- Outils : BioPython, R/Bioconductor, BLAST, Rosetta

MÉDECINE ET SANTÉ

- Prédiction du risque de maladie (diabète, infarctus, cancer)
 - Détection de tumeurs sur imagerie médicale (CNN)
 - Analyse de survie (Kaplan-Meier, Cox regression)
 - Épidémiologie computationnelle (modèles SIR, SIS, SEIR)
 - Drug discovery : prédiction d'interaction molécule-protéine
- Outils : lifelines, scikit-survival, medpy, nibabel

PHYSIQUE ET ASTRONOMIE

- Analyse de signaux ondes gravitationnelles (LIGO)
 - Classification de galaxies (Galaxy Zoo)
 - Détection de planètes exosolaires (transits)
 - Simulation de collisions de particules (LHC au CERN)
- Outils : AstroPy, HEALPix, ROOT

CLIMATOLOGIE ET ENVIRONNEMENT

- Modélisation du changement climatique
 - Prédiction de catastrophes naturelles
 - Analyse de séries temporelles de température
 - Traitement d'images satellites (forêts, glaciers, villes)
- Outils : xarray, netCDF4, GDAL, Google Earth Engine

SCIENCES SOCIALES COMPUTATIONNELLES

- Analyse de réseaux sociaux (graphes)
 - Détection de communautés
 - Modélisation de comportements collectifs
 - NLP sur corpus historiques
- Outils : NetworkX, igraph, NLTK

5.2 MÉTHODES SCIENTIFIQUES ET DATA SCIENCE

La rigueur scientifique est non négociable dans la recherche.

REPRODUCTIBILITÉ

- Problème critique en data science scientifique
- Solution : notebooks Jupyter avec seed fixé, environnements virtuels, Docker, DVC (Data Version Control)
- Tout résultat doit être reproductible par un tiers

VALIDATION CROISÉE EN CONTEXTE SCIENTIFIQUE

- K-fold standard : attention au leakage temporel
- Leave-One-Out pour petits datasets
- Bootstrapping pour intervalles de confiance

TESTS MULTIPLES (PROBLÈME DU P-HACKING)

- Tester 100 hypothèses → 5 fausses significativités par hasard ($\alpha=0.05$)
- Correction de Bonferroni : α ajusté = α / nombre de tests
- Correction de Benjamini-Hochberg : contrôle le taux de fausses découvertes

MÉTA-ANALYSES ET REVUES SYSTÉMATIQUES

- Combiner les résultats de plusieurs études
- Forest plots : visualiser les effets et leurs intervalles
- Hétérogénéité entre études (test I^2)

PARTIE VI – DATA SCIENCE DANS L'ARMÉE

6.1 LA DONNÉE COMME ARME STRATÉGIQUE

L'armée moderne est une machine à produire et consommer de la donnée.
Celui qui maîtrise l'information maîtrise le champ de bataille.

"La guerre moderne est une guerre de l'information.
Les données ne sont pas le support de la décision – elles sont la décision."

DOMAINES D'APPLICATION MILITAIRE

RENSEIGNEMENT ET ANALYSE GÉOSPATIALE (GEOINT)

- Analyse d'images satellites (SAR, optique, infrarouge)
- Détection de changements (bases, véhicules, constructions)
- Reconnaissance automatique de cibles (ATR)
- Fusion de sources HUMINT, SIGINT, IMINT
- Outils : QGIS, ArcGIS, SNAP, OpenCV, GDAL

ANALYSE PRÉDICTIVE DU CHAMP DE BATAILLE

- Modèles de prédiction d'incidents (hotspot analysis)
- Analyse de réseaux insurgés (graphes, centralité)
- Prédiction de mouvements de troupes adverses
- Analyse de terrain (relief, couverture, axes de progression)
- Outils : ArcPy, NetworkX, Prophet, spatial ML

CYBERSÉCURITÉ ET GUERRE ÉLECTRONIQUE

- Détection d'anomalies réseau (intrusion detection)
- Analyse de malware (classification ML)
- Attribution d'attaques (profiling d'acteurs)
- Prédiction de cyberattaques (threat intelligence)
- Outils : Elastic SIEM, Splunk, Darktrace, Snort

MAINTENANCE PRÉDICTIVE D'ÉQUIPEMENTS MILITAIRES

- Capteurs IoT sur véhicules, aéronefs, navires
- Prédiction de pannes avant qu'elles surviennent
- Optimisation des révisions et pièces de rechange
- Réduction du downtime opérationnel
- Outils : même stack que l'industrie 4.0

LOGISTIQUE ET SUPPLY CHAIN MILITAIRE

- Optimisation des flux de ravitaillement
- Prédiction des besoins en munitions, carburant, nourriture
- Routage optimal des convois
- Gestion des stocks sous contraintes opérationnelles
- Outils : OR-Tools, PuLP, SimPy

ANALYSE DES RÉSEAUX TERRORISTES/INSURGÉS

- Graphes de relations (social network analysis)
- Identification de nœuds critiques
- Détection de clusters d'activité
- Analyse de communications interceptées (NLP)
- Outils : Gephi, igraph, NetworkX, Maltego

6.2 ÉTHIQUE ET CONTRAINTES DU DATA SCIENTIST MILITAIRE

Le data scientist militaire est soumis à des contraintes éthiques et légales particulièrement strictes.

PRINCIPES FONDAMENTAUX

- Droit international humanitaire (distinction civil/combattant)
- Proportionnalité (dommages collatéraux vs avantage militaire)
- Précaution (vérification avant action létale)
- Responsabilité humaine finale (pas d'autonomie létale absolue)

RISQUES SPÉCIFIQUES AUX SYSTÈMES AUTOMATISÉS

- Biais dans les données d'entraînement → discrimination raciale/ethnique
- Faux positifs dans les systèmes de ciblage → victimes civiles
- Robustesse aux attaques adversariales (manipulation d'entrées)
- Opacité des modèles profonds (manque d'explicabilité)

DOCTRINE NATO SUR L'IA MILITAIRE

- L'humain doit rester dans la boucle pour les décisions létales
- Les systèmes d'IA doivent être explicables et auditables
- Tests de robustesse obligatoires avant déploiement opérationnel

6.3 MODÈLES ANALYTIQUES UTILISÉS EN CONTEXTE MILITAIRE

ANALYSE DE HOTSPOTS (Points chauds)

- Prédire où et quand des incidents vont se produire.
- Kernel Density Estimation (KDE) : densité spatiale d'événements
 - Scan statistics (SaTScan) : clusters spatio-temporels
 - Random Forest sur historique d'incidents + variables contextuelles

ANALYSE DE RÉSEAU (SNA)

- Cartographier les organisations adverses.
- Centralité de degré : qui a le plus de contacts ?
 - Centralité d'intermédierité : qui contrôle les flux d'information ?
 - Détection de communautés : quels sous-groupes existent ?

MODÈLES DE DÉPLACEMENT

- Prédire les trajectoires de véhicules ou de groupes.
- Modèles Markov cachés (HMM)
 - Réseaux de neurones récurrents (LSTM)
 - Analyse de routines et anomalies

FUSION DE DONNÉES MULTI-SOURCES

- Combiner des données hétérogènes en une image cohérente.
- Filtre de Kalman : fusion de capteurs avec incertitude
 - Dempster-Shafer : raisonnement sous incertitude
 - Bayesian fusion : mise à jour de probabilités avec nouvelles preuves

PARTIE VII – DATA SCIENCE DANS L'INDUSTRIE

7.1 VUE D'ENSEMBLE DES CAS D'USAGE INDUSTRIELS

L'industrie a été transformée plus rapidement que tout autre secteur par la data science. La clé est l'instrumentation – les capteurs, l'IoT, et les MES (Manufacturing Execution Systems) génèrent des téraoctets quotidiens.

7.2 MAINTENANCE PRÉDICTIVE (PREDICTIVE MAINTENANCE)

C'est le cas d'usage data le plus rentable dans l'industrie. Le passage de la maintenance corrective (pannes) à la maintenance prédictive (anticipation) génère des économies de 25 à 40%.

ARCHITECTURE TYPIQUE

- COLLECTE → CAPTEURS IoT (vibrations, température, pression, courant)
- Historique de pannes et d'interventions
 - Données de production (charge, vitesse, cycles)

PRÉPARATION → Synchronisation temporelle des signaux
→ Extraction de features : RMS, FFT, kurtosis, entropie
→ Labellisation des périodes pré-panne

MODÉLISATION → Approche 1 : Classification binaire (panne dans les 7 jours ?)
→ Approche 2 : Régression (dans combien de jours ?)
→ Approche 3 : Anomaly detection (état anormal détecté)

DÉPLOIEMENT → Score de risque en temps réel par machine
→ Alertes automatiques à l'équipe maintenance
→ Tableau de bord de santé des équipements

ALGORITHMES PERTINENTS

- Random Forest / XGBoost (classification panne)
- LSTM / Transformer (séries temporelles de capteurs)
- Isolation Forest (détection d'anomalies non supervisée)
- Autoencoder (détection d'anomalies par reconstruction)
- Kaplan-Meier / Cox (analyse de survie pour durée de vie)

MÉTRIQUES CLÉS

- MTBF (Mean Time Between Failures) : temps moyen entre pannes
- MTTR (Mean Time To Repair) : temps moyen de réparation
- OEE (Overall Equipment Effectiveness) : efficacité globale équipement
- Precision/Recall sur les alarmes (équilibre fausses alertes vs pannes manquées)

7.3 OPTIMISATION DE PRODUCTION ET SUPPLY CHAIN

PLANIFICATION DE LA DEMANDE

- Prévoir les volumes de commande pour ajuster la production
- Modèles : SARIMA, Prophet, XGBoost sur séries temporelles
- Intégration d'événements extérieurs (météo, promotions, fériés)
- Réduction des stocks excédentaires et ruptures simultanément

OPTIMISATION DES STOCKS

- Point de commande optimal, quantité économique de commande (EOQ)
- Analyse ABC-XYZ : prioriser selon valeur et variabilité
- Simulation Monte Carlo pour stocks de sécurité

OPTIMISATION LOGISTIQUE

- Problème du Voyageur de Commerce (TSP) → tournées optimales
- Vehicle Routing Problem (VRP) → flotte de véhicules
- Outils : OR-Tools (Google), PuLP, Gurobi

CONTRÔLE QUALITÉ STATISTIQUE (SPC)

- Cartes de contrôle (Shewhart, CUSUM, EWMA)
- Capacité de procédé (Cp, Cpk, Ppk)
- Détection précoce de dérives de production
- Six Sigma : réduction de la variabilité

7.4 INDUSTRIE 4.0 ET DIGITAL TWIN

CONCEPT DU DIGITAL TWIN

Un jumeau numérique est un modèle virtuel d'un actif physique, synchronisé en temps réel avec la réalité via des capteurs IoT.

Applications :

- Simuler des modifications avant de les appliquer
- Optimiser le fonctionnement en conditions réelles
- Prédire la dégradation et planifier la maintenance
- Former les opérateurs sans risque

ARCHITECTURE IoT → DATA SCIENCE

EDGE COMPUTING

- Traitement local sur la machine ou le capteur
- Latence très faible, données sensibles restent locales
- Filtrage avant envoi vers le cloud

CLOUD / DATA LAKE

- Agrégation de toutes les sources
- Stockage long terme à bas coût

→ Entraînement des modèles ML

STREAMING (TEMPS RÉEL)

- Apache Kafka : ingestion de flux massifs
- Apache Flink / Spark Streaming : traitement en temps réel
- Alertes et actions automatiques sur événements

PARTIE VIII – DEVENIR UN DATA SCIENTIST INDISPENSABLE

8.1 LA DIFFÉRENCE ENTRE UN JUNIOR ET UN SENIOR

Cette différence n'est pas seulement technique. Elle est fondamentalement une différence de posture, de vision et de communication.

JUNIOR	SENIOR
Se concentre sur les modèles	Se concentre sur le problème métier
Optimise le score de validation	Optimise l'impact business
Attend qu'on lui pose des questions	Formule les bonnes questions lui-même
Présente des graphiques techniques	Traduit en langage décisionnel
Cherche le modèle le plus complexe	Préfère le modèle le plus simple qui marche
Travaille en silo	Collabore avec toutes les équipes
Documente peu	Documente tout, automatise tout
Pense en projets	Pense en produits data pérennes
Craint l'échec	Teste, itère, apprend vite
Connaît des outils	Résout des problèmes avec des outils

8.2 LES COMPÉTENCES RARES QUI CRÉENT LA VALEUR

Ces compétences sont sous-enseignées mais sur-valorisées dans les organisations.

- [1] COMMUNICATION DES RÉSULTATS
 - Adapter le message selon l'audience
 - Storytelling avec les données (data storytelling)
 - Une slide = un message
 - Anticiper les questions et objections
- [2] SENS DU CADRAGE PROBLÈME
 - Définir le problème AVANT de chercher des données
 - Distinguer ce qu'on veut savoir de ce qu'on peut savoir
 - Reformuler une demande floue en problème précis
- [3] ÉTHIQUE ET BIAIS
 - Détecter les biais dans les données et les modèles
 - Fairness : différences de traitement selon groupe démographique
 - Privacy : RGPD, anonymisation, consentement
 - Expliquer les décisions automatisées
- [4] MLOps ET DÉPLOIEMENT
 - Un modèle non déployé ne crée aucune valeur
 - CI/CD pour modèles ML (MLflow, Weights & Biases, DVC)
 - Monitoring de drift en production
 - Rollback rapide en cas de dégradation
- [5] CULTURE DU DOCUMENT
 - Documentation du code (docstrings, README)
 - Documentation des modèles (Model Cards)
 - Documentation des pipelines de données
 - Reproductibilité totale

8.3 FEUILLE DE ROUTE JUNIOR → SENIOR (24 MOIS)

MOIS 1-3 : FONDATIONS SOLIDES

- ✓ Maîtriser Python (Pandas, NumPy, Matplotlib)
- ✓ SQL intermédiaire (jointures, agrégations, window functions)
- ✓ Statistiques descriptives et inférentielles
- ✓ Un premier projet complet de bout en bout

- ✓ Git et GitHub maîtrisés

MOIS 4-6 : MACHINE LEARNING CLASSIQUE

- ✓ scikit-learn : toute la bibliothèque
- ✓ 10 algorithmes ML fondamentaux (voir Partie X)
- ✓ Métriques et évaluation de modèles
- ✓ Pipelines et cross-validation
- ✓ Participation à une compétition Kaggle

MOIS 7-9 : SPÉCIALISATION ET PROFONDEUR

- ✓ Un domaine d'application (industrie, finance, santé, etc.)
- ✓ Feature engineering avancé
- ✓ Bases du Deep Learning (Keras/PyTorch)
- ✓ NLP ou Computer Vision (au choix)
- ✓ Déploiement d'un modèle (Flask/FastAPI + Docker)

MOIS 10-12 : INFRASTRUCTURE ET DONNÉES MASSIVES

- ✓ SQL avancé + un entrepôt de données (BigQuery, Redshift, Snowflake)
- ✓ Bases de Spark ou Dask
- ✓ Un projet de pipeline de données automatisé (Airflow, dbt)
- ✓ Tableau de bord en production (Power BI, Metabase, Streamlit)

MOIS 13-18 : IMPACT ET AUTONOMIE

- ✓ Leadership sur un projet complet
- ✓ Communication aux décideurs (sans support technique)
- ✓ MLOps (MLflow, monitoring, retraining)
- ✓ Revue de code et mentoring de juniors
- ✓ Contribution open source ou publication (blog, article)

MOIS 19-24 : VISION STRATÉGIQUE

- ✓ Définir la stratégie data d'une équipe ou d'une organisation
- ✓ Construire une culture data au sein d'une organisation
- ✓ Identifier les cas d'usage à fort ROI dans un secteur
- ✓ Capacité à recruter et évaluer des data scientists
- ✓ Construire des produits data autonomes (SaaS, APIs)

PARTIE IX – GESTION, STOCKAGE ET TRAITEMENT DES DONNÉES

9.1 ARCHITECTURES DE DONNÉES

BASES DE DONNÉES RELATIONNELLES (RDBMS)

- Structure : tables, lignes, colonnes, clés étrangères
- Langage : SQL
- Propriétés ACID : Atomicité, Cohérence, Isolation, Durabilité
- Exemples : PostgreSQL, MySQL, SQLite, Oracle, SQL Server
- Usage : données structurées, transactions, ERP, CRM

BASES DE DONNÉES NON RELATIONNELLES (NoSQL)

- Document Store : MongoDB (JSON), Firestore
Usage : contenu flexible, e-commerce, profils
- Clé-Valeur : Redis, DynamoDB
Usage : cache, sessions, temps réel
- Colonne Large : Cassandra, HBase
Usage : IoT, logs, séries temporelles massives
- Graphe : Neo4j, Amazon Neptune
Usage : réseaux sociaux, recommandation, fraude
- Séries Temporelles : InfluxDB, TimescaleDB
Usage : capteurs, métriques, monitoring

DATA WAREHOUSE (ENTREPÔT DE DONNÉES)

- Structure columnaire, optimisée pour la lecture analytique
- Données historiques nettoyées et transformées
- Exemples : BigQuery (Google), Redshift (AWS), Snowflake
- Modélisation : schéma en étoile (star schema), flocon de neige

DATA LAKE

- Stockage de données brutes dans leur format natif
- Flexibilité maximale, coût de stockage faible
- Risque : "marécage de données" (Data Swamp) si non gouverné
- Exemples : S3 (AWS), Azure Data Lake, GCS (Google)

DATA LAKEHOUSE

- Hybride : flexibilité du Lake + performance du Warehouse
- Exemples : Delta Lake, Apache Iceberg, Databricks
- Standard émergent dominant en 2024-2025

9.2 PIPELINES DE DONNÉES (ETL / ELT)

ETL (Extract, Transform, Load)

- Transformer les données AVANT de les charger
- Historique : pour entrepôts de données classiques
- Avantage : données propres dès l'arrivée
- Inconvénient : inflexible, long à mettre en place

ELT (Extract, Load, Transform)

- Charger brut d'abord, transformer après dans le Warehouse
- Moderne : profite de la puissance des entrepôts cloud
- Avantage : flexibilité, rapidité de mise en place
- Outils : dbt (data build tool) pour les transformations SQL

ORCHESTRATION DE PIPELINES

- Apache Airflow : scheduling, DAGs, monitoring (standard de facto)
- Prefect : alternative plus moderne à Airflow
- Dagster : orienté assets data, observabilité
- Luigi : plus simple, bon pour démarrer

INGESTION TEMPS RÉEL

- Apache Kafka : bus de messages distribué, haute performance
Concepts : Producer, Consumer, Topic, Partition, Offset
- Apache Flink : traitement de flux avec état (stateful)
- Spark Streaming : micro-batch sur Spark

9.3 GOUVERNANCE DES DONNÉES

La gouvernance des données est la politique qui garantit qualité, sécurité et utilisation responsable de la donnée.

QUALITÉ DES DONNÉES (5 DIMENSIONS)

1. EXACTITUDE : les données reflètent la réalité
2. COMPLÉTUDE : aucune valeur manquante attendue
3. COHÉRENCE : mêmes données = mêmes valeurs partout
4. TEMPORALITÉ : données fraîches, horodatage correct
5. UNICITÉ : pas de doublons

CATALOGUE DE DONNÉES

- Répertoire de toutes les tables, colonnes, définitions
- Qui peut accéder à quoi, pour quoi
- Lignage des données (data lineage) : d'où vient cette colonne ?
- Outils : Apache Atlas, DataHub, Alation, dbt docs

SÉCURITÉ ET CONFORMITÉ

- RGPD (Europe) : consentement, droit à l'oubli, portabilité
- Pseudonymisation et anonymisation des données personnelles
- Contrôle d'accès basé sur les rôles (RBAC)
- Chiffrement au repos et en transit
- Journalisation des accès (audit logs)

PARTIE X – MACHINE LEARNING : FONDEMENTS ET PRATIQUE

10.1 TAXONOMIE DU MACHINE LEARNING

APPRENTISSAGE SUPERVISÉ

Le modèle apprend à partir d'exemples étiquetés ($X \rightarrow Y$).

CLASSIFICATION (prédire une catégorie)

- Régression Logistique
- K plus proches voisins (KNN)
- Naïve Bayes

- Arbre de décision
- Random Forest
- SVM (Support Vector Machine)
- Gradient Boosting (XGBoost, LightGBM, CatBoost)

RÉGRESSION (prédire une valeur continue)

- Régression Linéaire
- Ridge, Lasso, ElasticNet
- Arbre de régression
- Random Forest Regressor
- Gradient Boosting Regressor
- SVR

APPRENTISSAGE NON SUPERVISÉ

Le modèle découvre la structure des données sans étiquettes.

CLUSTERING (regroupement)

- K-Means : clusters sphériques, rapide
- DBSCAN : clusters arbitraires, détection d'outliers
- Hierarchical Clustering : dendrogramme
- GMM (Gaussian Mixture Models) : clusters probabilistes

RÉDUCTION DE DIMENSIONNALITÉ

- PCA : variance maximale préservée, linéaire
- t-SNE : visualisation en 2D/3D, non linéaire
- UMAP : plus rapide que t-SNE, préserve structure globale
- Autoencoders : réduction non linéaire par réseau de neurones

DÉTECTION D'ANOMALIES

- Isolation Forest
- One-Class SVM
- Autoencoder (reconstruction error)
- LOF (Local Outlier Factor)

APPRENTISSAGE PAR RENFORCEMENT

Un agent apprend en interagissant avec un environnement (récompenses/punitions).

- Q-Learning, Deep Q-Network (DQN)
- Policy Gradient, PPO, A3C
- Applications : jeux, robotique, trading, optimisation de publicité

10.2 LES 10 ALGORITHMES FONDAMENTAUX (AVEC INTUITION)

[1] RÉGRESSION LINÉAIRE

Intuition : tracer la droite qui passe le plus près de tous les points

Formule : $Y = \beta_0 + \beta_1 X_1 + \dots + \beta_n X_n$

Usage : prédire des valeurs continues, relation linéaire

Avantages : interprétable, rapide

Limites : suppose linéarité, sensible aux outliers

[2] RÉGRESSION LOGISTIQUE

Intuition : transformer une sortie linéaire en probabilité [0,1]

Formule : $P(Y=1) = 1 / (1 + e^{(-z)})$ où $z = \beta_0 + \beta_1 X_1 + \dots$

Usage : classification binaire (spam, fraude, churn)

Avantages : interprétable, rapide, probabilités calibrées

Limites : frontière linéaire seulement

[3] ARBRE DE DÉCISION

Intuition : série de questions OUI/NON pour atteindre une décision

Usage : classification et régression, données mixtes

Avantages : interprétable, gère valeurs manquantes, non paramétrique

Limites : surapprentissage si profond, instable

[4] RANDOM FOREST

Intuition : voter entre 100+ arbres de décision différents

Usage : classification et régression, robuste et performant

Avantages : résistant au surapprentissage, importance des features

Limites : peu interprétable, lent sur grandes données

[5] GRADIENT BOOSTING (XGBoost)

Intuition : construire des arbres en série, chacun corrigeant les erreurs du précédent

Usage : compétitions ML, tabular data, production

Avantages : très performant, gère valeurs manquantes nativement

Limites : lent à entraîner, hyperparamètres nombreux

- [6] SVM (SUPPORT VECTOR MACHINE)
 Intuition : trouver la frontière de séparation maximisant la marge entre classes
 Usage : données de haute dimension, texte, images (petits datasets)
 Avantages : efficace haute dimension, robuste aux outliers
 Limites : lent sur grands datasets, difficile à interpréter
- [7] K-MEANS
 Intuition : itérativement assigner des points à leur centroïde le plus proche
 Usage : segmentation clients, clustering d'images, compression
 Avantages : rapide, simple, scalable
 Limites : k fixé à l'avance, clusters sphériques seulement, sensible aux outliers
- [8] KNN (K-NEAREST NEIGHBORS)
 Intuition : "dis-moi qui sont tes voisins, je te dirai qui tu es"
 Usage : classification, régression, systèmes de recommandation
 Avantages : aucun entraînement, s'adapte aux distributions complexes
 Limites : lent à la prédiction, sensible à la dimension, mémoire importante
- [9] NAÏVE BAYES
 Intuition : probabilité conditionnelle avec hypothèse d'indépendance
 Usage : classification de texte (spam, sentiment), temps réel
 Avantages : très rapide, peu de données requises, probabiliste
 Limites : hypothèse d'indépendance souvent fausse
- [10] ISOLATION FOREST
 Intuition : les anomalies sont isolées plus vite que les points normaux
 Usage : détection d'anomalies, fraude, intrusion réseau
 Avantages : non supervisé, scalable, peu de paramètres
 Limites : interprétabilité faible, seuil à calibrer

10.3 ÉVALUATION DES MODÈLES

MÉTRIQUES DE CLASSIFICATION

MATRICE DE CONFUSION

TP : Vrais Positifs (prédits positifs, réellement positifs)
 TN : Vrais Négatifs (prédits négatifs, réellement négatifs)
 FP : Faux Positifs – Erreur de Type I (prédits positifs, réellement négatifs)
 FN : Faux Négatifs – Erreur de Type II (prédits négatifs, réellement positifs)

MÉTRIQUES DÉRIVÉES

Accuracy = $(TP + TN) / \text{Total}$ [à éviter si classes déséquilibrées]
 Precision = $TP / (TP + FP)$ [parmi les prédits positifs, combien sont vrais ?]
 Recall = $TP / (TP + FN)$ [parmi les vrais positifs, combien sont détectés ?]
 F1-Score = $2 \times (Precision \times Recall) / (Precision + Recall)$
 AUC-ROC = aire sous la courbe ROC [performance globale du classifieur]

QUAND UTILISER QUOI ?

- Fraude, cancer, panne : priorité au Recall (ne pas manquer un vrai positif)
- Spam, fausse alarme : priorité à la Precision (ne pas déranger inutilement)
- Contexte équilibré : F1-Score
- Comparaison de modèles : AUC-ROC

MÉTRIQUES DE RÉGRESSION

MAE (Mean Absolute Error) = $\text{moy}(|y - \hat{y}|)$ [robuste, interprétable]
 RMSE (Root Mean Squared Error) = $\sqrt{\text{moy}((y - \hat{y})^2)}$ [pénalise les grandes erreurs]
 MAPE (Mean Absolute Pct Error) = $\text{moy}(|y - \hat{y}| / |y|)$ [erreur en pourcentage]
 R² (Coefficient de détermination) [0 à 1, proportion variance expliquée]

VALIDATION CROISÉE (CROSS-VALIDATION)

- K-Fold : diviser en k plis, entraîner k fois sur (k-1) plis, tester sur 1
- Stratified K-Fold : garantir la même distribution de classes dans chaque pli
- Time Series Split : respecter la chronologie pour les séries temporelles
- Leave-One-Out : k = n, pour très petits datasets

PROBLÈMES À DIAGNOSTIQUER

SURAPPRENTISSAGE (OVERFITTING)

Symptôme : très bonne performance sur train, mauvaise sur test
 Cause : modèle trop complexe, trop peu de données
 Remède : régularisation, plus de données, modèle plus simple, dropout

SOUS-APPRENTISSAGE (UNDERFITTING)

Symptôme : mauvaise performance sur train ET test

Cause : modèle trop simple, features insuffisantes

Remède : modèle plus complexe, plus de features, moins de régularisation

BIAIS-VARIANCE TRADEOFF

Biais = erreur due à des hypothèses simplificatrices du modèle

Variance= sensibilité aux fluctuations des données d'entraînement

Objectif: trouver le juste milieu entre les deux

10.4 OPTIMISATION DES HYPERPARAMÈTRES

GRID SEARCH

→ Tester toutes les combinaisons d'hyperparamètres définis

→ Exhaustif mais lent sur grand espace de paramètres

```
from sklearn.model_selection import GridSearchCV
```

RANDOM SEARCH

→ Échantillonner aléatoirement l'espace des paramètres

→ Plus efficace que Grid Search dans la pratique

```
from sklearn.model_selection import RandomizedSearchCV
```

BAYESIAN OPTIMIZATION

→ Utiliser les résultats précédents pour orienter la recherche

→ Converge plus vite que les méthodes aléatoires

Outils : Optuna, Hyperopt, Weights & Biases Sweeps

PARTIE XI – DEEP LEARNING : RÉSEAUX DE NEURONES ET IA

11.1 FONDEMENTS DES RÉSEAUX DE NEURONES

LE NEURONE ARTIFICIEL

Inspiré (très loosely) du neurone biologique.

Calcul : $z = w_1 \cdot x_1 + w_2 \cdot x_2 + \dots + w_n \cdot x_n + b$

Activation : $a = f(z)$ où f est la fonction d'activation

FONCTIONS D'ACTIVATION

- Sigmoid : $a = 1/(1+e^{-z}) \rightarrow [0,1]$ [obsolète pour couches cachées]
- Tanh : $a = \tanh(z) \rightarrow [-1,1]$ [mieux que sigmoid, centré sur 0]
- ReLU : $a = \max(0, z) \rightarrow [0, \infty]$ [standard actuel, rapide]
- Leaky ReLU : $a = \max(0.01z, z)$ [évite les neurones morts]
- Softmax : normalise en probabilités pour multi-classification

ARCHITECTURE DE BASE : RÉSEAU DENSE (MLP)

- Couche d'entrée : autant de neurones que de features
- Couches cachées : transformations successives
- Couche de sortie : autant de neurones que de classes (ou 1 pour régression)
- Chaque couche est entièrement connectée à la suivante

APPRENTISSAGE PAR RÉTROPROPAGATION

1. Propagation avant : calcul des prédictions
2. Calcul de la loss (erreur)
3. Propagation arrière : calcul des gradients (règle de la chaîne)
4. Mise à jour des poids (descente de gradient)

FONCTIONS DE PERTE (LOSS FUNCTIONS)

- Cross-Entropy : classification binaire ou multi-classe
- MSE (Mean Squared Error) : régression
- MAE (Mean Absolute Error) : régression robuste aux outliers
- Huber Loss : compromis MSE/MAE

OPTIMISEURS

- SGD (Stochastic Gradient Descent) : classique, simple
- Adam : adaptatif, standard actuel, rapide à converger
- RMSprop : bon pour RNN
- AdamW : Adam avec weight decay, meilleur pour les LLMs

11.2 ARCHITECTURES SPÉCIALISÉES

CNN – RÉSEAUX DE NEURONES CONVOLUTIFS (VISION)

Architecture : Convolution → Pooling → Convolution → Pooling → Dense

Usage : classification d'images, détection d'objets, segmentation

Comment ça marche :

- Filtre (kernel) glisse sur l'image et détecte des patterns locaux
- Couches précoces : contours, textures
- Couches profondes : formes, objets, visages

Architectures célèbres : VGG, ResNet, EfficientNet, ConvNeXt

Transfer Learning : utiliser un modèle pré-entraîné sur ImageNet

- Gèle les premières couches, fine-tune les dernières
- Besoin de très peu de données pour une tâche spécifique

RNN – RÉSEAUX RÉCURRENTS (SÉQUENCES)

Architecture : cellule avec état caché transmis dans le temps

Usage : NLP, séries temporelles, génération de texte

LSTM (Long Short-Term Memory) :

- Résout le problème du gradient qui disparaît sur longues séquences
- Cellule, état caché, portes (oubli, entrée, sortie)

GRU (Gated Recurrent Unit) :

- Version simplifiée du LSTM, souvent équivalente en performance

TRANSFORMER (ARCHITECTURE RÉVOLUTIONNAIRE)

Introduit en 2017 : "Attention is All You Need" (Vaswani et al.)

MÉCANISME D'ATTENTION

- Permet à chaque token de "regarder" tous les autres
- Calcul : $\text{Attention}(Q,K,V) = \text{softmax}(QK^T/\sqrt{d_k}) \times V$
- Multi-head : plusieurs têtes d'attention en parallèle

Applications :

- NLP : BERT, GPT, T5, LLaMA, Claude, Gemini
- Vision : ViT (Vision Transformer)
- Audio : Whisper
- Séries temporelles : Informer, Autoformer

AUTOENCODERS

Architecture : Encodeur → Espace latent → Décodeur

Usage :

- Compression de données
- Détection d'anomalies (erreur de reconstruction)
- Génération (VAE – Variational Autoencoder)
- Débruitage d'images (Denoising Autoencoder)

GAN – GENERATIVE ADVERSARIAL NETWORKS

Architecture : Générateur + Discriminateur en compétition

Usage : génération d'images réalistes, augmentation de données, deepfakes, super-résolution

Problèmes : instabilité d'entraînement, mode collapse

DIFFUSION MODELS

Modèle DALL-E, Stable Diffusion, Midjourney

Principe : apprendre à débruiter progressivement une image

Usage : génération d'images, vidéos, audio de très haute qualité

11.3 LARGE LANGUAGE MODELS (LLMs) ET IA GÉNÉRATIVE

LES LLMS EN 2024-2025

- GPT-4 / ChatGPT (OpenAI)
- Claude (Anthropic)
- Gemini (Google DeepMind)
- LLaMA 3, Mistral (open source)

CAPACITÉS CLÉS

- Compréhension et génération de texte de haute qualité
- Raisonnement en quelques étapes (chain-of-thought)
- Traduction, résumé, extraction d'information
- Génération de code
- Dialogue naturel multi-tour

PROMPT ENGINEERING

- Zero-shot : demander directement sans exemple

- Few-shot : fournir quelques exemples avant la question
- Chain-of-thought : "Raisonne étape par étape"
- Role prompting : "Tu es un expert en..."
- Structured output : "Réponds en JSON avec les champs..."

RAG (RETRIEVAL AUGMENTED GENERATION)

Architecture pour donner à un LLM accès à une base de connaissance.

1. Indexer des documents sous forme de vecteurs (embeddings)
2. À chaque question : chercher les documents les plus pertinents
3. Injecter ces documents dans le contexte du LLM
4. Le LLM répond en s'appuyant sur ces sources

Outils : LangChain, LlamaIndex, Chroma, Pinecone, Weaviate

FINE-TUNING

Adapter un LLM pré-entraîné à une tâche spécifique.

- Full fine-tuning : coûteux, tous les poids modifiés
- LoRA / QLoRA : fine-tuning efficace sur GPU modestes
- RLHF (Reinforcement Learning from Human Feedback) : alignement sur préférences humaines

APPLICATIONS DATA SCIENCE DES LLMs

- Génération automatique de requêtes SQL (Text-to-SQL)
- Analyse de documents non structurés à grande échelle
- Chatbots de support client avec données internes
- Extraction d'entités et de relations dans des textes
- Résumé automatique de rapports analytiques

PARTIE XII – ANALOGIE PALANTIR : LA DONNÉE COMME ARME

12.1 QU'EST-CE QUE PALANTIR ?

Palantir Technologies est la référence mondiale des plateformes data pour la défense et l'intelligence gouvernementale, puis pour l'industrie.

Fondée en 2003, financée initialement par la CIA (In-Q-Tel).
Clients : NSA, FBI, CIA, JSOC, ICE, NHS, Airbus, BP, Ferrari.

"Palantir ne fait pas de la business intelligence.
Elle fait de l'intelligence tout court."

PRODUITS PHARES

PALANTIR GOTHAM (Défense / Gouvernement)

- Fusion de données multi-sources (HUMINT, SIGINT, OSINT)
- Analyse de réseaux d'acteurs
- Ciblage et suivi d'individus/groupes
- Analyse géospatiale et temporelle
- Utilisé pour traquer des réseaux terroristes, cartels, fraude

PALANTIR FOUNDRY (Entreprise / Industrie)

- Plateforme de données unifiée pour grandes entreprises
- Ontologie des données : modélisation du monde réel en objets
- Pipelines de transformation visuels
- Applications no-code sur les données
- Utilisé par Airbus pour la supply chain, Ferrari pour la F1

PALANTIR AIP (IA Platform)

- LLMs et agents IA sur données propriétaires sécurisées
- Automatisation de workflows complexes
- Raisonnement IA avec données sensibles sans les exposer

12.2 CE QU'ON PEUT APPRENDRE DE PALANTIR

LEÇON 1 : L'ONTOLOGIE COMME FONDATION

Avant de construire des modèles, Palantir modélise le monde réel.
Une ontologie définit les OBJETS (personne, véhicule, lieu, événement)
et les RELATIONS entre eux (a conduit, était à, appartient à).

APPLICATION PRATIQUE :

Ne pas commencer par les tables de données – commencer par les entités métier.
Quels sont les objets de votre domaine ? Quelles sont leurs relations ?
Tout le reste découle de cette modélisation.

LEÇON 2 : FUSION DE SOURCES HÉTÉROGÈNES

La valeur de Palantir vient de sa capacité à connecter des sources qui ne parlent pas le même langage (bases différentes, formats différents, niveaux de qualité différents) et à en faire une vue cohérente.

APPLICATION PRATIQUE :

L'analyste data le plus précieux est celui qui sait faire parler des données qui ne se parlaient pas avant.
Investir dans les jointures, la réconciliation d'identités, la standardisation des référentiels.

LEÇON 3 : L'ANALYSE EXPLORATOIRE GUIDÉE PAR L'HUMAIN

Palantir ne remplace pas l'analyste. Il l'augmente.
L'analyste pose des questions, la plateforme l'aide à explorer.
Les hypothèses viennent de l'humain. Les preuves viennent des données.

APPLICATION PRATIQUE :

Un bon système data met l'humain en position de questionner plus rapidement, pas de le remplacer.
Interface utilisateur, UX, facilité d'exploration : aussi importants que les algorithmes sous-jacents.

LEÇON 4 : TRAÇABILITÉ ET CONFIANCE

Dans des contextes critiques (défense, médical, juridique), chaque décision doit être traçable. "Pourquoi ce résultat ?" doit avoir une réponse documentée.

APPLICATION PRATIQUE :

Lineage des données, explicabilité des modèles, logs d'audit.
XAI (Explainable AI) : SHAP values, LIME, arbres de décision.

12.3 CONSTRUIRE UN "MINI-PALANTIR" POUR VOTRE ORGANISATION

On n'a pas besoin de Palantir pour appliquer ses principes.
Voici une architecture open source équivalente pour PME et gouvernements :

COUCHE COLLECTE

- APIs, scraping, connecteurs ERP/CRM
- Kafka pour l'ingestion temps réel

COUCHE STOCKAGE

- PostgreSQL / TimescaleDB pour données structurées
- MinIO (S3-compatible) pour fichiers et données brutes
- Neo4j pour les graphes de relations

COUCHE TRANSFORMATION

- dbt pour transformations SQL documentées
- Airflow pour l'orchestration

COUCHE ANALYSE ET MODÉLISATION

- Python (Pandas, scikit-learn, NetworkX)
- JupyterHub pour les analystes

COUCHE VISUALISATION ET DÉCISION

- Apache Superset ou Metabase pour les dashboards
- Streamlit pour des applications custom
- Grafana pour le monitoring temps réel

COUCHE IA

- LangChain + modèle local (LLaMA, Mistral) pour RAG
- MLflow pour le tracking et déploiement des modèles

PARTIE XIII – DEVENIR UN SAAS DATA OU CRÉER SON ENTREPRISE

13.1 MODÈLES ÉCONOMIQUES AUTOUR DE LA DATA SCIENCE

Il existe plusieurs façons de monétiser l'expertise data.

MODÈLE 1 – CONSULTANT / FREELANCE

- Mission ponctuelle pour résoudre un problème précis
- Tarification : jour ou forfait projet
- Avantage : liberté, diversité des missions
- Inconvénient : instabilité, prospection permanente

MODÈLE 2 – CABINET DE CONSEIL (GCI-STYLE)

- Équipe de consultants sur plusieurs clients simultanément
- Offre packagée (audit data, stratégie, implémentation)
- Revenus récurrents via contrats de suivi/maintenance
- Avantage : levier, crédibilité, marque

MODÈLE 3 – SAAS DATA

- Logiciel en tant que service basé sur la data science
- Revenus récurrents (abonnement mensuel/annuel)
- Scalable : le coût marginal d'un client supplémentaire est faible
- Exemples : outil de prédiction de churn, dashboard sectoriel, scorecard de crédit, outil de prévision de demande

MODÈLE 4 – DATA PRODUCT

- Vente de données enrichies, de scores, d'indices
- Exemple : indice de risque par zone géographique, scoring crédit, données de benchmarking sectoriel
- Très scalable, forte barrière à l'entrée

MODÈLE 5 – PLATEFORME / MARKETPLACE

- Connecter producteurs et consommateurs de données
- Exemple : marketplace de modèles ML, échange de données B2B

13.2 CONSTRUIRE UN SAAS DATA : GUIDE TECHNIQUE

ÉTAPE 1 – IDENTIFIER LE PROBLÈME VERTICAL

Ne pas faire un "outil de data science générique".
Choisir un secteur précis et un problème précis.

Exemples africains à fort potentiel :

- Scoring crédit pour microfinance (données alternatives)
- Prédiction de rendement agricole (météo + satellite)
- Optimisation de tournées de livraison urbaine
- Détection de fraude pour mobile money
- Tableau de bord de santé pour cliniques

ÉTAPE 2 – VALIDER AVANT DE CONSTRUIRE (MVP)

- Parler à 10-20 clients potentiels AVANT de coder
- Comprendre leur douleur réelle, leur willingness to pay
- Simuler le produit avec Excel ou une démo Streamlit
- Obtenir une lettre d'intention ou un premier paiement

ÉTAPE 3 – ARCHITECTURE TECHNIQUE DU SAAS

BACKEND API

- Python FastAPI ou Django REST Framework
- Authentification JWT + gestion des rôles
- Base de données PostgreSQL
- Modèles ML sérialisés (joblib / ONNX)
- Celery + Redis pour les tâches asynchrones
- Docker + Docker Compose

FRONTEND

- React / Vue.js pour l'interface web
- Streamlit pour MVPs rapides
- Charts : Recharts, Chart.js, Plotly.js

INFRASTRUCTURE CLOUD

- AWS / GCP / Azure OU hébergement local souverain

- Nginx comme reverse proxy
- SSL avec Let's Encrypt
- Backups automatiques

MULTI-TENANCY (CLIENTS ISOLÉS)

- Approche 1 : base de données partagée avec tenant_id
- Approche 2 : schéma séparé par client dans PostgreSQL
- Approche 3 : base de données complètement séparée par client (plus coûteux, plus simple, plus sécurisé)

ÉTAPE 4 – MODÈLE DATA ET ML EN PRODUCTION

ARCHITECTURE TYPIQUE D'UN MODÈLE EN PRODUCTION :

```
[Données client] → [Pipeline ingestion]
                  → [Feature store]
                  → [Modèle ML (API)]
                  → [Score / prédiction]
                  → [Dashboard client]
                  → [Alerte si seuil dépassé]
```

BONNES PRATIQUES :

- Versionner les modèles (MLflow, DVC)
- Monitorer le drift (distribution des entrées change)
- Retraîner périodiquement sur nouvelles données
- Tests automatiques de non-régression avant déploiement

ÉTAPE 5 – ACQUISITION CLIENTS ET CROISSANCE

- Content marketing : articles, études de cas, LinkedIn
- Démonstration gratuite puis conversion payante
- Modèle freemium : fonctionnalités de base gratuites
- Partenariats avec associations professionnelles sectorielles
- Certification et formation sur l'outil (stickiness)

13.3 CONSTRUIRE UNE ÉQUIPE DATA

Les rôles d'une équipe data mature :

DATA ENGINEER

- Construire et maintenir les pipelines de données
- Technologies : SQL, Spark, Airflow, dbt, Kafka
- Le "plombier" de la data (indispensable)

DATA ANALYST

- Explorer, visualiser, rapporter
- Technologies : SQL, Excel, Power BI, Python de base
- Le "journaliste" de la data (proche du métier)

DATA SCIENTIST

- Modéliser, prédire, expliquer
- Technologies : Python, ML, statistiques
- Le "chercheur" de la data

ML ENGINEER / MLOps

- Déployer et maintenir les modèles en production
- Technologies : Docker, Kubernetes, MLflow, CI/CD
- Le "ingénieur" qui fait tourner la science

DATA PRODUCT MANAGER

- Définir la vision et la priorité des produits data
- Coordination entre technique et métier
- Le "stratège" de la data

POUR UNE STARTUP / PME (ressources limitées) :

Commencer avec 1 Data Analyst + 1 Data Scientist.
Le Data Engineer peut être partagé ou externalisé.
La priorité : créer de la valeur visible rapidement.

13.4 LES ERREURS À ÉVITER DANS UNE ENTREPRISE DATA

ERREUR 1 : COMMENCER PAR LA TECHNOLOGIE

- "On va implémenter Spark et une data lake avant de savoir quoi en faire."
- Solution : commencer par les questions métier, puis choisir la tech minimale.

ERREUR 2 : NÉGLIGER LA QUALITÉ DES DONNÉES

- Des dashboards beaux sur des données fausses = décisions fausses.
- Solution : investir dans la gouvernance dès le départ.

ERREUR 3 : LIVRER DES INSIGHTS SANS RECOMMANDATION

- "Voici ce qui se passe." sans "Voici ce qu'on doit faire."
- Solution : toujours terminer avec une action concrète.

ERREUR 4 : CONSTRUIRE POUR LES TECHNICIENS

- Tableaux de bord que seuls les data scientists comprennent.
- Solution : designer pour l'utilisateur final (décideur, opérateur).

ERREUR 5 : IGNORER LE CHANGEMENT ORGANISATIONNEL

- Les humains résistent aux outils qui remettent en question leurs habitudes.
- Solution : impliquer les utilisateurs dès la conception, former, accompagner.

ERREUR 6 : PROMETTRE LE IMPOSSIBLE

- "On va prédire X avec 99% de précision en 2 semaines."
- Solution : fixer des attentes réalistes, livrer par itérations.

ERREUR 7 : NE PAS MESURER L'IMPACT

- Savoir faire des modèles mais pas prouver leur valeur business.
- Solution : définir des KPIs d'impact AVANT de lancer tout projet.

CONCLUSION – LE MANIFESTE DU DATA SCIENTIST GCI

La data science n'est pas un métier de bureau. C'est une discipline de combat.

Un data scientist d'élite :

1. COMPREND le monde réel avant de plonger dans les données
2. POSE les bonnes questions plutôt que de répondre aux mauvaises
3. NETTOIE avec rigueur, parce qu'une donnée sale est une arme retournée
4. MODÉLISE avec parcimonie, préférant le simple qui marche au complexe qui impressionne
5. COMMUNIQUE avec clarté, pour que ses insights deviennent des décisions
6. DÉPLOIE en production, parce qu'un modèle sur un notebook ne vaut rien
7. MESURE l'impact, parce que la valeur créée est la seule vraie métrique
8. APPREND en continu, parce que le domaine évolue plus vite que tout autre
9. ÉTHIQUE toujours, parce que la puissance de la donnée implique la responsabilité
10. TRANSMET, parce que la vraie expertise se mesure à ce qu'on élève autour de soi

La donnée est la ressource la plus précieuse du XXI^e siècle.

Celui qui sait l'extraire, la comprendre et la traduire en action possède un avantage compétitif durable dans n'importe quel domaine : sciences, armée, industrie, commerce, gouvernance.

Ce cours n'est pas une fin. C'est un départ.

La vraie formation commence avec le premier projet réel, le premier échec, la première recommandation qui change une décision.

– GCI, Gykhamine Concept Investigation
Congo-Brazzaville

RESSOURCES RECOMMANDÉES POUR APPROFONDIR

LIVRES FONDAMENTAUX

- "Python for Data Analysis" – Wes McKinney (Pandas)
- "Hands-On Machine Learning" – Aurélien Géron (scikit-learn + TF)
- "The Elements of Statistical Learning" – Hastie, Tibshirani, Friedman
- "Designing Data-Intensive Applications" – Martin Kleppmann (architecture)
- "Storytelling with Data" – Cole Nussbaumer Knaflic (visualisation)
- "The Signal and the Noise" – Nate Silver (prévision)
- "Data Science for Business" – Provost & Fawcett (côté métier)

PLATEFORMES D'ENTRAÎNEMENT

- Kaggle.com : compétitions, datasets, notebooks gratuits
- fast.ai : Deep Learning de haut niveau, pédagogie excellence

- Coursera : Andrew Ng (ML), DeepLearning.AI
- DataCamp : parcours structurés Python/R
- LeetCode / HackerRank : SQL et algorithmes

RESSOURCES FRANCOPHONES

- OpenClassrooms : parcours data science complets en français
- DataScientest : formations certifiantes francophones
- Le blog de Machine Learnia (YouTube français)

VEILLE TECHNOLOGIQUE

- Papers With Code : recherches avec implémentations
- arXiv.org (cs.LG, stat.ML) : publications de recherche
- Towards Data Science (Medium) : articles praticiens
- The Batch (Andrew Ng) : newsletter hebdomadaire IA

=====

FIN DU COURS – GCI © 2024-2025 – TOUS DROITS RÉSERVÉS
Formation continue disponible via GCI – Congo-Brazzaville

=====