

TABLE DES MATIÈRES

PARTIE I	– LA DONNÉE EST UNE MATIÈRE PREMIÈRE
PARTIE II	– ARCHITECTURE DES DONNÉES : BÂTIR SON INFRASTRUCTURE
PARTIE III	– BASES DE DONNÉES : MAÎTRISER LES FONDATIONS
PARTIE IV	– SÉCURITÉ DES DONNÉES : PROTÉGER SON ACTIF
PARTIE V	– LOGISTIQUE & GOUVERNANCE DE LA DONNÉE
PARTIE VI	– PIPELINES : LA CHAÎNE D'APPROVISIONNEMENT DATA
PARTIE VII	– QUALITÉ, DETTE TECHNIQUE ET SOUVERAINETÉ
PARTIE VIII	– LA DATA SCIENCE COMME INSTRUMENT DE POUVOIR
PARTIE IX	– DEVENIR UN MAGICIEN AUX YEUX DE VOS CLIENTS
PARTIE X	– INFLUENCE, RÉPUTATION ET POSITIONNEMENT STRATÉGIQUE
PARTIE XI	– CRÉER DE LA DÉPENDANCE : L'ART DE DEVENIR INDISPENSABLE
PARTIE XII	– ÉTHIQUE DU POUVOIR PAR LA DONNÉE

PARTIE I – LA DONNÉE EST UNE MATIÈRE PREMIÈRE

=====

1.1 LE CHANGEMENT DE PARADIGME

Pendant des siècles, la richesse reposait sur des matières premières physiques : l'or, le pétrole, le bois, la terre agricole.
Aujourd'hui, une nouvelle ressource domine : la donnée.

Mais la donnée est une matière première paradoxale.

PROPRIÉTÉS UNIQUES DE LA DONNÉE :

- REPRODUCTIBLE sans coût marginal
 - Une tonne de pétrole partagée devient 500 kg chacun.
 - Une donnée partagée reste entière pour chacun.
- COMBINATOIRE à l'infini
 - Des données d'origine disparate, croisées, créent une valeur supérieure à la somme de leurs parties.
- PÉRISSABLE selon le contexte
 - La localisation d'un concurrent en temps réel vaut cher.
 - La même info vieille de 6 mois vaut zéro.
- ASYMÉTRIQUE dans sa valeur
 - La même donnée vaut 100 FCFA pour l'un et 100 millions pour l'autre selon sa position, son savoir-faire et son intention.
- EXTRACTIBLE en continu
 - Le pétrole s'épuise. La donnée se renouvelle à chaque transaction, chaque clic, chaque interaction humaine.

CONCLUSION :

Celui qui comprend la donnée comme une matière première commence à la traiter avec la même rigueur qu'un industriel traite son stock : acquisition, transformation, stockage, distribution, valorisation.

1.2 LA CHAÎNE DE VALEUR DE LA DONNÉE

Comme pour toute matière première, la donnée suit une chaîne de valeur :

- | | |
|--------------|--|
| [EXTRACTION] | → Collecter, capturer, acquérir la donnée brute |
| [TRANSPORT] | → Déplacer la donnée vers les systèmes de traitement |

[RAFFINAGE]	→ Nettoyer, normaliser, enrichir
[STOCKAGE]	→ Persister dans des structures adaptées à l'usage
[TRANSFORMATION]	→ Modéliser, agréger, calculer des indicateurs
[DISTRIBUTION]	→ Livrer les insights aux décideurs
[MONÉTISATION]	→ Convertir l'insight en valeur économique réelle

Un data scientist sans vision de chaîne de valeur est comme un raffineur qui ne sait pas d'où vient son brut ni où va son carburant. Il travaille dans le vide.

1.3 TYPOLOGIES DE DONNÉES

Connaître la nature de sa matière première est fondamental.

[A] PAR STRUCTURE

DONNÉES STRUCTURÉES

- Tables SQL, fichiers CSV, feuilles Excel
- Format fixe, schéma prédéfini
- Faciles à interroger, à agréger, à modéliser

DONNÉES SEMI-STRUCTURÉES

- JSON, XML, YAML, logs applicatifs
- Structure flexible, hiérarchique
- Requièrent parsing avant traitement standard

DONNÉES NON STRUCTURÉES

- Textes libres, images, vidéos, sons
- 80% des données du monde réel
- Requièrent NLP, Computer Vision, traitement spécialisé

[B] PAR TEMPORALITÉ

DONNÉES STATIQUES (snapshots)

- Capture à un instant T – état d'un stock, résultats d'enquête

DONNÉES TEMPORELLES (time-series)

- Séquences ordonnées dans le temps – ventes journalières, KPIs

DONNÉES TEMPS RÉEL (streaming)

- Flux continu – transactions, capteurs IoT, réseaux sociaux

[C] PAR ORIGINE

DONNÉES INTERNES	→ Produites par l'organisation elle-même
DONNÉES EXTERNES	→ Fournisseurs tiers, APIs, web scraping
DONNÉES PUBLIQUES	→ Open data, données gouvernementales
DONNÉES ACHETÉES	→ Panels, bases marketing, données enrichies

[D] PAR SENSIBILITÉ

DONNÉES PUBLIQUES	→ Accessibles à tous sans restriction
DONNÉES INTERNES	→ Confidentielles mais non réglementées
DONNÉES SENSIBLES	→ Personnelles, financières (réglementées)
DONNÉES CRITIQUES	→ Stratégiques, à protéger absolument

PARTIE II – ARCHITECTURE DES DONNÉES : BÂTIR SON INFRASTRUCTURE

2.1 POURQUOI L'ARCHITECTURE COMPTE PLUS QUE L'ALGORITHME

90% des data scientists débutants passent leur temps sur les modèles.
90% des problèmes en production sont des problèmes d'architecture.

Un modèle brillant sur une infrastructure fragile produit :

- Des résultats impossibles à reproduire
- Des pipelines qui cassent sans préavis
- Des données corrompues silencieusement
- Une maintenance cauchemardesque

L'architecture, c'est la différence entre un atelier artisanal et une usine.

PRINCIPE FONDATEUR :

"Les données doivent circuler avec la fiabilité d'un réseau électrique.
L'utilisateur ne voit pas l'infrastructure – il voit la lumière."

2.2 LES COUCHES DE L'ARCHITECTURE DATA MODERNE

Une architecture data robuste s'organise en couches distinctes :

COUCHE 1 – INGESTION (Sources → Système)

Rôle : capturer la donnée depuis toutes les sources

Outils : Apache Kafka, Apache NiFi, Airbyte, Fivetran, scripts Python

Méthodes :

- BATCH : collecte périodique (toutes les heures, chaque nuit)
- STREAMING : collecte continue en flux temps réel
- CDC (Change Data Capture) : capture les modifications en base

Règles d'or :

- Ne jamais transformer en ingestion (ingérer brut, transformer après)
- Tout enregistrer avec timestamp d'arrivée
- Prévoir la reprise sur erreur (idempotence)

COUCHE 2 – STOCKAGE BRUT (Raw Layer / Data Lake)

Rôle : conserver la donnée originale, non modifiée

Technologies : Amazon S3, Google Cloud Storage, HDFS, MinIO (auto-hébergé)

Formats : Parquet, ORC (colonnaires), CSV, JSON selon la source

RÈGLE ABSOLUE :

- La donnée brute ne doit JAMAIS être modifiée après ingestion.
On copie, on transforme, on dérive – on ne touche jamais la source.

COUCHE 3 – TRANSFORMATION (Processing Layer)

Rôle : nettoyer, normaliser, enrichir, agréger

Approches :

- ELT (Extract-Load-Transform) : transformation dans l'entrepôt
- ETL (Extract-Transform-Load) : transformation avant stockage final

Outils : dbt, Apache Spark, Pandas, SQL, Polars

COUCHE 4 – STOCKAGE ANALYTIQUE (Data Warehouse)

Rôle : servir les requêtes analytiques complexes rapidement

Technologies :

- Cloud : BigQuery, Snowflake, Redshift, Databricks
- On-premise : PostgreSQL, DuckDB, ClickHouse
- Léger : SQLite (pour prototypage), DuckDB (pour analyses locales)

COUCHE 5 – CONSOMMATION (Serving Layer)

Rôle : exposer les données aux utilisateurs finaux

Formes : dashboards, APIs REST, rapports PDF, alertes automatiques,
modèles ML en production

2.3 PATTERNS D'ARCHITECTURE COURANTS

LAMBDA ARCHITECTURE

- Deux chemins parallèles : batch (précis, lent) + streaming (rapide, approximatif)
- Avantage : tolérance aux pannes, richesse analytique
- Inconvénient : complexité de maintien de deux systèmes

KAPPA ARCHITECTURE

- Un seul chemin streaming, le batch est simulé par relecture

- Avantage : simplicité opérationnelle
- Inconvénient : rejouer du volume massif peut être coûteux

DATA MESH (Architecture distribuée)

- Chaque équipe métier est responsable de ses propres données
- Avantage : autonomie, scalabilité organisationnelle
- Inconvénient : cohérence inter-domaines difficile à maintenir

DATA LAKEHOUSE

- Fusion data lake (flexibilité) + data warehouse (performance ACID)
- Technologies : Apache Iceberg, Delta Lake, Apache Hudi
- Avantage : le meilleur des deux mondes

POUR UNE PME OU CONSULTANT INDÉPENDANT :

- PostgreSQL + dbt + Metabase = infrastructure complète à coût zéro
- DuckDB pour les analyses locales lourdes sans serveur
- Ce stack couvre 95% des besoins réels en Afrique subsaharienne

2.4 LE SCHÉMA DE DONNÉES : STAR SCHEMA ET SNOWFLAKE

Pour les entrepôts analytiques, deux modèles dominant :

STAR SCHEMA (Schéma en étoile)

- Une table de faits centrale (transactions, ventes, événements)
- Plusieurs tables de dimensions autour (client, produit, date, lieu)
- Requêtes simples, performantes, lisibles

Exemple :

```
FAITS_VENTES : id_vente, id_client, id_produit, id_date, montant, quantité
DIM_CLIENT   : id_client, nom, ville, segment
DIM_PRODUIT  : id_produit, nom, catégorie, prix_unitaire
DIM_DATE     : id_date, jour, mois, trimestre, année
```

SNOWFLAKE SCHEMA

- Dimensions elles-mêmes normalisées en sous-dimensions
- Avantage : moins de redondance
- Inconvénient : requêtes plus complexes, jointures supplémentaires

RÈGLE PRATIQUE :

- Star schema pour les dashboards et rapports (vitesse de lecture)
- Snowflake pour les systèmes à fort volume avec contraintes de stockage

PARTIE III – BASES DE DONNÉES : MAÎTRISER LES FONDATIONS

3.1 LA TAXONOMIE DES SYSTÈMES DE STOCKAGE

Il n'existe pas une "base de données". Il existe des familles d'outils, chacune optimisée pour un type de problème.

BASES RELATIONNELLES (SGBDR)

Principes : tables, lignes, colonnes, clés étrangères, SQL
 ACID garantis : Atomicité, Cohérence, Isolation, Durabilité
 Cas d'usage : transactions financières, gestion opérationnelle, systèmes métier, applications web

Exemples : PostgreSQL, MySQL, SQLite, Oracle, SQL Server

FORCES :

- Intégrité référentielle forte
- Requêtes complexes avec jointures multiples
- Standard universel (SQL)

FAIBLESSES :

- Schéma rigide (migration coûteuse)
- Scalabilité horizontale difficile
- Performances dégradées sur très grands volumes non structurés

BASES NOSQL

Familles et cas d'usage :

DOCUMENTS (MongoDB, CouchDB, Firestore)

- Stocke des documents JSON avec schéma flexible
- Idéal : catalogues produits, profils utilisateurs, contenu variable

CLÉ-VALEUR (Redis, DynamoDB, Memcached)

- Structure la plus simple : une clé → une valeur
- Idéal : cache, sessions, files d'attente, compteurs temps réel

COLONNES (Apache Cassandra, HBase, ClickHouse)

- Optimisé pour les lectures/écritures sur colonnes massives
- Idéal : données IoT, séries temporelles, analytics haute fréquence

GRAPHES (Neo4j, Amazon Neptune, ArangoDB)

- Nœuds et relations comme entités de premier niveau
- Idéal : réseaux sociaux, détection de fraude, recommandations

SÉRIES TEMPORELLES (InfluxDB, TimescaleDB, QuestDB)

- Optimisé pour les données horodatées en flux
- Idéal : métriques serveur, capteurs, données financières

VECTORIELLES (Pinecone, Weaviate, pgvector)

- Stocke des vecteurs d'embeddings pour recherche sémantique
- Idéal : moteurs de recherche IA, systèmes de recommandation

3.2 PRINCIPES AVANCÉS DES BASES RELATIONNELLES

NORMALISATION

Objectif : éliminer la redondance, garantir la cohérence

1NF : chaque cellule contient une valeur atomique (pas de listes)

2NF : pas de dépendance partielle à la clé primaire

3NF : pas de dépendance transitive entre attributs non-clé

RÈGLE PRATIQUE :

- 3NF pour les bases transactionnelles (données opérationnelles)
- Dénormaliser délibérément pour les bases analytiques (performance)

INDEXATION

Un index est à une table ce qu'un sommaire est à un livre.

Sans index sur une table de 10 millions de lignes : scan complet.

Avec index : accès direct en millisecondes.

Types d'index :

- B-TREE : index standard, équilibré, pour la plupart des requêtes
- HASH : ultra-rapide pour les égalités strictes
- GIN/GiST : pour les types complexes (JSON, full-text, géospatial)
- BRIN : pour les très grandes tables avec données ordonnées

PIÈGES D'INDEXATION :

- Trop d'index ralentit les écritures (chaque INSERT/UPDATE reindexe)
- Index inutilisés consomment de l'espace
- L'index ne sert que si la requête l'utilise (EXPLAIN ANALYZE)

TRANSACTIONS ET ISOLATION

Une transaction regroupe plusieurs opérations en une unité atomique.

BEGIN;

UPDATE comptes SET solde = solde - 10000 WHERE id = 1;

UPDATE comptes SET solde = solde + 10000 WHERE id = 2;

COMMIT;

Si une opération échoue → ROLLBACK automatique.

Sans transaction → état incohérent possible (argent débit sans crédit).

NIVEAUX D'ISOLATION (du plus permissif au plus strict) :

READ UNCOMMITTED → lecture de données non validées (dirty reads)
READ COMMITTED → lecture uniquement des données validées (défaut PG)
REPEATABLE READ → même requête donne même résultat dans la transaction
SERIALIZABLE → isolation complète, comme si exécution séquentielle

3.3 OPTIMISATION SQL : REQUÊTES QUI TUENT VS REQUÊTES QUI VOLENT

LIRE UN PLAN D'EXÉCUTION

```
EXPLAIN ANALYZE SELECT * FROM ventes WHERE client_id = 42;
```

Interpréter :

- "Seq Scan" sur grande table = problème (pas d'index utilisé)
- "Index Scan" = bon
- "Nested Loop" sur millions de lignes = dangereux
- "Hash Join" = efficace pour les grandes jointures

ANTIPATTERNS SQL À ÉVITER

SELECT * au lieu de colonnes nommées

- Transfère toutes les colonnes, même inutiles
- Empêche l'optimiseur d'utiliser des index couvrants

Fonctions dans WHERE sur colonnes indexées

- WHERE YEAR(date_vente) = 2024 ← MAUVAIS (désactive l'index)
- WHERE date_vente >= '2024-01-01' AND date_vente < '2025-01-01' ← BON

Sous-requêtes corrélées dans SELECT

- Exécutées une fois par ligne, catastrophique sur gros volumes
- Réécrire en JOIN ou CTE (WITH)

NOT IN avec sous-requête

- Comportement inattendu avec NULL, lent
- Préférer NOT EXISTS ou LEFT JOIN ... WHERE IS NULL

REQUÊTES AVANCÉES UTILES

CTEs (Common Table Expressions) :

```
WITH clients_actifs AS (  
    SELECT id FROM clients WHERE derniere_commande > NOW() - INTERVAL '90 days'  
)  
SELECT p.nom, SUM(v.montant)  
FROM ventes v  
JOIN clients_actifs ca ON v.client_id = ca.id  
JOIN produits p ON v.produit_id = p.id  
GROUP BY p.nom  
ORDER BY 2 DESC;
```

WINDOW FUNCTIONS (fonctions de fenêtrage) :

```
SELECT  
    client_id,  
    date_vente,  
    montant,  
    SUM(montant) OVER (PARTITION BY client_id ORDER BY date_vente) AS cumul_client,  
    RANK() OVER (PARTITION BY mois ORDER BY montant DESC) AS rang_mensuel  
FROM ventes;
```

- Les window functions sont parmi les outils les plus puissants du SQL analytique. Elles permettent des calculs de rang, cumul, moyenne mobile, décalage temporel sans GROUP BY (donc sans perdre le détail ligne à ligne).

PARTIE IV – SÉCURITÉ DES DONNÉES : PROTÉGER SON ACTIF

4.1 POURQUOI LA SÉCURITÉ EST UN SUJET DE DATA SCIENTIST

La donnée est un actif. Un actif non protégé est une invitation au vol.
En tant que data scientist ou consultant, vous manipulez des données

appartenant à vos clients. Leur sécurité est votre responsabilité directe.

RISQUES CONCRETS EN CONTEXTE AFRICAIN :

- Absence de politique de backup → perte irrémédiable après incident
- Accès partagés sur des comptes uniques → impossibilité d'audit
- Données clients envoyées par WhatsApp / email non chiffré
- Serveurs locaux sans pare-feu ni mise à jour
- Mots de passe partagés dans des fichiers Excel non protégés

LA RÈGLE D'OR :

"Vous n'avez pas besoin d'une attaque sophistiquée pour perdre vos données.
La négligence suffit."

4.2 LES PILIERS DE LA SÉCURITÉ : CIA TRIAD

Toute politique de sécurité repose sur trois propriétés fondamentales :

[C] CONFIDENTIALITÉ

- Seules les personnes autorisées accèdent à la donnée
- Mécanismes : chiffrement, contrôle d'accès, authentification forte

[I] INTÉGRITÉ

- La donnée n'est pas altérée de manière non autorisée
- Mécanismes : checksums, signatures numériques, journaux d'audit, contraintes base de données

[A] DISPONIBILITÉ

- La donnée est accessible quand on en a besoin
- Mécanismes : redondance, backups, plans de reprise d'activité (PRA), monitoring d'infrastructure

4.3 CONTRÔLE D'ACCÈS : QUI VOIT QUOI

PRINCIPE DU MOINDRE PRIVILÈGE

Chaque utilisateur ou système ne reçoit que les permissions strictement nécessaires à sa fonction – pas plus.

Exemple appliqué en base de données :

```
-- Compte pour lecture seule (reporting)
CREATE USER analyste_lecture WITH PASSWORD '...';
GRANT SELECT ON ALL TABLES IN SCHEMA public TO analyste_lecture;

-- Compte pour l'application web
CREATE USER app_backend WITH PASSWORD '...';
GRANT SELECT, INSERT, UPDATE ON TABLE commandes TO app_backend;
GRANT SELECT ON TABLE produits TO app_backend;

-- Jamais : GRANT ALL PRIVILEGES TO app_backend;
```

MODÈLES DE CONTRÔLE D'ACCÈS :

RBAC (Role-Based Access Control)

- Les permissions sont assignées à des rôles (admin, analyste, lecteur)
- Les utilisateurs reçoivent des rôles, pas des permissions directes
- Standard le plus courant, simple à gérer

ABAC (Attribute-Based Access Control)

- Les accès dépendent d'attributs (heure, localisation, niveau, contexte)
- Plus flexible mais plus complexe à implémenter

Row-Level Security (RLS) en SQL

- Chaque utilisateur ne voit que ses propres lignes
- Exemple : un commercial ne voit que ses propres clients

```
CREATE POLICY vision_commerciaux
ON clients
USING (commercial_id = current_user_id());
```

4.4 CHIFFREMENT : PROTÉGER LA DONNÉE EN MOUVEMENT ET AU REPOS

CHIFFREMENT EN TRANSIT (données qui voyagent)

- Toute communication réseau doit utiliser TLS/SSL
- Ne jamais accepter de connexions HTTP non chiffrées pour des données
- Certificats à renouveler (Let's Encrypt pour le gratuit)

CHIFFREMENT AU REPOS (données stockées)

- Chiffrement au niveau disque (LUKS sur Linux, FileVault sur Mac)
- Chiffrement au niveau base de données (pgcrypto sur PostgreSQL)
- Chiffrement applicatif : chiffrer avant d'écrire en base

HACHAGE (pour les mots de passe)

- JAMAIS stocker un mot de passe en clair
- JAMAIS utiliser MD5 ou SHA1 pour les mots de passe (cassables)
- TOUJOURS utiliser bcrypt, argon2, ou scrypt

```
import bcrypt
hashed = bcrypt.hashpw(password.encode(), bcrypt.gensalt(rounds=12))
```

ANONYMISATION ET PSEUDONYMISATION

Pour les données personnelles avant utilisation analytique :

ANONYMISATION : suppression irréversible des identifiants

- Nom → supprimé ou remplacé par token aléatoire
- Impossible de retrouver l'identité originale

PSEUDONYMISATION : remplacement réversible par un pseudonyme

- Nom → ID_client_74829 (la correspondance est stockée séparément)
- Permet les analyses sans exposer les données personnelles brutes

4.5 STRATÉGIE DE BACKUP : LA RÈGLE 3-2-1

La règle 3-2-1 est le standard minimum de tout professionnel sérieux :

- 3 copies des données
- 2 supports différents (ex : disque local + cloud)
- 1 copie hors site (géographiquement séparée)

AUTOMATISATION DES BACKUPS POSTGRESQL :

```
# Backup quotidien avec pg_dump
pg_dump -U postgres -Fc nom_base > backup_$(date +%Y%m%d).dump
```

```
# Restauration
pg_restore -U postgres -d nom_base backup_20250115.dump
```

RÈGLES DE BACKUP :

- Tester la restauration régulièrement (un backup non testé n'existe pas)
- Versionner les backups (garder 7 jours minimum)
- Chiffrer les backups avant de les envoyer hors site
- Automatiser et monitorer les échecs

4.6 AUDIT ET TRAÇABILITÉ

JOURNALISATION DES ACCÈS

Tout accès aux données sensibles doit être enregistré :

- Qui a accédé ? (identifiant utilisateur)
- Quand ? (timestamp)
- Depuis où ? (adresse IP)
- Quelle action ? (SELECT, UPDATE, DELETE)
- Sur quoi ? (table, enregistrement)

En PostgreSQL, activer pgaudit pour une journalisation fine.
En applicatif, enregistrer dans une table d'audit immuable.

DÉTECTION D'ANOMALIES

Surveiller :

- Volumes inhabituels de requêtes (exfiltration potentielle)
- Accès à des heures atypiques
- Tentatives de connexion échouées en série (brute force)
- Requête sur des colonnes jamais accédées normalement

PARTIE V – LOGISTIQUE & GOUVERNANCE DE LA DONNÉE

5.1 LA GOUVERNANCE : LE DROIT ET L'ORDRE DE LA DONNÉE

La gouvernance des données, c'est l'ensemble des politiques, processus et responsabilités qui régissent la donnée dans une organisation.

Sans gouvernance :

- Personne ne sait quelle version des données est la "bonne"
- Les mêmes termes signifient des choses différentes selon les équipes
- Les décisions sont prises sur des données différentes
- La responsabilité en cas d'erreur est floue

COMPOSANTES DE LA GOUVERNANCE :

[1] DATA OWNERSHIP

- Chaque jeu de données a un propriétaire responsable de sa qualité
- Le propriétaire approuve les modifications de schéma
- Le propriétaire définit qui y accède

[2] DATA CATALOG

- Inventaire documenté de toutes les données disponibles
- Métadonnées : source, format, fraîcheur, propriétaire, usage autorisé
- Outils : Apache Atlas, DataHub, Amundsen, ou simple wiki interne

[3] DATA LINEAGE (Lignage)

- Tracer l'origine et les transformations de chaque donnée
- "Cette colonne chiffreaffaires provient de quelle source ?"
- Permet le débogage, l'audit, la confiance dans les chiffres

[4] GLOSSAIRE MÉTIER

- Définitions communes pour tous les termes critiques
- "Client actif" : quelqu'un ayant acheté dans les 90 derniers jours
- Sans glossaire, chaque équipe calcule ses propres métriques
 - résultats contradictoires, perte de confiance

5.2 GESTION DU CYCLE DE VIE DE LA DONNÉE

Comme toute matière première, la donnée a un cycle de vie à gérer :

CRÉATION / ACQUISITION

- Définir les règles de validation dès la saisie
- Documenter la source, la fréquence, le format attendu

UTILISATION ACTIVE

- Données fréquemment accédées → stockage rapide et accessible
- Optimiser les index et partitions pour les requêtes courantes

ARCHIVAGE

- Données anciennes peu consultées → stockage froid moins coûteux
- Maintenir l'accessibilité mais sans performance prioritaire

SUPPRESSION

- Définir des durées de rétention légales et métier
- Procédures de suppression sécurisée (GDPR, RGPD et équivalents locaux)
- Ne jamais supprimer sans validation du propriétaire des données

TABLEAU DE RÉTENTION TYPE :

Données transactions financières : 10 ans (légal)

Données RH (salariés)	: 5 ans après départ
Données clients actifs	: durée de la relation + 3 ans
Logs techniques	: 1 à 3 ans selon sensibilité
Données anonymisées pour analyse	: illimitées (plus de PII)
Données marketing prospects	: 3 ans sans interaction

5.3 QUALITÉ DES DONNÉES : MESURER POUR AMÉLIORER

LES 6 DIMENSIONS DE LA QUALITÉ

COMPLÉTUDE	→ Les champs obligatoires sont-ils renseignés ? Taux de remplissage par colonne
EXACTITUDE	→ Les valeurs correspondent-elles à la réalité ? Vérification vs sources de référence
COHÉRENCE	→ Les données sont-elles cohérentes entre systèmes ? Même client dans 2 bases = mêmes informations ?
FRAÎCHEUR	→ Les données sont-elles à jour ? Délai entre événement réel et enregistrement
UNICITÉ	→ Pas de doublons non intentionnels Mêmes entités enregistrées plusieurs fois
VALIDITÉ	→ Les valeurs respectent le format et les règles métier ? Email valide, date dans le passé, montant positif

TABLEAU DE BORD QUALITÉ :

Pour chaque jeu de données critique, calculer hebdomadairement :

```
score_completude = nb_lignes_sans_null / nb_total_lignes * 100
score_unicity     = (1 - nb_doublons / nb_total_lignes) * 100
score_validite    = nb_lignes_valides / nb_total_lignes * 100
score_global      = moyenne(scores) - pénalités_critiques
```

→ Objectif : score_global > 95% pour les données en production

PARTIE VI – PIPELINES : LA CHAÎNE D'APPROVISIONNEMENT DATA

6.1 QU'EST-CE QU'UN PIPELINE DATA ?

Un pipeline data est une séquence automatisée d'opérations qui transforment la donnée d'un état A vers un état B de manière fiable et répétable.

ANALOGIE INDUSTRIELLE :

Un pipeline data est à la donnée ce qu'une chaîne de montage est à l'automobile.
Chaque étape a une entrée définie, une transformation précise, une sortie vérifiable.

PROPRIÉTÉS D'UN BON PIPELINE :

REPRODUCTIBLE	→ Les mêmes inputs donnent toujours les mêmes outputs
IDEMPOTENT	→ L'exécuter N fois produit le même résultat qu'une fois
OBSERVABLE	→ On sait à tout moment où en est l'exécution
RÉSILIENT	→ Il gère les erreurs, les reprises, les timeouts
VERSIONNÉ	→ Le code du pipeline est sous contrôle de version (Git)
TESTÉ	→ Des tests automatiques valident les transformations

6.2 ORCHESTRATION : DIRIGER L'ORCHESTRE DATA

L'orchestration, c'est la coordination de l'exécution des pipelines :
qui s'exécute, dans quel ordre, avec quelles dépendances, en cas d'échec.

APACHE AIRFLOW

Standard de l'industrie. Un DAG (Directed Acyclic Graph) définit les dépendances entre tâches.

```
from airflow import DAG
from airflow.operators.python import PythonOperator
from datetime import datetime
```

```
def extraire(): pass # logique d'extraction
def transformer(): pass # logique de transformation
def charger(): pass # logique de chargement

with DAG('pipeline_ventes', schedule_interval='@daily',
        start_date=datetime(2025,1,1)) as dag:
    t1 = PythonOperator(task_id='extraire', python_callable=extraire)
    t2 = PythonOperator(task_id='transformer',python_callable=transformer)
    t3 = PythonOperator(task_id='charger', python_callable=charger)
    t1 >> t2 >> t3
```

ALTERNATIVES LÉGÈRES :

- Prefect : plus Pythonique qu'Airflow, meilleure UX
- Dagster : orienté données et assets, meilleure observabilité
- Cron + make : pour des pipelines simples sans dépendances complexes

6.3 dbt : LE STANDARD DE LA TRANSFORMATION SQL

dbt (data build tool) a révolutionné la transformation de données en SQL.

PRINCIPES dbt :

- Chaque transformation est un fichier SQL SELECT
- dbt gère les dépendances et l'ordre d'exécution
- Tests de qualité déclaratifs (not null, unique, accepted values)
- Documentation auto-générée depuis le code
- Versioning Git natif

Exemple de modèle dbt :

```
-- models/marts/ventes_mensuelles.sql
WITH ventes_brutes AS (
    SELECT * FROM {{ ref('stg_ventes') }}
),
agregees AS (
    SELECT
        DATE_TRUNC('month', date_vente) AS mois,
        produit_id,
        SUM(montant) AS ca_mensuel,
        COUNT(*) AS nb_commandes
    FROM ventes_brutes
    GROUP BY 1, 2
)
SELECT * FROM agregees
```

Exemple de test dbt :

```
-- models/marts/schema.yml
models:
  - name: ventes_mensuelles
    columns:
      - name: mois
        tests:
          - not_null
      - name: ca_mensuel
        tests:
          - not_null
          - dbt_utils.expression_is_true:
              expression: "> 0"
```

PARTIE VII – QUALITÉ, DETTE TECHNIQUE ET SOUVERAINETÉ

7.1 LA DETTE TECHNIQUE DATA : LE CANCER LENT

La dette technique, c'est le coût futur des raccourcis pris aujourd'hui.

FORMES DE DETTE TECHNIQUE EN DATA :

- Scripts Python sans structure, sans tests, sans documentation
- Données transformées sans audit trail (on ne sait plus d'où vient un chiffre)
- Colonnes renommées sans communication → downstream brisé
- Schémas de base jamais migrés proprement

- Pipelines dupliqués faute de refactorisation
- Credentials en clair dans les scripts versionnés

SYMPTÔMES :

- "On ne peut plus toucher ce pipeline, personne ne sait comment ça marche"
- "Les chiffres de l'équipe A et de l'équipe B ne s'accordent jamais"
- "Il faut 3 semaines pour ajouter une colonne"

REMÈDES :

- Refactoriser régulièrement (ne pas attendre la crise)
- Tests automatisés dès le départ
- Documentation as code (dbt, notebooks commentés)
- Code review sur les pipelines comme sur le code applicatif

7.2 SOUVERAINETÉ DES DONNÉES : ENJEU STRATÉGIQUE

La souveraineté des données, c'est la capacité d'une organisation (ou d'un pays) à contrôler ses propres données.

POUR UNE ENTREPRISE :

- Connaître où sont ses données (inventaire complet)
- Savoir qui y accède (contrôle d'accès documenté)
- Pouvoir les migrer si le fournisseur cloud disparaît (portabilité)
- Ne pas dépendre d'un seul outil propriétaire (vendor lock-in)

POUR UN CONSULTANT GCI :

- Ne jamais stocker les données client sur vos serveurs personnels
- Livrer les données sous des formats ouverts (CSV, Parquet, SQL dump)
- Documenter les transformations pour que le client puisse reprendre
- Proposer des solutions hébergeables localement (pas seulement cloud)

ENJEUX POUR L'AFRIQUE :

- Les données africaines hébergées uniquement en Europe/USA sont soumises à des juridictions étrangères
- Opportunité : infrastructures locales de données (data centers en Afrique, solutions open source auto-hébergées)
- La souveraineté numérique est un enjeu géopolitique majeur

PARTIE VIII – LA DATA SCIENCE COMME INSTRUMENT DE POUVOIR

8.1 LA DONNÉE COMME ASYMÉTRIE INFORMATIONNELLE

Dans toute négociation, dans tout marché, dans toute compétition : celui qui dispose d'une information que l'autre n'a pas est en position de force.

LA DONNÉE CRÉE TROIS FORMES DE POUVOIR :

[1] POUVOIR PRÉDICTIF

- Savoir ce qui va se passer avant que ça n'arrive
- Exemple : prévoir la rupture de stock d'un concurrent
- Exemple : identifier les clients qui vont partir avant qu'ils partent

[2] POUVOIR INTERPRÉTATIF

- Donner un sens à ce qui se passe quand les autres ne comprennent pas
- Exemple : expliquer pourquoi les ventes ont chuté
- Exemple : identifier la cause racine d'un problème opérationnel

[3] POUVOIR DÉCISIONNEL

- Prendre des décisions meilleures et plus rapides
- Exemple : optimiser un budget marketing avec une précision impossible autrement
- Exemple : identifier le meilleur moment pour lancer un produit

CITATION STRATÉGIQUE :

"L'information est le pétrole du XXI^e siècle, et l'analytique est le moteur à combustion." – Peter Sondergaard, Gartner

8.2 COMMENT LES ORGANISATIONS UTILISENT LA DATA POUR DOMINER

MODÈLE AMAZON

Amazon n'est pas une entreprise logistique. C'est une machine à données.

- Chaque clic, chaque achat, chaque temps de pause sur une page est capturé
- Des modèles prédisent ce que vous allez acheter avant que vous le sachiez
- Les prix changent des millions de fois par jour selon la demande en temps réel
- Les stocks sont pré-positionnés géographiquement en anticipant les commandes

MODÈLE NETFLIX

- 75% du contenu regardé provient de recommandations algorithmiques
- Les miniatures des films/séries sont personnalisées par utilisateur
- Les décisions de production (quel film tourner) sont guidées par les données

MODÈLE MPESA (FINTECH AFRICAINE)

- Les données de transactions permettent de calculer un score de crédit pour des millions de personnes sans historique bancaire traditionnel
- La donnée comportementale remplace le collatéral physique
- C'est de la data science appliquée à l'inclusion financière

MODÈLE POLITIQUE (Cambridge Analytica / micro-targeting)

- Données comportementales → profilage psychologique → messages ciblés
- Chaque électeur reçoit un message différent selon ses angoisses profondes
- La donnée comme instrument de persuasion à grande échelle

LEÇON POUR LE CONSULTANT DATA :

Ces organisations ont transformé la donnée en avantage compétitif durable.
Votre rôle est d'apporter cette capacité à vos clients.

8.3 LE RENSEIGNEMENT ÉCONOMIQUE PAR LA DATA

La veille concurrentielle par la donnée est une discipline à part entière.

SOURCES DE DONNÉES PUBLIQUES EXPLOITABLES :

DONNÉES FINANCIÈRES

- Rapports annuels (documents publics pour les sociétés cotées)
- Bilans déposés au registre de commerce
- Prix pratiqués (web scraping des sites concurrents)

DONNÉES OPÉRATIONNELLES PUBLIQUES

- Offres d'emploi publiées → révèlent les orientations stratégiques
Un concurrent qui recrute massivement en ML → pivot technologique
- Brevets déposés → axes d'innovation
- Contrats publics (marchés publics) → clients et volumes

DONNÉES NUMÉRIQUES

- Trafic web (SimilarWeb, Semrush) → popularité des concurrents
- Avis clients (Google, Trustpilot) → forces et faiblesses perçues
- Réseaux sociaux → sentiment, engagement, croissance de communauté

DONNÉES SECTORIELLES

- Associations professionnelles, fédérations
- Études de marché publiées
- Données douanières d'import/export (pour le commerce international)

CONSTRUCTION D'UN TABLEAU DE BORD CONCURRENTIEL :

Pour chaque concurrent clé, suivre mensuellement :

- Trafic web estimé (tendance)
- Prix moyen par catégorie (si applicable)
- Note client et évolution
- Actualité (nouveaux produits, partenariats, levées de fonds)
- Recrutements actifs

- Ce tableau est une arme de conseil que 95% des PME n'ont pas.
Vous leur apportez une capacité de renseignement d'entreprise.

PARTIE IX – DEVENIR UN MAGICIEN AUX YEUX DE VOS CLIENTS

9.1 LA PSYCHOLOGIE DE L'EFFET MAGIQUE

Un tour de magie produit son effet parce que le spectateur ne voit pas le mécanisme. La connaissance dissout la magie.

La data science produit un effet similaire sur les non-initiés. Votre travail – invisible dans sa mécanique, visible dans ses résultats – crée un sentiment de stupéfaction.

CE QUI CRÉE L'EFFET "MAGICIEN" :

- [1] PRÉDIRE AVANT QUE ÇA N'ARRIVE
 - "Comment avez-vous su que ce client allait partir ?"
 - Vous ne devenez pas magicien. Vous devenez celui qu'on écoute avant de décider.
- [2] EXPLIQUER CE QUE PERSONNE NE COMPRENAIT
 - "Nos ventes baissent depuis 6 mois et personne ne sait pourquoi."
 - Vous arrivez avec les données. Vous identifiez la cause en 3 heures.
 - C'est de la magie pour celui qui cherchait depuis 6 mois.
- [3] QUANTIFIER L'INTUITION
 - "On pensait que le produit X ne marchait pas bien."
 - Vous montrez que X génère 34% de la marge alors qu'il représente 8% du CA.
 - La décision change immédiatement.
- [4] RÉVÉLER CE QUI EST INVISIBLE À L'ŒIL NU
 - Un tableau de 50 000 lignes, personne ne le lit.
 - Une visualisation bien construite révèle une anomalie en 10 secondes.
 - Voir ce que les autres ne peuvent pas voir = pouvoir.

9.2 LES ANALYSES QUI PRODUISENT LE PLUS D'IMPACT IMMÉDIAT

Certaines analyses ont un rapport impact/effort très favorable. Ce sont ces analyses qu'il faut maîtriser et sortir en premier.

ANALYSE PARETO (80/20)

- 20% des produits font 80% du CA
 - 20% des clients font 80% des achats
 - 20% des problèmes causent 80% des pertes
- Impact : immédiat. Tout décideur comprend instinctivement.
Temps : 30 minutes avec un fichier ventes basique.

ANALYSE DE COHORTE

- Comparer le comportement de groupes de clients selon leur date d'acquisition
 - Révèle si les clients récents sont moins fidèles que les anciens
 - Mesure l'efficacité des actions de rétention
- Impact : révélateur pour les SaaS, abonnements, commerce de répétition.

ANALYSE RFM (Récence, Fréquence, Montant)

- Segmentation clients en 3 dimensions
 - Identifie les "meilleurs clients" (RF élevé, M élevé) et les "clients perdus" (R faible, F faible)
 - Base pour des campagnes personnalisées
- Impact : applicable en 2 heures sur n'importe quelle base clients.

DÉTECTION D'ANOMALIES

- Identifier les transactions suspectes, les erreurs de saisie, les comportements atypiques
 - Souvent révèle des fraudes ou des erreurs que personne n'avait vues
- Impact : peut sauver ou récupérer de l'argent directement.

PRÉVISION DE TRÉSORERIE

- Modélisation simple (moyenne mobile, régression) des flux de trésorerie
- Anticiper les tensions de liquidité 30-60 jours à l'avance

Impact : existentiel pour les PME. Celui qui prédit les crises de trésorerie devient indispensable.

OPTIMISATION DE PRIX

- Analyser l'élasticité prix par produit/segment
- Identifier les marges sous-optimisées
- Impact : +5% sur les prix au bon endroit = gain pur, zéro investissement.

9.3 LA PRÉSENTATION : TRANSFORMER UN RÉSULTAT EN MOMENT MÉMORABLE

L'analyse la plus brillante présentée de manière terne ne produit aucun effet. La magie opère autant dans la présentation que dans le contenu.

LA STRUCTURE NARRATIVE D'UN RENDU IMPACT

ACTE 1 – LA SITUATION (contexte reconnaissable)

- Rappeler le problème tel que le client le vivait
- "Vous m'avez sollicité parce que vos ventes en zone nord stagnaient."
- Le client doit se voir dans votre description.

ACTE 2 – LA DÉCOUVERTE (le moment de révélation)

- Présenter la trouvaille principale avec la visualisation la plus forte
- Laisser le silence agir après la révélation
- "Regardez ce graphique. 3 clients représentent 67% de la stagnation."

ACTE 3 – L'EXPLICATION (la mécanique)

- Expliquer pourquoi, avec des données secondaires qui soutiennent
- Montrer que vous avez compris le problème en profondeur
- Anticiper les objections avec les données

ACTE 4 – LA RECOMMANDATION (l'action)

- Toujours finir par ce qu'il faut faire – pas seulement ce qui se passe
- Proposer une, deux, trois actions classées par impact / effort
- Quantifier l'impact estimé si possible

ACTE 5 – LA PROCHAINE ÉTAPE (l'ancrage)

- Proposer immédiatement la suite
- "Si vous m'autorisez à aller plus loin, voici ce que je pourrais analyser."

RÈGLE DES TROIS

- Jamais plus de 3 messages clés dans un rapport
- Jamais plus de 3 slides sur un même point
- La simplicité est une compétence technique, pas un manque d'effort

PARTIE X – INFLUENCE, RÉPUTATION ET POSITIONNEMENT STRATÉGIQUE

10.1 POURQUOI LA RÉPUTATION EST VOTRE PREMIER ACTIF DATA

Votre réputation est une donnée que les autres collectent sur vous. Plus les signaux positifs s'accumulent, plus la confiance se construit. Et dans le conseil, la confiance est la vente.

LES SIGNAUX DE RÉPUTATION QUI COMPTENT :

[1] RÉSULTATS DÉMONSTRABLES

- Cas concrets avec chiffres : "+18% de rétention après segmentation RFM"
- Témoignages clients spécifiques (nommer la personne, la fonction, l'entreprise)
- Avant/après documenté

[2] VISIBILITÉ INTELLECTUELLE

- Articles, posts, analyses publiés sur LinkedIn ou un blog
- Ne pas partager des analyses génériques – partager des observations sur votre marché local (Congo-Brazzaville, Afrique Centrale)
- Vous devenez la référence là où personne d'autre ne regarde

[3] RÉSEAU STRATÉGIQUE

- Être connu de 50 décideurs dans votre secteur vaut plus que 5000 abonnés

- Investir dans des relations de qualité, pas de quantité
- Recommandations d'une personne crédible = pipeline de clients

[4] COHÉRENCE DE LA MARQUE

- GCI doit être reconnaissable instantanément
- Chaque livrable soigné renforce l'image premium
- Un rapport mal formaté détruit ce que 10 bons rapports ont bâti

10.2 CRÉER DES INSIGHTS QUI FONT LE TOUR DU BUREAU

La meilleure publicité est un insight tellement surprenant que votre client en parle à son directeur financier, à son associé, à son banquier.

ANATOMIE D'UN INSIGHT VIRAL (dans le monde corporate) :

CONTRE-INTUITIF

- Contredit ce que tout le monde croyait savoir
- "On pensait que les clients low-cost étaient moins fidèles. Les données montrent l'inverse pour votre catégorie."

PRÉCIS

- "Les ventes baissent" = banal
- "Les ventes des produits à marge > 40% chutent de 23% dans la tranche 35-45 ans depuis mars" = actionnable et mémorable

ACTIONNABLE

- Chaque insight doit pointer vers une décision possible
- Pas d'observation sans recommandation

VISUELLEMENT FRAPPANT

- Le graphique que l'on envoie par WhatsApp à un collègue est plus puissant qu'un rapport de 50 pages

10.3 LOBBYING PAR LA DONNÉE : INFLUENCER LES DÉCISIONS ORGANISATIONNELLES

La donnée est l'argument le plus difficile à contredire dans une réunion.

LA STRATÉGIE DU "DATA LOBBYIST" :

ÉTAPE 1 – IDENTIFIER QUI DÉCIDE ET CE QUI LES MOTIVE

- Un DG est motivé par la croissance et sa réputation
- Un DAF est motivé par la rentabilité et la maîtrise des risques
- Un directeur commercial est motivé par les objectifs et les commissions
- Chaque insight doit être présenté dans leur langage

ÉTAPE 2 – CONSTRUIRE LA NARRATIVÉ DATA AVANT LA RÉUNION

- Ne pas arriver avec des données brutes – arriver avec une histoire
- La décision que vous voulez voir prise doit sembler inévitable à la lumière des données présentées

ÉTAPE 3 – ANTICIPER LES OBJECTIONS AVEC LES DONNÉES

- Pour chaque argument contre, préparer le contre-argument en données
- "Mais le marché local est différent"
- "Voici les données du marché local. Le pattern est identique."

ÉTAPE 4 – DONNER À L'ALLIÉ UN OUTIL DE CONVICTION

- Identifier qui dans l'organisation veut déjà ce que vous recommandez
- Lui fournir les données pour qu'il convainque les autres
- Vous n'êtes plus seul porteur de la recommandation

PARTIE XI – CRÉER DE LA DÉPENDANCE : L'ART DE DEVENIR INDISPENSABLE

11.1 LA DIFFÉRENCE ENTRE PRESTATION ET DÉPENDANCE

Un prestataire livre une mission. On le paie. Il repart.
 Un partenaire indispensable est intégré dans les décisions.
 On ne l'imagine plus absent.

LA PYRAMIDE DE L'INDISPENSABILITÉ :

NIVEAU 1 – COMPÉTENT

- Fait le travail correctement
- Remplaçable par un autre compétent

NIVEAU 2 – FIABLE

- Fait le travail correctement ET dans les délais ET sans friction
- Plus difficile à trouver, mais encore remplaçable

NIVEAU 3 – CONTEXTUALISÉ

- Connaît l'organisation, son histoire, ses enjeux implicites
- Transition vers un autre consultant = mois de perte de contexte
- Devient difficile à remplacer

NIVEAU 4 – STRATÉGIQUE

- Contribue aux décisions, pas seulement aux analyses
- Ses recommandations changent des directions
- Difficile à remplacer et à valoriser

NIVEAU 5 – INSTITUTIONNEL

- Ses outils, dashboards, pipelines sont devenus l'infrastructure
- Partir signifierait perdre des systèmes entiers
- Quasiment irremplaçable à court terme

OBJECTIF GCI : atteindre le niveau 3-4 chez chaque client clé.

11.2 LES MÉCANISMES DE CRÉATION DE DÉPENDANCE

[A] L'INFRASTRUCTURE PROPRIÉTAIRE

- Construire les dashboards, les pipelines, les bases de données
- Plus la solution est intégrée dans les opérations quotidiennes, plus le coût de remplacement est élevé
- Ne pas juste analyser – construire les outils qui analysent

[B] LA MÉMOIRE INSTITUTIONNELLE

- Accumuler un contexte que personne d'autre ne possède
- Connaître les données historiques, les décisions passées, les tentatives échouées
- Documenter consciencieusement pour prouver votre valeur mais garder le contexte vivant dans votre relation

[C] LES RITUELS D'INFORMATION

- Rapport mensuel automatique → le client attend ce rapport
- Alerte automatique sur les anomalies → vous êtes présent même absent
- Réunion trimestrielle de revue → moment structuré dans leur agenda

[D] LA FORMATION INTERNE

- Former les équipes du client à utiliser vos outils
- Ils deviennent compétents sur votre stack → vos outils se diffusent
- La formation renforce l'attachement et la confiance

[E] L'ÉVOLUTION CONTINUE

- Toujours avoir une "prochaine étape" à proposer
- Ne jamais terminer une mission sans montrer ce qui est possible ensuite
- "On a résolu X. Voici Y que vous ne pouvez pas encore voir."

11.3 LE TABLEAU DE BORD COMME OUTIL DE POUVOIR

Un tableau de bord bien conçu et quotidiennement consulté est le mécanisme de dépendance le plus puissant qui soit.

PRINCIPES D'UN DASHBOARD QUI CRÉE DE L'ATTACHEMENT :

PERSONNALISÉ AU DÉCIDEUR

- Pas de KPIs génériques – les métriques qui correspondent à SES responsabilités et à SES objectifs personnels
- Si le dashboard aide à défendre sa performance en comité de direction, il ne s'en passera plus jamais

TEMPS RÉEL OU AU MOINS QUOTIDIEN

- Un dashboard mis à jour mensuellement est consulté mensuellement
- Un dashboard mis à jour quotidiennement est consulté quotidiennement

SIMPLE ET BEAU

- 5-7 KPIs maximum par écran
- Des couleurs qui ont un sens (rouge = problème, vert = objectif atteint)
- La charte GCI appliquée = professionnalisme visible

AVEC ALERTES AUTOMATIQUES

- Email/SMS quand un seuil est franchi
- "Votre taux de retour clients vient de dépasser 5%"
- Vous êtes présent dans leur vie sans y être

LIÉ À UNE QUESTION QU'ILS SE POSENT CHAQUE MATIN

- "Les ventes d'hier ont-elles atteint l'objectif ?"
- "Combien ai-je de nouveaux clients cette semaine ?"
- Le dashboard répond à la question avant qu'ils la posent

PARTIE XII – ÉTHIQUE DU POUVOIR PAR LA DONNÉE

12.1 POURQUOI L'ÉTHIQUE N'EST PAS UNE CONTRAINTE MAIS UN AVANTAGE

L'éthique est souvent présentée comme une limite à la puissance.
C'est l'inverse. L'éthique est un actif stratégique à long terme.

RAISONNEMENT :

- La data science donne un accès unique à des informations sensibles
- Les clients vous confient des données qu'ils ne montrent pas à leur banquier
- Cette confiance est votre vrai capital – plus précieux que vos compétences

UN CONSULTANT DATA SANS ÉTHIQUE :

- Peut exploiter les données de son client pour un concurrent
- Peut manipuler des chiffres pour orienter une décision
- Peut utiliser des données personnelles sans consentement
- Gagnera à court terme, perdra tout à moyen terme

UN CONSULTANT DATA ÉTHIQUE :

- Est recommandé même aux concurrents de ses clients
- Construit une réputation sur 20 ans, pas sur 2 contrats
- Peut refuser un client dont les intentions sont douteuses et rester crédible
- Dort bien la nuit

12.2 LES LIGNES ROUGES DU PRATICIEN DATA

MANIPULER LES DONNÉES POUR CONFIRMER UNE CONCLUSION PRÉEXISTANTE

- C'est du cherry-picking. C'est de la tromperie déguisée en analyse.
- Votre rôle : dire ce que les données disent, même si ça déplaît.
- Un consultant qui dit toujours ce que le client veut entendre est inutile. Un consultant qui dit la vérité est précieux.

UTILISER DES DONNÉES PERSONNELLES SANS CONSENTEMENT APPROPRIÉ

- Les données de clients, d'employés, de citoyens sont des informations sur des personnes réelles
- Tout usage doit être proportionné, consenti, documenté

PRODUIRE DES ANALYSES QUI RENFORCENT DES DISCRIMINATIONS INJUSTES

- Un modèle entraîné sur des données historiques biaisées reproduit et amplifie les biais
- Exemple : un modèle de crédit entraîné sur des données historiquement discriminantes reproduit cette discrimination de manière automatisée

VENDRE DES CERTITUDES LÀ OÙ IL N'Y A QUE DES PROBABILITÉS

- "Ce modèle prédit avec 100% de certitude..." ne dit jamais un expert honnête
 - Communiquer les intervalles de confiance, les limites, les conditions
 - La crédibilité à long terme repose sur la précision de vos claims
-

"Utilisez la puissance de la donnée pour servir les intérêts de vos clients et de leurs clients finaux – pas pour exploiter les uns au détriment des autres."

Appliqué concrètement :

- Analyser les données pour améliorer le service client (pas pour identifier les moins informés à sur-facturer)
- Construire des modèles prédictifs pour optimiser l'allocation de ressources (pas pour exclure systématiquement des populations vulnérables)
- Utiliser la veille concurrentielle pour être meilleur (pas pour espionner illégalement les personnes)
- Automatiser les processus pour libérer du temps humain (pas uniquement pour supprimer des emplois sans transition)

CONCLUSION – LE MANIFESTE DU DATA STRATÈGE GCI

La donnée est la matière première la plus démocratique jamais connue. Elle n'appartient pas aux grandes entreprises par droit naturel. Elle appartient à ceux qui savent la traiter.

Un data stratège d'élite maîtrise deux dimensions :

LA DIMENSION TECHNIQUE

- Il bâtit des infrastructures fiables qui survivent à leur créateur
- Il protège les données comme un actif précieux
- Il construit des pipelines qui tournent sans surveillance
- Il modélise avec rigueur et honnêteté intellectuelle

LA DIMENSION STRATÉGIQUE

- Il comprend que l'analyse n'est qu'un moyen, la décision est la fin
- Il sait présenter pour émouvoir, convaincre et activer
- Il construit des relations de confiance sur des décennies
- Il utilise son pouvoir avec discernement et éthique

En Afrique, et particulièrement au Congo-Brazzaville, cette combinaison est encore rare. Le marché est vierge. Les opportunités sont réelles. Les organisations qui vous confieront leurs données le font parce qu'elles n'ont pas les compétences internes – et elles vous en seront reconnaissantes si vous transformez leur réalité avec des chiffres et des preuves.

Le magicien n'a pas de pouvoirs surnaturels. Il maîtrise simplement ce que les autres ignorent. Et il le fait avec élégance.

– GCI, Gykhamine Concept Investigation
Congo-Brazzaville

RESSOURCES POUR APPROFONDIR

ARCHITECTURE ET INFRASTRUCTURE

- "Designing Data-Intensive Applications" – Martin Kleppmann
- "Fundamentals of Data Engineering" – Joe Reis & Matt Housley
- "The Data Warehouse Toolkit" – Ralph Kimball (star/snowflake schema)
- Documentation dbt : docs.getdbt.com

SÉCURITÉ DES DONNÉES

- "The Web Application Hacker's Handbook" (principes de sécurité applicative)
- OWASP Top 10 : owasp.org (failles les plus courantes)
- Documentation pgaudit (audit PostgreSQL)
- CIS Benchmarks : frameworks de sécurité par technologie

GOUVERNANCE

- "Data Management Body of Knowledge" (DAMA-DMBOK) : la référence officielle
- "Data Governance" – John Ladley
- DataHub : datahubproject.io (open source data catalog)

POUVOIR ET INFLUENCE

- "Influence" – Robert Cialdini (psychologie de la persuasion)
- "The Signal and the Noise" – Nate Silver (prévision et incertitude)
- "Thinking with Data" – Max Shron (formuler les bons problèmes)
- "Storytelling with Data" – Cole Nussbaumer Knafllic (présentation)

ÉTHIQUE DATA

- "Weapons of Math Destruction" – Cathy O'Neil (algorithmes et injustice)
- "The Alignment Problem" – Brian Christian (IA et valeurs humaines)
- Lignes directrices de l'Union Africaine sur la gouvernance des données

=====

FIN DU COURS – GCI © 2025 – TOUS DROITS RÉSERVÉS

Formation continue disponible via GCI – Congo-Brazzaville

=====