

TABLE DES MATIÈRES

PARTIE I	– FONDEMENTS : PSYCHOLOGIE SOCIALE ET DONNÉE
PARTIE II	– LA PSYCHOLOGIE DES FOULES : MODÉLISATION QUANTITATIVE
PARTIE III	– COLLECTE DE DONNÉES COMPORTEMENTALES ET SOCIALES
PARTIE IV	– ANALYSE DES RÉSEAUX SOCIAUX (SNA)
PARTIE V	– OPINION MINING, SENTIMENT ET NARRATION COLLECTIVE
PARTIE VI	– MODÉLISATION DES BIAIS COGNITIFS PAR LA DONNÉE
PARTIE VII	– INFLUENCE, PERSUASION ET CHANGEMENT D'OPINION
PARTIE VIII	– PROPAGANDE, DÉSINFORMATION ET DÉTECTION
PARTIE IX	– PRÉDICTION DES COMPORTEMENTS COLLECTIFS
PARTIE X	– NUDGE, ARCHITECTURE DU CHOIX ET DESIGN COMPORTEMENTAL
PARTIE XI	– APPLICATIONS : POLITIQUE, MARCHÉ, SÉCURITÉ, SOCIÉTÉ
PARTIE XII	– ÉTHIQUE, LIMITES ET RESPONSABILITÉ DU DATA SCIENTIST SOCIAL
PARTIE XIII	– OUTILS, STACK TECHNIQUE ET PROJETS CONCRETS

=====

PARTIE I – FONDEMENTS : PSYCHOLOGIE SOCIALE ET DONNÉE

=====

1.1 POURQUOI CROISER DATA SCIENCE ET PSYCHOLOGIE SOCIALE ?

La psychologie sociale étudie comment les individus pensent, ressentent et se comportent en présence – réelle ou imaginée – des autres.

La data science fournit les outils pour mesurer ces comportements à grande échelle, les modéliser, les prédire et les influencer.

Cette intersection produit ce que certains appellent la "computational social science" : une discipline qui transforme les comportements humains en données traitables.

POURQUOI C'EST RÉVOLUTIONNAIRE :

- Avant : la psychologie sociale travaillait en laboratoire, sur des petits échantillons (100 à 1000 personnes), avec des résultats difficiles à généraliser.
- Maintenant : on dispose de milliards de comportements enregistrés en temps réel (clics, likes, partages, achats, déplacements, messages) qui forment une psychologie sociale à l'échelle de l'humanité entière.

DÉFINITION OPÉRATIONNELLE :

"La data science sociale est l'ensemble des méthodes computationnelles permettant de capturer, analyser, modéliser et prédire les comportements individuels et collectifs d'une population à partir de traces numériques."

1.2 LES GRANDS CONCEPTS DE LA PSYCHOLOGIE SOCIALE PERTINENTS POUR LA DONNÉE

[A] CONFORMISME ET INFLUENCE SOCIALE

- Les individus alignent leur comportement sur celui du groupe
- Mesurable : convergence de scores d'opinion après exposition à des contenus viraux
- Modélisable : modèles de diffusion sociale (SIR, cascade d'information)

[B] DISSONANCE COGNITIVE

- Tension entre croyances contradictoires → résolution par rationalisation
- Detectable dans les données : changements de vocabulaire post-exposition, suppression de messages, modifications rétroactives de profil

[C] BIAIS DE CONFIRMATION

- Tendance à rechercher et mémoriser les informations qui confirment ses croyances existantes
- Mesurable : analyse des patterns de clics, des sources consultées, des bulles informationnelles

[D] PENSÉE DE GROUPE (GROUPTHINK)

- Dans un groupe homogène, la pression vers le consensus supprime les avis divergents
- Détectable : réduction de la diversité lexicale dans des forums, disparition des voix minoritaires au fil du temps

[E] NORME SOCIALE

- Les individus adoptent les comportements qu'ils croient majoritaires
- Exploitable : afficher "90% des utilisateurs font X" modifie le comportement des autres (nudge)

[F] PEUR, INCERTITUDE, URGENCE

- Les émotions négatives accélèrent la viralité et la prise de décision impulsive
- Mesurable : corrélation entre tonalité émotionnelle d'un post et son taux de diffusion

1.3 LES TROIS NIVEAUX D'ANALYSE SOCIALE PAR LA DONNÉE

NIVEAU MICRO – L'INDIVIDU

- Comportement personnel, préférences, historique
- Données : logs individuels, profils, historiques d'achat, géolocalisation
- But : personnalisation, profilage, prédiction individuelle

NIVEAU MÉSO – LE GROUPE / LA COMMUNAUTÉ

- Dynamiques de sous-cultures, tribus, groupes d'appartenance
- Données : graphes sociaux, forums, communautés Reddit/Discord/Telegram
- But : identifier les leaders d'opinion, les coalitions, les tensions

NIVEAU MACRO – LA SOCIÉTÉ / LA FOULE

- Mouvements d'opinion, tendances culturelles, crises sociales
- Données : médias sociaux agrégés, données électorales, sondages à grande échelle, données de mobilité
- But : prédiction des mouvements sociaux, détection de ruptures

PARTIE II – LA PSYCHOLOGIE DES FOULES : MODÉLISATION QUANTITATIVE

2.1 GUSTAVE LE BON À L'ÈRE DU BIG DATA

Gustave Le Bon (1895, "Psychologie des foules") a identifié que les individus dans une foule perdent leur rationalité individuelle et se comportent selon une "âme collective" distincte.

Ses trois mécanismes fondamentaux, traduits en data science :

[1] ANONYMAT → Désinhibition en ligne

- Sur Internet, l'anonymat produit les mêmes effets que dans la foule
- Mesure : comparaison du contenu des comptes anonymes vs identifiés (agressivité, extrémisme, mensonge)

[2] CONTAGION ÉMOTIONNELLE → Diffusion virale

- Une émotion se propage dans la foule comme une onde
- Modèle de données : réseau de diffusion, taux de reproduction (R0) emprunté à l'épidémiologie, appliqué aux mêmes et aux émotions

[3] SUGGESTIBILITÉ → Vulnérabilité à la manipulation

- Dans un état émotionnel intense, l'esprit critique s'effondre
- Mesure : délai entre exposition à une information et action (partage, achat, vote) → les délais courts = décisions émotionnelles non réfléchies

2.2 MODÈLES MATHÉMATIQUES DES FOULES

MODÈLE SIR (Susceptible - Infected - Recovered)

Emprunté à l'épidémiologie, appliqué à la diffusion d'idées :

S → Individus susceptibles (pas encore exposés à l'idée)
I → Individus infectés (qui propagent activement l'idée)
R → Individus rétablis (qui ont cessé de propager)

$$\begin{aligned}dS/dt &= -\beta \times S \times I / N \\dI/dt &= \beta \times S \times I / N - \gamma \times I \\dR/dt &= \gamma \times I\end{aligned}$$

β = taux de transmission (viralité du message)
 γ = taux de récupération (oubli ou désintérêt)
 $R_0 = \beta/\gamma$ → si $R_0 > 1$: l'idée se propage, si $R_0 < 1$: elle s'éteint

APPLICATION PRATIQUE EN PYTHON :

```
import numpy as np
from scipy.integrate import odeint
import matplotlib.pyplot as plt

def sir_model(y, t, beta, gamma, N):
    S, I, R = y
    dSdt = -beta * S * I / N
    dIdt = beta * S * I / N - gamma * I
    dRdt = gamma * I
    return dSdt, dIdt, dRdt

N = 1_000_000 # population totale
I0 = 100      # porteurs initiaux (influenceurs, sources)
S0 = N - I0
R0_val = 0
beta, gamma = 0.3, 0.05 # paramètres à calibrer sur données réelles
t = np.linspace(0, 160, 160)
sol = odeint(sir_model, [S0, I0, R0_val], t, args=(beta, gamma, N))

plt.plot(t, sol[:, 1], label="Propagateurs actifs")
plt.xlabel("Jours")
plt.ylabel("Individus")
plt.title("Diffusion d'une idée dans une population")
plt.legend()
plt.show()
```

MODÈLE DE CASCADE D'INFORMATION (Information Cascade)

- Un individu adopte une opinion non pas par conviction mais parce que suffisamment de gens autour de lui l'ont adoptée
- Seuil individuel θ : chaque personne rejoint le mouvement si le pourcentage de participants dépasse son seuil personnel
- Distribution des seuils dans la population → point critique (tipping point)

MODÈLE DE SCHELLING (Ségrégation)

- Même une légère préférence pour côtoyer des semblables produit une ségrégation totale à grande échelle
- Application data : formation de bulles idéologiques sur les réseaux, ségrégation des recommandations algorithmiques

2.3 DÉTECTION DES FOULES NUMÉRIQUES

Une "foule numérique" est un agrégat d'individus dont les comportements se synchronisent spontanément autour d'un événement, d'une émotion ou d'une narrative.

INDICATEURS DE DÉTECTION :

- Spike soudain de volume de posts sur un sujet
- Convergence rapide de vocabulaire (lexical alignment)
- Hausse du taux de retweet vs contenu original
- Baisse de diversité des sources citées
- Émergence d'un lexique in-group spécifique

ALGORITHME DE DÉTECTION D'ANOMALIE COMPORTEMENTALE :

```

from sklearn.ensemble import IsolationForest
import pandas as pd

# df contient : timestamp, volume_posts, sentiment_moyen,
#               nb_utilisateurs_actifs, ratio_retweets
df = pd.read_csv("flux_social.csv", parse_dates=["timestamp"])

features = ["volume_posts", "sentiment_moyen", "ratio_retweets"]
model = IsolationForest(contamination=0.02, random_state=42)
df["anomalie"] = model.fit_predict(df[features])
# anomalie == -1 → comportement de foule détecté

```

PARTIE III – COLLECTE DE DONNÉES COMPORTEMENTALES ET SOCIALES

3.1 SOURCES DE DONNÉES SOCIALES

DONNÉES PUBLIQUES (Open Source Intelligence – OSINT)

- Réseaux sociaux : Twitter/X API, Reddit API (PRAW), YouTube Data API
- Données électorales et sondages publics
- Archives médias, presses, journaux (scraping légal)
- Données gouvernementales (recensements, statistiques publiques)
- Commentaires de plateformes publiques (Amazon, Trustpilot, forums)

DONNÉES COMPORTEMENTALES PASSIVES

- Logs de navigation et de clics (heatmaps, funnels)
- Données de streaming (Netflix, Spotify → patterns culturels)
- Données de mobilité (Google Mobility Reports, téléphonie)
- Données transactionnelles (achats, cartes bancaires agrégées)

DONNÉES PSYCHOMÉTRIQUES

- Questionnaires en ligne à grande échelle (OCEAN/Big Five)
- Tests implicites (IAT – Implicit Association Test)
- Expériences comportementales en ligne (A/B tests massifs)

3.2 SCRAPING ET COLLECTE DE DONNÉES SOCIALES

EXEMPLE : COLLECTE TWITTER/X AVEC TWEETPY

```

import tweepy
import pandas as pd

client = tweepy.Client(bearer_token="VOTRE_TOKEN")

# Recherche de tweets sur un sujet sensible
query = "#greve OR #mouvement social -is:retweet lang:fr"
tweets = client.search_recent_tweets(
    query=query,
    max_results=100,
    tweet_fields=["created_at", "public_metrics", "author_id", "text"]
)

data = []
for tweet in tweets.data:
    data.append({
        "id": tweet.id,
        "texte": tweet.text,
        "date": tweet.created_at,
        "likes": tweet.public_metrics["like_count"],
        "retweets": tweet.public_metrics["retweet_count"],
        "auteur": tweet.author_id
    })

df = pd.DataFrame(data)
df.to_csv("tweets_mouvement.csv", index=False)

```

EXEMPLE : COLLECTE REDDIT AVEC PRAW

```
import praw
```

```
import pandas as pd

reddit = praw.Reddit(
    client_id="XXX",
    client_secret="YYY",
    user_agent="SocialResearch/1.0"
)

subreddit = reddit.subreddit("france+politique")
posts = []
for post in subreddit.hot(limit=200):
    posts.append({
        "titre": post.title,
        "score": post.score,
        "nb_commentaires": post.num_comments,
        "date": post.created_utc,
        "texte": post.selftext
    })

df = pd.DataFrame(posts)
```

3.3 BIAIS DANS LES DONNÉES SOCIALES

BIAIS DE SÉLECTION

- Les utilisateurs actifs sur Twitter ne représentent pas la population
- Les gens qui postent en ligne sont plus polarisés que la moyenne silencieuse
- Correction : pondération démographique, calibration sur sondages offline

BIAIS DE PLATEFORME

- Chaque plateforme attire un profil psychologique différent
- TikTok ≠ LinkedIn ≠ Reddit ≠ Facebook en termes de normes sociales
- Correction : ne pas généraliser des findings d'une plateforme à toute la société

BIAIS DE SURVIVANCE

- On observe les posts qui n'ont pas été supprimés, les comptes actifs
- Les contenus les plus extrêmes sont souvent supprimés → underestimation de la radicalisation réelle

BIAIS D'AMPLIFICATION ALGORITHMIQUE

- Les algorithmes de recommandation amplifient certains contenus
- Les données récoltées reflètent déjà un biais algorithmique
- Correction : collecter via API directe, pas via le feed "recommandé"

PARTIE IV – ANALYSE DES RÉSEAUX SOCIAUX (SNA)

4.1 CONCEPTS FONDAMENTAUX DU GRAPHE SOCIAL

Un réseau social se représente comme un graphe $G = (V, E)$:

- V = ensemble des noeuds (individus, comptes, entités)
- E = ensemble des arêtes (relations, interactions, liens)

MÉTRIQUES CLÉS :

CENTRALITÉ DE DEGRÉ

- Nombre de connexions directes d'un noeud
- Identifie les hubs d'influence brute

CENTRALITÉ D'INTERMÉDIARITÉ (Betweenness Centrality)

- Fréquence à laquelle un noeud se trouve sur le chemin le plus court entre deux autres noeuds
- Identifie les "ponts" qui contrôlent le flux d'information entre communautés – les courtiers stratégiques

CENTRALITÉ DE PROXIMITÉ (Closeness Centrality)

- Inverse de la distance moyenne à tous les autres noeuds
- Identifie qui peut diffuser une information le plus rapidement

PAGERANK

- Probabilité qu'un marcheur aléatoire arrive sur ce noeud
- Mesure l'influence pondérée par la qualité des sources qui pointent vers ce noeud (utilisé par Google, applicable aux réseaux d'influence)

4.2 DÉTECTION DE COMMUNAUTÉS ET CHAMBRES D'ÉCHO

ALGORITHME DE LOUVAIN (détection de communautés) :

```
import networkx as nx
import community_louvain
import matplotlib.pyplot as plt
import pandas as pd

# Construction du graphe depuis des données d'interactions
df_edges = pd.read_csv("interactions.csv") # colonnes: source, target, weight
G = nx.from_pandas_edgelist(df_edges, "source", "target", "weight")

# Détection des communautés
partition = community_louvain.best_partition(G)
nx.set_node_attributes(G, partition, "communaute")

# Visualisation
pos = nx.spring_layout(G, k=0.3)
couleurs = [partition[n] for n in G.nodes()]
nx.draw(G, pos, node_color=couleurs, node_size=50,
        cmap=plt.cm.Set3, with_labels=False)
plt.title("Communautés d'opinion dans le réseau")
plt.show()
```

MESURER L'HOMOPHILIE (tendance à interagir avec des semblables) :

```
# Homophilie sur un attribut (ex: opinion politique)
# Calcul de l'assortativity coefficient (-1 à 1)
# 1 = interaction exclusive avec ses semblables (bulle parfaite)
# 0 = interactions aléatoires
# -1 = interaction exclusive avec des différents (rare)

assortativity = nx.attribute_assortativity_coefficient(G, "opinion_politique")
print(f"Homophilie : {assortativity:.3f}")
```

DÉTECTION DE CHAMBRE D'ÉCHO :

Une chambre d'écho se caractérise par :

1. Haute densité interne (beaucoup d'interactions entre membres)
2. Faible densité externe (peu de liens vers d'autres communautés)
3. Homophilie élevée sur les opinions
4. Diversité lexicale réduite (vocabulaire convergent)

Méthode de détection :

- Calculer le ratio densité interne / densité externe pour chaque cluster
- Calculer l'assortativity par cluster
- Analyser l'évolution temporelle (les bulles se renforcent-elles ?)

4.3 IDENTIFIER LES LEADERS D'OPINION ET INFLUENCEURS STRATÉGIQUES

Un leader d'opinion n'est pas nécessairement le plus populaire.
Il peut être un connecteur entre communautés (forte betweenness)
ou un amplificateur de premier ordre (forte centralité de degré).

PROFILS D'INFLUENCEURS :

- TYPE 1 – LE HUB : forte centralité de degré
- Beaucoup d'audience directe
 - Atteint rapidement de nombreuses personnes
 - Vulnérabilité : cibler ce hub perturbe le réseau entier
- TYPE 2 – LE BROKER : forte betweenness
- Pont entre communautés différentes
 - Capable de faire passer un message d'une bulle à une autre
 - Rare et stratégiquement crucial

TYPE 3 – LE SEED : première vague d'adoption
→ Pas forcément populaire, mais adopte tôt et déclenche les cascades
→ Identifiable rétrospectivement dans les données de diffusion temporelle

CODE : SCORING D'INFLUENCE COMPOSITE

```
import networkx as nx
import pandas as pd

G = nx.read_gexf("reseau_social.gexf")

scores = pd.DataFrame({
    "noeud": list(G.nodes()),
    "degre": [G.degree(n) for n in G.nodes()],
    "betweenness": list(nx.betweenness centrality(G).values()),
    "pagerank": list(nx.pagerank(G).values()),
    "closeness": list(nx.closeness centrality(G).values())
})

# Normalisation et score composite
for col in ["degre", "betweenness", "pagerank", "closeness"]:
    scores[col] = (scores[col] - scores[col].min()) / \
        (scores[col].max() - scores[col].min())

scores["score_influence"] = (
    0.25 * scores["degre"] +
    0.35 * scores["betweenness"] +
    0.25 * scores["pagerank"] +
    0.15 * scores["closeness"]
)

top_influenceurs = scores.nlargest(20, "score_influence")
print(top_influenceurs)
```

PARTIE V – OPINION MINING, SENTIMENT ET NARRATION COLLECTIVE

5.1 ANALYSE DE SENTIMENT À L'ÉCHELLE SOCIALE

L'analyse de sentiment transforme des textes en signaux émotionnels mesurables. Appliquée à l'échelle d'une population, elle devient un baromètre en temps réel de l'humeur collective.

NIVEAUX D'ANALYSE :

NIVEAU 1 – POLARITÉ SIMPLE : positif / négatif / neutre
NIVEAU 2 – INTENSITÉ ÉMOTIONNELLE : score continu de -1 à +1
NIVEAU 3 – ÉMOTIONS SPÉCIFIQUES : joie, colère, peur, dégoût, tristesse, surprise (modèle de Plutchik)
NIVEAU 4 – ANALYSE FINE DES ASPECTS : l'opinion sur un aspect spécifique d'un sujet ("le président est compétent mais peu empathique")

IMPLÉMENTATION AVEC CAMEMBERT (modèle BERT français) :

```
from transformers import pipeline

# Modèle pré-entraîné pour le français
sentiment_analyzer = pipeline(
    "sentiment-analysis",
    model="tblard/tf-allocine"
)

textes = [
    "Ce gouvernement nous mène droit dans le mur.",
    "Enfin des mesures concrètes pour les familles !",
    "Je ne sais plus quoi penser de tout ça.",
    "Ils nous mentent depuis le début, réveil collectif nécessaire."
]

resultats = sentiment_analyzer(textes)
for texte, res in zip(textes, resultats):
    print(f"[{res['label']}] | {res['score']:.2f} {texte[:60]}...")
```

5.2 CARTOGRAPHIE DES NARRATIVES COLLECTIVES

Une narrative collective est un récit partagé qui donne du sens à un événement ou à une situation. Les narratives structurent la pensée de groupe et conditionnent les décisions collectives.

MÉTHODE D'EXTRACTION PAR TOPIC MODELING :

```
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.decomposition import NMF
import pandas as pd

# Corpus de textes sociaux
df = pd.read_csv("corpus_social.csv")
textes = df["texte"].dropna().tolist()

# Vectorisation
vectorizer = TfidfVectorizer(
    max_features=5000,
    stop_words=None, # utiliser une liste de stopwords français
    ngram_range=(1, 2),
    min_df=5
)
tfidf_matrix = vectorizer.fit_transform(textes)
feature_names = vectorizer.get_feature_names_out()

# Extraction de narratives avec NMF
n_topics = 10
nmf = NMF(n_components=n_topics, random_state=42)
W = nmf.fit_transform(tfidf_matrix) # poids des narratives par document
H = nmf.components_                 # poids des mots par narrative

# Affichage des narratives
for topic_idx, topic in enumerate(H):
    top_mots = [feature_names[i] for i in topic.argsort()[::-16:-1]]
    print(f"\nNarrative {topic_idx + 1} :")
    print(" | ".join(top_mots))
```

ANALYSE TEMPORELLE DES NARRATIVES :

- Tracer l'évolution des narratives dans le temps révèle les moments de basculement d'opinion collective
- Les ruptures narratives précèdent souvent les mouvements sociaux réels

5.3 DÉTECTION DES SIGNAUX FAIBLES ET POINTS DE BASCULE

Un signal faible est une anomalie précoce qui annonce un changement majeur.

INDICATEURS DE TENSION SOCIALE IMMINENTE :

- Hausse du sentiment négatif au-delà d'un seuil (ex: > -0.6 de moyenne)
- Apparition soudaine de vocabulaire de déshumanisation
- Accélération du taux de croissance des nouvelles communautés en colère
- Déclin de la diversité des sources (convergence vers des sources marginales)
- Augmentation des métaphores guerrières dans le discours ordinaire

DÉTECTION PAR MODÈLE DE CHANGEMENT DE RÉGIME (CUSUM) :

```
import numpy as np
import pandas as pd

def cusum_detection(series, threshold=5, drift=0.5):
    """Détection des changements de régime dans une série temporelle."""
    s_pos, s_neg = 0, 0
    alarms = []
    for i, x in enumerate(series):
        s_pos = max(0, s_pos + x - drift)
        s_neg = max(0, s_neg - x - drift)
        if s_pos > threshold or s_neg > threshold:
            alarms.append(i)
            s_pos, s_neg = 0, 0
```

```
return alarms
```

```
# Appliquer sur la série temporelle du sentiment moyen
df = pd.read_csv("sentiment_temporel.csv")
sentiment_series = df["sentiment_moyen"].values
points_de_bascule = cusum_detection(sentiment_series, threshold=4)
print(f"Points de bascule détectés aux indices : {points_de_bascule}")
```

PARTIE VI – MODÉLISATION DES BIAIS COGNITIFS PAR LA DONNÉE

6.1 CARTOGRAPHIE DES BIAIS COGNITIFS MESURABLES

Les biais cognitifs sont des raccourcis mentaux systématiques qui dévient la pensée rationnelle. Ils sont exploitables par la donnée parce qu'ils produisent des patterns comportementaux prédictibles et répétables.

BIAIS D'ANCRAGE

Définition : la première information reçue influence disproportionnellement le jugement final.

Mesure par les données :

- Comparer les estimations d'utilisateurs selon la valeur affichée en premier
- A/B test : afficher un prix initial différent → effet sur le prix accepté

Application : pricing psychologique, présentation des options politiques

BIAIS DE DISPONIBILITÉ

Définition : on surestime la probabilité d'événements facilement mémorisables (récents, émotionnels, médiatisés).

Mesure :

- Corrélation entre couverture médiatique d'un risque et niveau de peur déclaré de ce risque dans les sondages

Application : gestion de la perception du risque, communication de crise

BIAIS DU STATU QUO

Définition : les individus préfèrent l'inaction et maintien de l'existant.

Mesure :

- Taux d'opt-out vs opt-in dans des expériences comportementales
- Inertie de vote (les gens votent comme ils ont toujours voté)

Application : conception de systèmes de choix, architecture des menus par défaut

EFFET DE HALO

Définition : une caractéristique positive d'une personne ou d'une idée influence positivement l'évaluation de ses autres caractéristiques.

Mesure :

- Corrélation entre attractivité perçue d'un candidat et scores de compétence
- Corrélation entre prestige de la source et crédibilité de l'information

Application : branding politique, communication institutionnelle

6.2 PSYCHOGRAPHIE ET PROFILAGE PSYCHOMÉTRIQUE PAR LES DONNÉES

Le modèle OCEAN (Big Five) est le standard en psychologie de la personnalité :

- O – OUVERTURE À L'EXPÉRIENCE : curiosité, créativité, flexibilité
- C – CONSCIENCIOSITÉ : organisation, discipline, fiabilité
- E – EXTRAVERSION : sociabilité, assertivité, positivité
- A – AGRÉABILITÉ : coopération, empathie, bienveillance
- N – NÉVROSISME : anxiété, instabilité émotionnelle, sensibilité au stress

LA DÉCOUVERTE CLÉ (Kosinski et al., 2013) :

- Les likes Facebook permettent de prédire les scores OCEAN avec une précision supérieure aux proches du sujet
- 10 likes → meilleure prédiction qu'un collègue
- 150 likes → meilleure prédiction qu'un parent
- 300 likes → meilleure prédiction que le conjoint

VARIABLES PRÉDICTIVES DU PROFIL PSYCHOLOGIQUE :

- Vocabulaire utilisé (taille du vocabulaire → O, utilisation de "je" → N)
- Heure de publication (nuit → N élevé)
- Fréquence de publication (élevée → E élevé)
- Type de contenu partagé (actualités → O élevé, famille → A élevé)

- Réseau de contacts (dense → E élevé)

IMPLÉMENTATION SIMPLIFIÉE :

```
from sklearn.linear_model import Ridge
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import cross_val_score
import pandas as pd

# df contient features comportementales + scores OCEAN labellisés
df = pd.read_csv("psychometric_dataset.csv")

features_comportementales = [
    "nb_likes_par_jour", "heure_moy_publication", "ratio_selfies",
    "taille_vocab_moy", "nb_amis", "ratio_posts_actuelles",
    "nb_groupes_politiques", "ratio_emoji_negatifs"
]

X = df[features_comportementales]
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

for trait in ["O", "C", "E", "A", "N"]:
    y = df[f"score_{trait}"]
    model = Ridge(alpha=1.0)
    scores = cross_val_score(model, X_scaled, y, cv=5, scoring="r2")
    print(f"Trait {trait} – R2 moyen : {scores.mean():.3f}")
```

PARTIE VII – INFLUENCE, PERSUASION ET CHANGEMENT D'OPINION

7.1 LES LEVIERS DE LA PERSUASION – CIALDINI REVISITÉ PAR LA DATA

Robert Cialdini a identifié six principes de persuasion universels. Chacun est mesurable et optimisable par les données.

[1] RÉCIPROCITÉ

- Lorsqu'on donne quelque chose, l'autre se sent obligé de rendre.
- Mesure data : taux de conversion après offre gratuite vs sans offre
- Optimisation : A/B test sur la valeur perçue du cadeau initial

[2] ENGAGEMENT ET COHÉRENCE

- Une fois engagé publiquement, l'individu maintient sa position.
- Mesure data : taux de rétention post-engagement public (signature de pétition, déclaration publique)
- Application : faire signer des micro-engagements avant les grands

[3] PREUVE SOCIALE

- "Si beaucoup de gens font X, X doit être correct."
- Mesure data : taux de conversion en fonction du nombre d'avis affichés, du compteur de partages, du "X personnes regardent ceci"
- Optimisation : afficher les chiffres au bon moment, dans le bon contexte

[4] AUTORITÉ

- Les individus font confiance aux experts et figures d'autorité.
- Mesure data : différence de crédibilité perçue entre source anonyme et source avec titre d'expertise (A/B test)
- Application : calibrer le niveau d'expertise nécessaire selon l'audience

[5] SYMPATHIE / AFFINITÉ

- On est persuadé par ceux qu'on apprécie et qui nous ressemblent.
- Mesure data : corrélation entre similarité perçue (même région, mêmes valeurs) et taux d'adoption d'une opinion
- Application : micro-ciblage démographique et psychographique

[6] RARETÉ / URGENCE

- Ce qui est rare ou limité dans le temps est perçu comme plus désirable.
- Mesure data : taux de clic avec et sans compteur d'urgence
- Application : communication de crise, mobilisation politique

7.2 MICRO-CIBLAGE COMPORTEMENTAL ET PERSONNALISATION PERSUASIVE

Le micro-ciblage consiste à envoyer des messages personnalisés à des segments psychographiques précis, exploitant leurs biais spécifiques.

PIPELINE DE MICRO-CIBLAGE :

ÉTAPE 1 – PROFILAGE PSYCHOGRAPHIQUE DE L'AUDIENCE

- Collecte des données comportementales
- Prédiction des scores OCEAN
- Segmentation en clusters psychographiques

ÉTAPE 2 – CRÉATION DE MESSAGES ADAPTÉS PAR PROFIL

- Profil O élevé : message axé sur la nouveauté, le changement, l'innovation
- Profil C élevé : message axé sur la sécurité, l'ordre, la preuve chiffrée
- Profil E élevé : message axé sur la communauté, l'appartenance, l'action
- Profil A élevé : message axé sur l'entraide, les valeurs humaines
- Profil N élevé : message axé sur la menace, la protection, la peur

ÉTAPE 3 – DIFFUSION CIBLÉE ET TEST

- Attribution des messages aux segments correspondants
- A/B test par segment psychographique
- Mesure du taux d'engagement, de conversion, de changement d'opinion

ÉTAPE 4 – OPTIMISATION CONTINUE

- Analyse des résultats par segment
- Ajustement du message et du canal
- Retour au cycle

7.3 MESURER LE CHANGEMENT D'OPINION PAR LES DONNÉES

MÉTHODES DE MESURE DIRECTE :

- Sondages pré/post exposition à un message (panel longitudinal)
- Analyse des changements de sentiment dans les posts avant/après un événement
- Analyse du vocabulaire : apparition/disparition de termes associés à une position politique

MÉTHODES INDIRECTES (COMPORTEMENTALES) :

- Changement dans les comportements de partage (contenu partagé avant vs après)
- Évolution des connexions dans le graphe social (avec qui on interagit)
- Changement des patterns de lecture (sources consultées, temps passé)

EXEMPLE : MESURE DE CHANGEMENT D'OPINION PAR ANALYSE LEXICALE

```
import pandas as pd
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.metrics.pairwise import cosine_similarity
import numpy as np

# Comparer le vocabulaire d'un utilisateur avant et après exposition
def mesurer_derive_opinion(posts_avant, posts_apres):
    """Mesure le changement lexical = proxy du changement d'opinion."""
    vect = TfidfVectorizer()
    corpus_avant = " ".join(posts_avant)
    corpus_apres = " ".join(posts_apres)
    matrix = vect.fit_transform([corpus_avant, corpus_apres])
    similarite = cosine_similarity(matrix[0], matrix[1])[0][0]
    derive = 1 - similarite # 0 = stable, 1 = transformation totale
    return derive
```

PARTIE VIII – PROPAGANDE, DÉSINFORMATION ET DÉTECTION

8.1 ANATOMIE DE LA DÉSINFORMATION PAR LA DONNÉE

La désinformation n'est pas simplement l'erreur factuelle. C'est un système social organisé avec des acteurs, des canaux, des objectifs et une logique de diffusion.

COMPOSANTES MESURABLES D'UNE CAMPAGNE DE DÉSINFORMATION :

- [1] SOURCE : origine du contenu (authentique vs fabriqué)
 - Mesure : analyse de la date de création du compte, cohérence historique du profil, patterns de publication (horaires, fréquence)
- [2] AMPLIFICATION : réseau d'amplification coordonné
 - Mesure : détection de comportements coordonnés (CIB – Coordinated Inauthentic Behavior) : comptes qui postent le même contenu en même temps, avec le même vocabulaire
- [3] CONTENU : caractéristiques linguistiques de la désinformation
 - Mesure : modèles de classification NLP entraînés sur des corpus labellisés (fake news vs real news)
- [4] RÉCEPTION : qui croit et qui propage la désinformation
 - Mesure : corrélation entre profil psychographique et susceptibilité (le névrosisme élevé et la faible ouverture → plus vulnérable)

8.2 DÉTECTION DE FAUX COMPTES ET COMPORTEMENTS COORDONNÉS

FEATURES CARACTÉRISTIQUES D'UN BOT / FAUX COMPTE :

- Date de création récente (< 6 mois)
- Ratio followers/following anormal
- Fréquence de publication irréaliste (> 100 posts/jour)
- Absence de photo de profil originale (détectable par reverse image search)
- Distribution temporelle anormale (publication à toute heure, 24h/24)
- Contenu peu original (quasi-exclusivement des retweets)
- Absence d'interactions authentiques (likes/réponses spontanés)

MODÈLE DE DÉTECTION DE BOT :

```
from sklearn.ensemble import GradientBoostingClassifier
from sklearn.model_selection import train_test_split
from sklearn.metrics import classification_report
import pandas as pd

# Dataset labellé : 0 = humain authentique, 1 = bot/faux compte
df = pd.read_csv("comptes_labelises.csv")

features = [
    "age_compte_jours", "ratio_followers_following",
    "posts_par_jour", "ratio_retweets", "heure_moy_ecart_type",
    "nb_languages_différentes", "taux_originalite_contenu",
    "score_similarite_avatar"
]

X = df[features]
y = df["est_bot"]

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)

model = GradientBoostingClassifier(n_estimators=200, max_depth=4)
model.fit(X_train, y_train)

y_pred = model.predict(X_test)
print(classification_report(y_test, y_pred,
    target_names=["Authentique", "Bot"]))
```

8.3 CLASSIFICATION AUTOMATIQUE DE FAKE NEWS

APPROCHE PAR FEATURES LINGUISTIQUES :

- Les fake news ont des caractéristiques stylistiques mesurables :
- Vocabulaire émotionnel plus intense (LIWC scores)
 - Plus de termes absolus ("toujours", "jamais", "tous", "personne")
 - Moins de nuances (peu de modaux : "peut-être", "probablement")
 - Titres plus sensationnels (ponctuation excessive, majuscules)
 - Moins de citations de sources
 - Plus de pronoms à la première personne du pluriel ("nous", "notre")

```

from transformers import pipeline

# Modèle de détection de fake news (nécessite fine-tuning sur données FR)
fake_detector = pipeline(
    "text-classification",
    model="mrms8488/bert-tiny-finetuned-fake-news-detection"
)

articles = [
    "Des scientifiques prouvent que le vaccin modifie l'ADN humain !",
    "L'Institut Pasteur publie des résultats préliminaires sur l'efficacité."
]

for article in articles:
    result = fake_detector(article)[0]
    print(f"[{result['label']} | {result['score']:.2f}] {article[:70]}...")

```

PARTIE IX – PRÉDICTION DES COMPORTEMENTS COLLECTIFS

9.1 PRÉDICTION DES MOUVEMENTS SOCIAUX

La prédiction des mouvements sociaux repose sur la détection précoce de signaux précurseurs dans les données.

VARIABLES PRÉDICTIVES D'UN MOUVEMENT SOCIAL :

INDICATEURS EN LIGNE :

- Volume et vélocité de mentions d'une thématique
- Sentiment moyen et sa vitesse de dégradation
- Croissance des communautés de mécontentement
- Émergence de hashtags de coordination
- Partage de contenus d'organisation (dates, lieux, consignes)

INDICATEURS HORS LIGNE :

- Enquêtes de confiance institutionnelle (baromètres)
- Taux de chômage, pouvoir d'achat, inégalités (données macro)
- Historique des mouvements précédents (saisonnalité, déclencheurs)

MODÈLE DE PRÉDICTION HYBRIDE :

```

import pandas as pd
from sklearn.ensemble import RandomForestClassifier
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import TimeSeriesSplit
from sklearn.metrics import roc_auc_score

df = pd.read_csv("dataset_mouvements_sociaux.csv", parse_dates=["date"])
df = df.sort_values("date")

features = [
    "volume_mentions_7j", "sentiment_moyen_7j", "croissance_communautes",
    "nb_hashtags_coordination", "taux_chomage", "inflation_mensuelle",
    "confiance_gouvernement", "historique_manifestations_3mois"
]

X = df[features]
y = df["mouvement_dans_30j"] # 0 = pas de mouvement, 1 = mouvement

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

tscv = TimeSeriesSplit(n_splits=5)
model = RandomForestClassifier(n_estimators=200, class_weight="balanced")
auc_scores = []

for train_idx, test_idx in tscv.split(X_scaled):
    model.fit(X_scaled[train_idx], y.iloc[train_idx])
    y_prob = model.predict_proba(X_scaled[test_idx])[:, 1]
    auc_scores.append(roc_auc_score(y.iloc[test_idx], y_prob))

print(f"AUC moyen : {sum(auc_scores)/len(auc_scores):.3f}")

```

9.2 PRÉDICTION ÉLECTORALE PAR LES DONNÉES SOCIALES

La prédiction électorale à partir des données sociales est l'un des domaines les plus étudiés et les plus controversés de la data science sociale.

MÉTHODES PRINCIPALES :

- [1] ANALYSE DU SENTIMENT PAR CANDIDAT
 - Suivre l'évolution du sentiment positif/négatif pour chaque candidat
 - Corrélation avec les intentions de vote des sondages traditionnels
 - Limite : les utilisateurs Twitter ne représentent pas l'électorat réel
- [2] SHARE OF VOICE (SOV)
 - Part des mentions totales obtenue par chaque candidat
 - Simple proxy de visibilité et de mobilisation
 - Corrélation modérée avec les résultats électoraux
- [3] ANALYSE DE L'ENTHOUSIASME (Enthusiasm Gap)
 - L'intensité émotionnelle des supporters prédit mieux que les sondages le taux de mobilisation réel le jour du vote
 - Mesure : longueur des posts, nombre de signes d'exclamation, fréquence des mentions spontanées (non sollicitées)
- [4] MODÈLES ENSEMBLES MULTI-SOURCES
 - Combiner données sociales + sondages + données économiques + données historiques de vote
 - L'ensemble dépasse systématiquement chaque méthode seule

9.3 SIMULATION AGENT-BASED DE LA SOCIÉTÉ

La modélisation agent-based (ABM) simule une population d'agents autonomes dont les interactions locales produisent des comportements collectifs émergents.

UTILITÉ POUR LA DATA SCIENCE SOCIALE :

- Tester des scénarios "et si" impossibles à évaluer empiriquement
- Simuler l'impact d'une campagne de communication avant déploiement
- Comprendre les dynamiques de polarisation à partir de règles simples
- Prédire des points de bascule dans des systèmes sociaux complexes

EXEMPLE SIMPLIFIÉ : MODÈLE DE POLARISATION OPINION

```
import numpy as np
import matplotlib.pyplot as plt

# Population de N agents avec une opinion entre -1 (gauche) et +1 (droite)
N = 500
opinions = np.random.uniform(-1, 1, N)
tolerance = 0.5 # seuil au-delà duquel on refuse d'interagir

def mise_a_jour(opinions, tolerance, mu=0.3):
    """Mise à jour selon modèle de Deffuant : on s'influence mutuellement
    seulement si on est suffisamment proches."""
    i, j = np.random.choice(N, 2, replace=False)
    if abs(opinions[i] - opinions[j]) < tolerance:
        diff = opinions[j] - opinions[i]
        opinions[i] += mu * diff
        opinions[j] -= mu * diff
    return opinions

# Simulation sur 100 000 itérations
for _ in range(100_000):
    opinions = mise_a_jour(opinions, tolerance)

plt.hist(opinions, bins=50, color="steelblue", edgecolor="white")
plt.xlabel("Position d'opinion (-1 : gauche, +1 : droite)")
plt.ylabel("Nombre d'agents")
plt.title("Distribution des opinions après convergence\n(Modèle de Deffuant)")
plt.show()
```

10.1 LE NUDGE : INFLUENCER SANS CONTRAINDRE

Un nudge (coup de pouce) est toute modification de l'environnement de choix qui oriente le comportement d'une manière prévisible, sans interdire ni changer les incitations économiques.

Concept développé par Thaler & Sunstein (Prix Nobel d'économie 2017).

TYPES DE NUDGES ET LEUR EFFICACITÉ MESURÉE :

- [1] VALEUR PAR DÉFAUT (Default)
 - L'option par défaut est la plus choisie, quelle que soit sa nature
 - Exemple : opt-in vs opt-out pour le don d'organes (opt-out → taux de consentement de 95% vs 15% pour opt-in)
 - Mesure data : taux d'activation des options par défaut vs alternatives
- [2] NORME SOCIALE (Social Norm)
 - "Vos voisins consomment 20% moins d'énergie que vous"
 - Efficacité prouvée : réduction de 2-4% de la consommation électrique
 - Mesure : comparaison pré/post affichage de la norme sociale
- [3] SIMPLIFICATION (Friction reduction)
 - Réduire le nombre d'étapes vers le comportement souhaité
 - Augmenter la friction vers les comportements à décourager
 - Mesure : taux de complétion en fonction du nombre d'étapes
- [4] ANCORAGE TEMPOREL (Commitment device)
 - "Commencez maintenant, nous vous rappellerons dans 30 jours"
 - Exploite le biais de présent (on valorise le présent par rapport au futur)
 - Mesure : taux de maintien du comportement à 1, 3, 6 mois
- [5] FEEDBACK EN TEMPS RÉEL
 - Afficher immédiatement les conséquences d'un comportement
 - Exemple : compteur calorique en temps réel lors de commandes en ligne
 - Mesure : changement dans la composition des commandes

10.2 A/B TESTING COMPORTEMENTAL À GRANDE ÉCHELLE

L'A/B test est l'outil fondamental pour mesurer l'impact causal d'un changement comportemental sur une population.

PROCESSUS RIGoureux D'A/B TEST COMPORTEMENTAL :

```
import scipy.stats as stats
import numpy as np

# Groupe A : condition contrôle (pas de nudge)
# Groupe B : condition expérimentale (nudge activé)

n_A, n_B = 10_000, 10_000 # taille des groupes
conv_A, conv_B = 1250, 1480 # conversions observées

taux_A = conv_A / n_A
taux_B = conv_B / n_B

# Test de proportion bilatéral
count = np.array([conv_B, conv_A])
nobs = np.array([n_B, n_A])
z_stat, p_value = stats.proportions_ztest(count, nobs)

print(f"Taux A : {taux_A:.3%} | Taux B : {taux_B:.3%}")
print(f"Lift : +{((taux_B - taux_A)/taux_A):.1%}")
print(f"p-value : {p_value:.4f}")
print(f"Significatif ( $\alpha=0.05$ ) : {p_value < 0.05}")

# Calcul de la taille d'échantillon nécessaire a priori
from statsmodels.stats.power import NormalIndPower
analysis = NormalIndPower()
```

```
n_required = analysis.solve_power(
    effect_size=0.1, # différence minimale détectable
    alpha=0.05,
    power=0.80
)
print(f"\nTaille d'échantillon requise par groupe : {int(n_required)}")
```

PARTIE XI – APPLICATIONS : POLITIQUE, MARCHÉ, SÉCURITÉ, SOCIÉTÉ

11.1 APPLICATIONS EN COMMUNICATION POLITIQUE

LA GUERRE DE L'ATTENTION :

Les partis politiques modernes traitent la communication comme une campagne marketing basée sur les données, avec des objectifs de conversion clairs.

PIPELINE DE COMMUNICATION POLITIQUE DATA-DRIVEN :

- [1] CARTOGRAPHIE DE L'ÉLECTORAT
 - Segmentation psychographique des électeurs
 - Identification des "persuadables" (ni convaincus ni opposés irréductibles)
 - Géolocalisation des zones à fort potentiel de gain
- [2] MESSAGES PERSONNALISÉS
 - Messages différents par segment (sécurité, économie, identité, écologie)
 - Test de multiples formats (vidéo, texte, image, infographie)
 - Optimisation continue par performance
- [3] MOBILISATION DIFFÉRENTIELLE
 - Mobiliser ses partisans (turnout)
 - Démobiliser les partisans adverses (suppression – tactique controversée)
 - Identifier et activer les non-inscrits favorables
- [4] MONITORING EN TEMPS RÉEL
 - Dashboard de sentiment par région, démographie, thème
 - Détection rapide des crises narratives
 - Ajustement de message en < 24h

11.2 APPLICATIONS EN MARKETING ET CONSOMMATION SOCIALE

Le marketing moderne est une science du comportement social appliquée à l'intention d'achat.

SEGMENTATION COMPORTEMENTALE DES CONSOMMATEURS :

Au-delà des segments traditionnels (âge, sexe, revenu), la segmentation psychographique et comportementale produit des groupes d'une homogénéité et d'une actionabilité sans précédent.

Exemple : segmenter non pas par "femmes 25-35 ans" mais par :

- "Femmes soucieuses de leur image sociale, très influençables par la preuve sociale, avec haute activité Instagram et faible délai de décision d'achat"

ÉCONOMIE DE L'ATTENTION ET DESIGN ADDICTIF :

- Les produits numériques optimisent le temps passé sur la plateforme
- Métriques cibles : DAU/MAU, session length, return rate
- Techniques : variable reward schedules (slots machines du numérique), social validation loops (likes), fear of missing out (FOMO)

11.3 APPLICATIONS EN SÉCURITÉ ET RENSEIGNEMENT SOCIAL

VEILLE STRATÉGIQUE ET ANTICIPATION :

- Monitoring en temps réel des signaux de radicalisation
- Détection de mouvements extrémistes émergents
- Analyse des flux de désinformation pendant des élections

GESTION DE CRISE SOCIALE :

- Modélisation de la propagation d'une rumeur ou d'une crise

- Identification des vecteurs à neutraliser en priorité
- Communication de contre-narratives ciblées

ANALYSE PRÉDICTIVE DE LA CRIMINALITÉ SOCIALE :

- Prédiction des zones et moments de tensions communautaires
- Anticipation des débordements lors de rassemblements
- Allocation préventive des ressources

PARTIE XII – ÉTHIQUE, LIMITES ET RESPONSABILITÉ DU DATA SCIENTIST SOCIAL

12.1 LES LIGNES QUI NE DOIVENT PAS ÊTRE FRANCHIES

La data science sociale est une discipline à double tranchant.
Les mêmes outils qui servent à comprendre la société peuvent être utilisés pour la manipuler contre l'intérêt des individus.

COMPRENDRE ≠ MANIPULER

Comprendre les biais cognitifs → aider les gens à mieux décider
Exploiter les biais cognitifs → empêcher les gens de décider librement

Comprendre les émotions collectives → gérer une crise, soutenir les populations
Amplifier artificiellement les émotions → créer une panique, déclencher la haine

Analyser les comportements → améliorer les services, personnaliser l'aide
Utiliser les comportements → piéger les gens dans des boucles addictives

12.2 LE CADRE ÉTHIQUE DU DATA SCIENTIST SOCIAL

PRINCIPES FONDAMENTAUX :

- [1] CONSENTEMENT ÉCLAIRÉ
 - Les individus dont on collecte les données doivent en être informés
 - Le consentement doit être libre, spécifique et révocable
- [2] PROPORTIONNALITÉ
 - Collecter uniquement les données nécessaires à l'objectif déclaré
 - Ne pas conserver les données au-delà de la nécessité
- [3] NON-DISCRIMINATION
 - Les modèles ne doivent pas discriminer sur des critères protégés
 - Mesurer et corriger les biais algorithmiques
- [4] TRANSPARENCE
 - Les personnes affectées par un algorithme doivent pouvoir en connaître la logique et la contester
- [5] INTÉRÊT PUBLIC
 - La finalité de l'analyse doit bénéficier à la société ou à l'individu, pas uniquement à l'organisation commanditaire

CADRE LÉGAL APPLICABLE :

- RGPD (Union Européenne) : protection des données personnelles
- Loi Informatique et Libertés (France)
- DSA/DMA : régulation des grandes plateformes numériques
- Proposition de loi sur l'IA (EU AI Act) : encadrement des systèmes à risque

12.3 LES CAS EMBLÉMATIQUES À CONNAÎTRE

- [1] CAMBRIDGE ANALYTICA (2016-2018)
 - Collecte non consentie des données de 87 millions d'utilisateurs Facebook
 - Création de profils psychographiques à des fins de micro-ciblage politique
 - Utilisation lors du Brexit et de l'élection présidentielle américaine 2016
 - Leçon : les méthodes existent, la question est leur cadre d'utilisation
- [2] EXPERIENCE FACEBOOK SUR LA CONTAGION ÉMOTIONNELLE (2014)
 - Manipulation des flux de 700 000 utilisateurs sans consentement

- Démonstration de la contagion émotionnelle à l'échelle numérique
- Leçon : les expériences comportementales à grande échelle nécessitent un consentement et une supervision éthique

[3] SYSTÈMES DE SCORING SOCIAL (CHINE)

- Agrégation de données comportementales pour attribuer un score de "fiabilité sociale"
- Conséquences réelles : accès au crédit, voyages, emploi
- Leçon : la donnée n'est pas neutre, elle est politique

[4] NUDGE UNIT (ROYAUME-UNI, BEHAVIORAL INSIGHTS TEAM)

- Utilisation systématique des nudges par le gouvernement britannique
- Résultats positifs : augmentation du paiement des impôts, dons d'organes, économies d'énergie
- Leçon : la même approche peut servir le bien commun ou l'intérêt étroit

PARTIE XIII – OUTILS, STACK TECHNIQUE ET PROJETS CONCRETS

13.1 STACK TECHNIQUE COMPLET DU DATA SCIENTIST SOCIAL

COLLECTE DE DONNÉES SOCIALES :

- tweepy, snsrape → Twitter/X
- praw → Reddit
- youtube-data-api → YouTube
- selenium / playwright → scraping de sites
- requests + BeautifulSoup → parsing HTML

TRAITEMENT DU LANGAGE NATUREL :

- spaCy → NLP de base en français (tokenisation, NER, POS)
- transformers (HuggingFace) → BERT, CamemBERT, RoBERTa
- gensim → Word2Vec, LDA (topic modeling)
- VADER, TextBlob → sentiment rapide
- sentence-transformers → embeddings sémantiques

ANALYSE DE RÉSEAUX :

- networkx → manipulation de graphes (< 100K noeuds)
- igraph → graphes larges (C backend)
- gephi → visualisation interactive de réseaux
- python-louvain → détection de communautés

MODÉLISATION ET SIMULATION :

- scikit-learn → ML classique (classification, clustering)
- scipy → modèles SIR, statistiques
- mesa → framework de simulation agent-based
- statsmodels → tests statistiques, séries temporelles

VISUALISATION :

- matplotlib, seaborn → visualisations statiques
- plotly → visualisations interactives
- Gephi, Cytoscape → réseaux sociaux
- Flourish, Datawrapper → visualisations narratives pour non-techniciens

13.2 PROJETS CONCRETS À RÉALISER

PROJET 1 – BAROMÈTRE D'OPINION EN TEMPS RÉEL

Objectif : tableau de bord de l'opinion publique sur un sujet donné
 Données : API Twitter + Reddit + Google Trends
 Méthodes : sentiment analysis, topic modeling, visualisation temporelle
 Livrables : dashboard Streamlit ou Dash avec alertes automatiques

PROJET 2 – CARTOGRAPHIE DES CHAMBRES D'ÉCHO

Objectif : visualiser les bulles informationnelles dans un réseau social
 Données : graphe de relations d'un réseau (follows, mentions, retweets)
 Méthodes : SNA (centralité, détection de communautés), homophilie
 Livrables : visualisation réseau interactive + rapport d'analyse

PROJET 3 – DÉTECTEUR DE CAMPAGNES DE DÉSINFORMATION

Objectif : identifier les réseaux coordonnés de faux comptes
 Données : comportements de comptes Twitter sur une période donnée

Méthodes : clustering, détection d'anomalies, classification NLP
Livrables : modèle de scoring des comptes + interface d'alerte

PROJET 4 – PROFIL PSYCHOGRAPHIQUE À PARTIR DE DONNÉES PUBLIQUES

Objectif : inférer les traits OCEAN à partir des comportements en ligne
Données : posts, likes, activité publique d'un panel consentant
Méthodes : régression supervisée, feature engineering
Livrables : modèle de prédiction + rapport de fiabilité et limites

PROJET 5 – SIMULATION D'UNE CAMPAGNE DE NUDGE

Objectif : simuler l'impact d'un nudge avant déploiement réel
Données : données comportementales historiques d'une population cible
Méthodes : modélisation ABM + calibration sur données réelles
Livrables : rapport de simulation + estimations de l'impact attendu

13.3 RESSOURCES POUR ALLER PLUS LOIN

LIVRES FONDAMENTAUX :

- Gustave Le Bon – "Psychologie des foules" (1895, fondateur)
- Robert Cialdini – "Influence et manipulation" (persuasion)
- Thaler & Sunstein – "Nudge" (architecture du choix)
- Eli Pariser – "The Filter Bubble" (bulles algorithmiques)
- Sasha Issenberg – "The Victory Lab" (data et politique électorale)
- Cathy O'Neil – "Weapons of Math Destruction" (algorithmes et société)
- Shoshana Zuboff – "The Age of Surveillance Capitalism" (économie de la donnée)

PAPERS SCIENTIFIQUES CLÉS :

- Kosinski et al. (2013) "Private traits and attributes are predictable from digital records of human behavior" – PNAS
- Kramer et al. (2014) "Experimental evidence of massive-scale emotional contagion through social networks" – PNAS
- Flaxman et al. (2016) "Filter bubbles, echo chambers, and online news consumption" – Public Opinion Quarterly
- Bail et al. (2018) "Exposure to opposing views on social media can increase political polarization" – PNAS

DATASETS PUBLICS POUR S'ENTRAÎNER :

- FakeNewsNet : corpus de fake news labellisées
- Botometer datasets : comptes Twitter labellisés (bots vs humains)
- LIAR dataset : 12K déclarations politiques fact-checkées
- myPersonality dataset : données Facebook + scores OCEAN (accès restreint)
- Election datasets : données électorales + Twitter (Stanford Internet Observatory)

FIN DU COURS

GCI – GYKHAMINE CONCEPT INVESTIGATION
DATA SCIENCE & PSYCHOLOGIE SOCIALE DES FOULES

"Comprendre la foule, c'est comprendre que la somme des consciences individuelles ne produit pas une conscience collective rationnelle. C'est la leçon centrale – et la responsabilité fondamentale – de tout data scientist qui travaille sur le comportement humain."
